


TRƯỜNG ĐẠI HỌC KỸ THUẬT - CÔNG NGHỆ CẦN THƠ

KHOA CÔNG NGHỆ THÔNG TIN



ĐỒ ÁN 2

Ngành: Công nghệ thông tin


**DỰ BÁO CHẤT LƯỢNG KHÔNG KHÍ ĐA VÙNG
DỰA TRÊN CÁC CHỈ SỐ THỜI TIẾT**

NGUYỄN TRƯỜNG DUY

NGUYỄN NGỌC SƠN

Cần Thơ, Tháng 4 Năm 2026

TRƯỜNG ĐẠI HỌC KỸ THUẬT - CÔNG NGHỆ CẦN THƠ
KHOA CÔNG NGHỆ THÔNG TIN



ĐỒ ÁN 2

Ngành: Công nghệ thông tin

**DỰ BÁO CHẤT LƯỢNG KHÔNG KHÍ ĐA VÙNG
DỰA TRÊN CÁC CHỈ SỐ THỜI TIẾT**

Cán bộ hướng dẫn:
Ths. Lê Anh Nhã Uyên

Sinh viên thực hiện:
Nguyễn Trường Duy
MSSV: CNTT2311041

Nguyễn Ngọc Sơn
MSSV: CNTT2311095

Cần Thơ, Tháng 4 Năm 2026

NHẬN XÉT CỦA GIẢNG VIÊN HƯỚNG DẪN

Sinh viên thực hiện	Mã số sinh viên
Nguyễn Trường Duy	CNTT2311041
Nguyễn Ngọc Sơn	CNTT2311095

Tên đề tài: Dự báo chất lượng không khí đa vùng dựa trên các chỉ số thời tiết

Họ và tên GVHD: Ths. Lê Anh Nhã Uyên

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

Cần Thơ, Ngày 16 tháng 4 năm 2026
Giảng viên hướng dẫn

Ths. Lê Anh Nhã Uyên

NHẬN XÉT CỦA GIẢNG VIÊN PHẢN BIỆN

Sinh viên thực hiện	Mã số sinh viên
Nguyễn Trường Duy	CNTT2311041
Nguyễn Ngọc Sơn	CNTT2311095

Tên đề tài: Dự báo chất lượng không khí đa vùng dựa trên các chỉ số thời tiết

Họ và tên GVHD: Ths. Lê Anh Nhã Uyên

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

Cần Thơ, Ngày 16 tháng 4 năm 2026
Giảng viên phản biện

Ths. Lê Anh Nhã Uyên

LỜI CAM ĐOAN

Chúng tôi xin được cam đoan đề tài “**Dự báo chất lượng không khí đa vùng dựa trên các chỉ số thời tiết**” được tiến hành công khai, là công trình nghiên cứu dựa trên sự cố gắng, nỗ lực của bản thân tôi và các cộng sự trong thời gian qua.

Các số liệu và kết quả nghiên cứu của đề tài là trung thực, không sao chép hoặc sử dụng kết quả của đề tài nghiên cứu nào tương tự. Tất cả những sự giúp đỡ cho việc xây dựng cơ sở lý thuyết đều được trích dẫn đầy đủ và ghi nguồn gốc rõ ràng và được phép công bố.

Chúng tôi xin chịu hoàn toàn trách nhiệm nếu có sự không trung thực trong thông tin sử dụng trong công trình nghiên cứu này.

Cần Thơ, ngày 16 tháng 4 năm 2026

Tác giả đề tài

Nguyễn Trường Duy

Nguyễn Ngọc Sơn

LỜI CẢM ƠN

Để hoàn thành đề tài “**Dự báo chất lượng không khí đa vùng dựa trên các chỉ số thời tiết**” này, ngoài sự nỗ lực và cố gắng của bản thân tôi và các cộng sự, chúng tôi đã nhận được sự quan tâm, giúp đỡ và hỗ trợ quý báu từ nhiều cá nhân và tập thể. Chúng tôi xin được gửi lời tri ân sâu sắc nhất đến:

Ban Giám hiệu Nhà trường và Khoa Công nghệ thông tin: Đã tạo mọi điều kiện thuận lợi về cơ sở vật chất, môi trường học tập, và cung cấp các kiến thức nền tảng quan trọng trong suốt quá trình học tập và nghiên cứu.

Thạc sĩ Lê Anh Nhã Uyên: Người đã trực tiếp hướng dẫn, tận tâm truyền đạt kinh nghiệm, cung cấp những lời khuyên chuyên môn sâu sắc và động viên kịp thời để chúng tôi có thể hoàn thành đề tài một cách trọn vẹn.

Tất cả các nguồn tài liệu, nghiên cứu và công cụ đã được trích dẫn trong đồ án: Đã cung cấp cơ sở lý thuyết và nền tảng kỹ thuật vững chắc để đề tài được xây dựng một cách khoa học và trung thực.

TÓM LƯỢC

Ô nhiễm không khí, đặc biệt bụi mịn $PM_{2.5}$, đang là vấn đề nghiêm trọng tại Việt Nam, ảnh hưởng trực tiếp đến sức khỏe cộng đồng. Việc dự báo chính xác nồng độ $PM_{2.5}$ trong ngắn hạn (1–24 giờ) đóng vai trò quan trọng trong hệ thống cảnh báo sớm và hỗ trợ ra quyết định. Đề án này xây dựng và so sánh **6 mô hình** dự báo $PM_{2.5}$ multi-horizon ($T + 1, T + 3, T + 6, T + 12, T + 24$ giờ), bao gồm: XGBoost, XLinear, ESTGCN, ST-XLinear, Ensemble và iTransformer. Dữ liệu được thu thập từ **12 trạm quan trắc** (6 miền Bắc, 6 miền Nam), kết hợp dữ liệu chất lượng không khí ($PM_{2.5}, PM_{10}, CO, NO_2, SO_2, O_3$) và dữ liệu khí tượng (nhiệt độ, độ ẩm, gió, lượng mưa, nhiệt độ đất). Một pipeline tiền xử lý hoàn chỉnh gồm 12 bước đã được thiết kế, bao gồm phát hiện lỗi cảm biến quang học (OPC), xử lý dữ liệu đóng băng, ngoại lai, và 6 đặc trưng kỹ thuật mới dựa trên kiến thức hóa học khí quyển (oxidation potential, humid sulfate risk, thermal stability...). Đặc biệt, đề án đề xuất **Dynamic Graph Builder** — ma trận kề thay đổi theo hướng gió thực tế ($\alpha = 0.4858$), nhằm mô hình hóa sự lan truyền ô nhiễm giữa các trạm. Kết quả cho thấy **XGBoost đạt hiệu suất cao nhất** xuyên suốt mọi horizon dự báo, với $R^2 = 90.47\%$ ($T + 1$) và 70.95% ($T + 24$), vượt trội so với các mô hình Deep Learning. Sai số RMSE trung bình chỉ dao động từ $5.16 \mu g/m^3$ ($T + 1$) đến $11.52 \mu g/m^3$ ($T + 24$). Cụm trạm miền Nam cho kết quả tốt hơn miền Bắc ($R^2 = 98.81\%$ vs 82.12% tại $T + 1$), phản ánh mức độ biến động của hạt $PM_{2.5}$ thấp hơn nhờ đặc thù khí hậu rửa trôi. Toàn bộ hệ thống đã được tích hợp thành ứng dụng Web Streamlit, cho phép giám sát và dự báo trực tuyến $PM_{2.5}$ tại 12 trạm, sẵn sàng phục vụ mục đích cảnh báo dân sinh.

ABSTRACT

Air pollution, particularly concerning fine particulate matter ($\text{PM}_{2.5}$), has emerged as a critical environmental concern in Vietnam with direct implications for public health. Accurate short-term forecasting of $\text{PM}_{2.5}$ concentrations (1–24 hours) plays a pivotal role in early warning systems and decision-making support. This study develops and benchmarks **six advanced models** for multi-horizon $\text{PM}_{2.5}$ prediction (T+1, T+3, T+6, T+12, T+24 hours), namely: XGBoost, XLinear, ESTGCN, ST-XLinear, Ensemble, and iTransformer. The dataset was acquired from **12 sensor monitoring stations** (6 in Northern and 6 in Southern Vietnam), deeply integrating air quality metrics ($\text{PM}_{2.5}$, PM_{10} , CO, NO_2 , SO_2 , O_3) with meteorological sequences (temperature, relative humidity, wind dynamics, precipitation, and soil temperature). A comprehensive, 12-step preprocessing pipeline was devised, encompassing the detection of Optical Particle Counter (OPC) failures, mitigation of sensor freezing anomalies, outlier handling, and the synthesis of six novel engineered features grounded in atmospheric chemistry (e.g., oxidation potential, humid sulfate risk, and thermal stability). Notably, to effectively model the spatiotemporal propagation of pollution among stations, this research proposes a **Dynamic Graph Builder**—an adjacency matrix strictly modulated by real-time wind directions ($\alpha = 0.4858$). Experimental results demonstrate that **XGBoost achieves the highest predictive efficiency** consistently across all forecast horizons, yielding an $R^2 = 90.47\%$ (T+1) and 70.95% (T+24), significantly outperforming the comparative deep learning architectures. The mean RMSE ranges precisely from $5.16 \mu\text{g}/\text{m}^3$ (T+1) to $11.52 \mu\text{g}/\text{m}^3$ (T+24). Furthermore, the Southern station cluster exhibited superior accuracy metrics compared to the Northern cluster ($R^2 = 98.81\%$ vs. 82.12% at T+1), reflecting a lower intrinsic volatility of $\text{PM}_{2.5}$ particles attributable to the region-specific climatic wash-out effect. Ultimately, the entire algorithmic framework was successfully deployed into an interactive Streamlit web application, facilitating real-time monitoring and online forecasting of $\text{PM}_{2.5}$ across all 12 stations, providing a highly scalable and functional public health early warning system.

MỤC LỤC

NHẬN XÉT CỦA GIẢNG VIÊN HƯỚNG DẪN	i
NHẬN XÉT CỦA GIẢNG VIÊN PHẢN BIỆN	ii
LỜI CAM ĐOAN	iii
LỜI CẢM ƠN	iv
TÓM LƯỢC	v
ABSTRACT	vi
DANH MỤC CÁC TỪ VIẾT TẮT VÀ THUẬT NGỮ	xi
DANH MỤC HÌNH VẼ	xv
DANH MỤC BẢNG BIỂU	xvi
LỜI MỞ ĐẦU	xviii
1. Lý do chọn đề tài	xviii
2. Mục tiêu nghiên cứu	xviii
3. Đối tượng và phạm vi nghiên cứu	xix
4. Phương pháp nghiên cứu	xix
5. Cấu trúc của đồ án	xx
1 TỔNG QUAN LÝ THUYẾT VÀ CƠ SỞ NGHIÊN CỨU	1
1. Tổng quan về ô nhiễm không khí và $PM_{2.5}$	1
1.1. Ô nhiễm không khí tại Việt Nam	1
1.2. Bụi mịn $PM_{2.5}$	2
1.3. Tác động của $PM_{2.5}$ đến sức khỏe con người	2
2. Cơ sở lý thuyết kỹ thuật	3
2.1. Bài toán dự báo chuỗi thời gian	3
2.2. Nhóm mô hình Machine Learning	5
2.3. Nhóm mô hình Deep Learning — Temporal	6
2.4. Nhóm mô hình Spatio-Temporal	10
2.5. Các chỉ số đánh giá hiệu suất	15
2.6. Các phương pháp chuẩn hóa dữ liệu	16
2.7. Các công trình nghiên cứu liên quan	18

2	PHƯƠNG TIỆN NGHIÊN CỨU - PHƯƠNG PHÁP NGHIÊN CỨU	20
1.	Sơ đồ tổng quan giải pháp	20
2.	Phương tiện nghiên cứu	22
2.1.	Ngôn ngữ lập trình và thư viện	22
2.2.	Phần cứng	22
3.	Thu thập dữ liệu	22
3.1.	Dữ liệu chất lượng không khí	23
3.2.	Dữ liệu thời tiết lịch sử	23
3.3.	Siêu dữ liệu	23
4.	Khảo sát và chọn lọc trạm quan trắc	24
4.1.	Sự cần thiết của bước chọn lọc	24
4.2.	Hệ thống tiêu chí lọc	24
4.3.	Kết quả chọn lọc	25
5.	Tiền xử lý dữ liệu — Làm sạch	26
5.1.	Bước 1 — Mã hóa tuần hoàn và phân tách thành phần gió	27
5.2.	Bước 2 — Kiểm tra khoảng thời gian	27
5.3.	Bước 3 — Phát hiện dữ liệu đóng băng	27
5.4.	Bước 4 — Phát hiện ngoại lai	27
5.5.	Bước 5 — Phát hiện lỗi cảm biến quang học	28
5.6.	Bước 6 — Xóa trùng lặp	28
5.7.	Bước 7 — Điền giá trị khuyết	29
6.	Kỹ thuật đặc trưng	29
6.1.	Tổng quan và lý do thực hiện	29
6.2.	Đặc trưng tương tác	30
6.3.	Các nhóm đặc trưng còn lại	31
7.	Chuẩn hóa dữ liệu	32
7.1.	Nguyên tắc chung	32
7.2.	Chi tiết chiến lược	33
7.3.	Lưu trữ bộ chuẩn hóa	33
8.	Chia tập dữ liệu	33
8.1.	Vấn đề với chia dữ liệu truyền thống	33
8.2.	Chiến lược chia theo khối ngày	34
9.	Huấn luyện mô hình	35
9.1.	Tổng quan	35
9.2.	Mô hình 1 — XGBoost	36
9.3.	Mô hình 2 — XLinear	37

9.4.	Mô hình 3 — ESTGCN	38
9.5.	Mô hình 4 — ST-XLinear	39
9.6.	Mô hình 5 — Ensemble	40
9.7.	Mô hình 6 — iTransformer	41
10.	Đánh giá mô hình	42
10.1.	Nguyên tắc đánh giá	42
10.2.	Không gian thực nghiệm	42
10.3.	Các chỉ số đánh giá	43
11.	Triển khai ứng dụng (Deployment)	43
11.1.	Tổng quan kiến trúc triển khai	43
11.2.	Module suy luận	43
11.3.	Giao diện người dùng (Web UI)	43
3	KẾT QUẢ VÀ THẢO LUẬN	45
1.	Kết quả tổng hợp	45
2.	Phân tích hiệu suất theo tầm nhìn dự báo	47
2.1.	Sai số tuyệt đối trung bình (MAE)	47
2.2.	Sai số toàn phương trung bình (RMSE)	48
2.3.	Hệ số xác định R^2	49
2.4.	Sai số phần trăm tuyệt đối trung bình (MAPE)	49
3.	Đánh giá tính ổn định	50
3.1.	Khoảng cách hiệu suất ngắn hạn – dài hạn	51
3.2.	Phân bố RMSE qua các cấu hình	52
3.3.	Đánh giá đa metric đồng thời	52
4.	Ảnh hưởng của vùng miền	54
5.	Ảnh hưởng của chiến lược chia dữ liệu	55
6.	Tốc độ suy giảm hiệu suất	57
7.	Đánh giá phương pháp kết hợp mô hình	58
8.	Chi phí tính toán	59
9.	Ứng dụng web dự báo chất lượng không khí	60
9.1.	Kiến trúc ứng dụng	60
9.2.	Giao diện tổng quan	60
9.3.	Hiển thị các chỉ số ô nhiễm	61
9.4.	Khu vực dự báo	61
10.	Thảo luận	62
10.1.	Đánh giá mức độ đạt mục tiêu	62

10.2.	Ưu điểm của nghiên cứu	63
10.3.	Hạn chế của nghiên cứu	63
4	KẾT LUẬN VÀ ĐỀ XUẤT	64
1.	Kết luận chung	64
1.1.	Về thu thập và tiền xử lý dữ liệu	64
1.2.	Về kỹ thuật đặc trưng và chuẩn hóa	64
1.3.	Về kết quả đối chuẩn mô hình	65
1.4.	Về mô hình đề xuất ST-XLinear	65
1.5.	Về phương pháp Ensemble	66
1.6.	Về chi phí tính toán và triển khai	66
1.7.	Tổng hợp đánh giá	66
2.	Hạn chế	67
2.1.	Quy mô mạng lưới trạm	67
2.2.	Thiếu thực nghiệm phân lập đặc trưng	67
2.3.	Phương pháp Ensemble đơn giản	67
2.4.	Đánh giá chưa kèm khoảng tin cậy	67
2.5.	Thiếu đường cơ sở bên ngoài	68
3.	Kiến nghị và hướng phát triển	68
3.1.	Mở rộng quy mô mạng lưới trạm quan trắc	68
3.2.	Thực nghiệm phân lập đặc trưng	68
3.3.	Cải tiến phương pháp kết hợp mô hình	69
3.4.	Tích hợp dữ liệu dự báo khí tượng số	69
3.5.	Áp dụng xác thực chéo chuỗi thời gian	69
3.6.	Mở rộng so sánh với đường cơ sở bổ sung	70
3.7.	Nâng cấp ứng dụng triển khai	70
3.8.	Cải tiến kiến trúc Dynamic Graph	70
	TÀI LIỆU THAM KHẢO	72

DANH MỤC CÁC TỪ VIẾT TẮT VÀ THUẬT NGỮ

Ký hiệu / Viết tắt	Ý nghĩa đầy đủ
AdamW	Biến thể của thuật toán tối ưu Adam có tích hợp cơ chế phân rã trọng số tách biệt
Aerosol sulfate	Các hạt sulfate (SO_4^{2-}) lơ lửng trong không khí, hình thành từ phản ứng của SO_2 với hơi nước, là nguồn tạo $PM_{2.5}$ thứ cấp
AI	Artificial Intelligence (Trí tuệ nhân tạo)
API	Application Programming Interface (Giao diện lập trình ứng dụng) — cơ chế giao tiếp giữa các hệ thống phần mềm để trao đổi dữ liệu
AQI	Air Quality Index (Chỉ số chất lượng không khí)
ARIMA	Autoregressive Integrated Moving Average (Mô hình tự hồi quy tích hợp trung bình trượt)
AsymmetricHuberLoss	Hàm mất mát Huber bất đối xứng, phạt nặng hơn đối với sai số dự đoán thấp (under-prediction) so với dự đoán cao
Attention Pooling	Cơ chế tổng hợp chuỗi đặc trưng thành một vector đại diện duy nhất bằng trọng số attention
Batch size	Kích thước lô mẫu được nạp vào mô hình trong mỗi bước cập nhật tham số
Benchmark	Đối chuẩn — quy trình đánh giá và so sánh hiệu suất của nhiều mô hình trên cùng tập dữ liệu và điều kiện thí nghiệm
BiLSTM	Bidirectional Long Short-Term Memory (LSTM hai chiều)
Block-days splitting	Chiến lược phân tách dữ liệu theo khối ngày tuần hoàn, đảm bảo mỗi tập con bao phủ mọi điều kiện khí tượng
Boosting	Phương pháp học kết hợp tuần tự, mỗi mô hình mới sửa sai số của mô hình trước đó
CART	Classification and Regression Trees (Cây phân loại và hồi quy)
CMAQ	Community Multiscale Air Quality Model (Mô hình chất lượng không khí đa quy mô)
CNN	Convolutional Neural Network (Mạng thần kinh tích chập)
CO	Carbon Monoxide (Khí carbon monoxit)
CombinedLoss	Hàm mất mát kết hợp có trọng số giữa MSE và HuberLoss, cân bằng giữa bám sát xu thế chính và kháng nhiễu ngoại lai
COPD	Chronic Obstructive Pulmonary Disease (Bệnh phổi tắc nghẽn mãn tính)
CosineAnnealingLR	Bộ lịch trình giảm tốc độ học theo hàm cosin
CUDA	Compute Unified Device Architecture — kiến trúc tính toán song song trên GPU của NVIDIA
DL	Deep Learning (Học sâu)
Dropout	Kỹ thuật chính quy hóa vô hiệu hóa ngẫu nhiên một tỷ lệ nơ-ron trong quá trình huấn luyện
Dynamic Graph Builder	Module xây dựng ma trận kề động thay đổi theo thời gian, tích hợp khoảng cách địa lý và hướng gió thực tế
E-STGCN	Enhanced Spatio-Temporal Graph Convolutional Network
Early stopping	Cơ chế ngắt huấn luyện sớm khi hiệu suất trên tập kiểm định không cải thiện
ECMWF	European Centre for Medium-Range Weather Forecasts (Trung tâm Dự báo Khí tượng Hạn vừa Châu Âu)

Endogenous pathway	Đường dẫn nội sinh — luồng xử lý tín hiệu trực tiếp của biến mục tiêu trong kiến trúc mạng nơ-ron đa phân luồng
Ensemble	Phương pháp kết hợp dự đoán từ nhiều mô hình thành phần nhằm nâng cao hiệu suất tổng thể
Epoch	Một vòng lặp hoàn chỉnh duyệt qua toàn bộ tập dữ liệu huấn luyện
ERA5	Bộ dữ liệu tái phân tích khí tượng toàn cầu thế hệ thứ 5 của ECMWF, độ phân giải $0,25^\circ \times 0,25^\circ$
Error accumulation	Sai số tích lũy — hiện tượng sai số dự báo bị khuếch đại liên tục tỷ lệ thuận theo độ dài của tầm nhìn dự báo
Exogenous pathway	Đường dẫn ngoại sinh — luồng phụ trợ khai thác các biến ngoại vi (thường là dữ liệu khí tượng) thông qua màng lọc hoặc cơ chế gating
Exogenous variables	Biến ngoại sinh — các biến số độc lập đóng vai trò tương tác hỗ trợ quy trình dự báo (như nhiệt độ, hệ số gió)
Feature Engineering	Kỹ thuật xây dựng đặc trưng — quá trình tạo các biến dẫn xuất từ dữ liệu thô nhằm nâng cao hiệu năng mô hình
Forecast horizon	Tầm nhìn dự báo — khoảng thời gian tương lai (tính bằng số bước) mà mô hình cần phải dự toán kết quả
Gaussian kernel	Hàm nhân Gaussian — hàm trọng số dạng chuông chuẩn dùng để chuyển đổi khoảng cách thành hệ số tương đồng
GCN	Graph Convolutional Network (Mạng tích chập đồ thị)
GELU	Gaussian Error Linear Unit (Hàm kích hoạt tuyến tính lỗi Gaussian)
GFS	Global Forecast System (Hệ thống dự báo toàn cầu) — mô hình NWP do NOAA vận hành
Gradient Descent	Thuật toán tối ưu hóa dựa trên gradient, cập nhật tham số theo hướng giảm nhanh nhất của hàm mất mát
Grid Search	Phương pháp tìm kiếm dạng lưới dò quét toàn bộ tổ hợp siêu tham số khả dĩ
GRU	Gated Recurrent Unit (Đơn vị hồi quy có cổng)
Haversine	Công thức tính khoảng cách giữa hai điểm trên mặt cầu dựa trên tọa độ kinh vĩ độ
Hessian	Ma trận đạo hàm riêng bậc hai của hàm mục tiêu
HuberLoss	Hàm mất mát kết hợp ưu điểm của MAE và MSE, sử dụng MSE khi sai số nhỏ và MAE khi sai số lớn
IDW	Inverse Distance Weighting (Nội suy trọng số nghịch đảo khoảng cách)
Inference	Quá trình suy luận — sử dụng mô hình đã huấn luyện để đưa ra dự báo trên dữ liệu mới
Interpretability	Khả năng diễn giải mô hình — đặc tính cho phép bóc tách và giải nghĩa lý do hệ thống thuật toán đưa ra phán đoán dự báo
Inverse-transform	Phép biến đổi ngược từ không gian chuẩn hóa về đơn vị đo gốc
IoT	Internet of Things (Internet vạn vật)
IQR	Interquartile Range (Khoảng tứ phân vị)
iTransformer	Inverted Transformer — kiến trúc Transformer đảo ngược chiều attention sang chiều biến
KNN	K-Nearest Neighbors (K láng giềng gần nhất)
Kriging	Phương pháp nội suy không gian dựa trên mô hình biến đổi bán phương sai, tối ưu cho dữ liệu địa thống kê
Lag	Phép trễ — trích xuất giá trị tại các mốc thời gian trước đó ($t-1, t-3, \dots$) để cung cấp ngữ cảnh lịch sử
LayerNorm	Layer Normalization — kỹ thuật chuẩn hóa trên chiều đặc trưng trong mỗi mẫu, ổn định quá trình huấn luyện mạng sâu
LightGBM	Light Gradient Boosting Machine (Thuật toán tăng cường gradient nhẹ)

Linear projection	Phép chiếu tuyến tính — phép nhân ma trận ánh xạ vector đặc trưng từ không gian d_1 chiều sang không gian d_2 chiều
Log1p	Phép biến đổi $\ln(1 + x)$, xử lý an toàn giá trị bằng không và giảm độ lệch phân phối
Lookback window	Cửa sổ quan sát — đoạn dữ liệu lịch sử có độ dài L bước thời gian được sử dụng làm đầu vào cho mô hình dự báo
LSTM	Long Short-Term Memory (Bộ nhớ dài hạn ngắn hạn)
MAE	Mean Absolute Error (Sai số tuyệt đối trung bình)
MAPE	Mean Absolute Percentage Error (Sai số phần trăm tuyệt đối trung bình)
MinMaxScaler	Phương pháp chuẩn hóa theo giá trị cực tiểu và cực đại, ánh xạ dữ liệu về khoảng $[0, 1]$
ML	Machine Learning (Học máy)
MLP	Multi-Layer Perceptron (Perceptron đa tầng)
MSE	Mean Squared Error (Sai số bình phương trung bình)
Multi-horizon forecasting	Dự báo đa tầm nhìn — bài toán ước lượng đồng thời giá trị tại nhiều bước thời gian tương lai ($T+1, T+3, \dots, T+H$)
NO_2	Nitrogen Dioxide (Khí nitơ dioxit)
Non-stationarity	Tính không dừng — đặc điểm chuỗi thời gian có trung bình, phương sai hoặc cấu trúc tự tương quan thay đổi theo thời gian
NWP	Numerical Weather Prediction (Dự báo thời tiết bằng mô hình số trị)
O_3	Ozone (Khí ozon)
One-hot encoding	Phương pháp mã hóa biến phân loại thành vector nhị phân, mỗi phần tử đại diện một giá trị danh mục
OPC	Optical Particle Counter (Bộ đếm hạt quang học)
Overfitting	Hiện tượng quá khớp khi mô hình học thuộc nhiều thay vì quy luật tổng quát
Patience	Số epoch liên tiếp không cải thiện trước khi kích hoạt early stopping
Pearson	Hệ số tương quan tuyến tính Pearson — thước đo mức độ tương quan tuyến tính giữa hai biến, giá trị trong $[-1, 1]$
Pipeline	Đường ống xử lý — chuỗi các bước xử lý dữ liệu hoặc mô hình được kết nối tuần tự, đầu ra bước trước là đầu vào bước sau
Plotly	Thư viện trực quan hóa dữ liệu tương tác dành cho Python
PM_{10}	Particulate Matter 10 (Bụi có đường kính $\leq 10 \mu m$)
$PM_{2.5}$	Particulate Matter 2.5 (Bụi mịn có đường kính $\leq 2,5 \mu m$)
PyTorch	Thư viện mã nguồn mở cho học sâu, hỗ trợ tính toán tensor trên GPU và cơ chế tự động vi phân
R^2	Coefficient of Determination (Hệ số xác định)
Regularization	Chính quy hóa — kỹ thuật thêm ràng buộc (L1, L2, Dropout) vào quá trình huấn luyện nhằm hạn chế Overfitting
ReLU	Rectified Linear Unit (Hàm kích hoạt tuyến tính chỉnh lưu)
RevIN	Reversible Instance Normalization (Chuẩn hóa mẫu khả nghịch)
RMSE	Root Mean Square Error (Sai số bình phương trung bình gốc)
RNN	Recurrent Neural Network (Mạng thần kinh hồi quy)
RobustScaler	Phương pháp chuẩn hóa sử dụng trung vị và khoảng tứ phân vị, ít nhạy cảm với ngoại lai
Rolling	Thống kê trượt — tính toán trung bình, độ lệch chuẩn trên cửa sổ thời gian di chuyển
ROS	Reactive Oxygen Species (Các gốc oxy phản ứng)
SARIMA	Seasonal ARIMA (ARIMA có thành phần mùa vụ)
Seasonality	Tính mùa vụ — thành phần biến động tuần hoàn với chu kỳ cố định (ngày, tuần, tháng, năm) trong chuỗi thời gian

Self-Attention	Cơ chế tự chú ý — cho phép mỗi phần tử trong chuỗi đánh giá mức độ liên quan với mọi phần tử khác
Sequential processing	Xử lý tuần tự — phương thức tính toán trong đó mỗi bước thời gian phải hoàn thành trước khi bước tiếp theo bắt đầu (đặc trưng của RNN)
Sigmoid	Hàm kích hoạt dạng chữ S ánh xạ đầu ra về khoảng $[0, 1]$
Single-step forecasting	Dự báo đơn bước — bài toán ước lượng giá trị tại một bước thời gian duy nhất ($T+1$) tiếp theo
SO_2	Sulfur Dioxide (Khí lưu huỳnh dioxit)
SOA	Secondary Organic Aerosol (Sol khí hữu cơ thứ cấp)
Spatial dependency	Phụ thuộc không gian — mức độ tương quan thuận giữa nồng độ $PM_{2.5}$ tại trạm quan trắc gốc và sự dịch chuyển gió từ trạm lân cận
Spatial resolution	Phân giải không gian — mức độ chi tiết của lưới tọa độ biểu diễn dữ liệu (ví dụ: $0,25^\circ \times 0,25^\circ$ cho ERA5)
Split finding	Thuật toán tìm điểm phân tách tối ưu trên các nút của cây quyết định trong Gradient Boosting
ST-XLinear	Spatio-Temporal XLinear — mô hình do đồ án đề xuất tích hợp đồ thị động vào XLinear
Stacking	Phương pháp kết hợp mô hình phi tuyến, sử dụng mô hình bậc hai để học cách tổng hợp đầu ra từ các mô hình thành phần
StandardScaler	Phương pháp chuẩn hóa theo trung bình và độ lệch chuẩn, đưa dữ liệu về phân phối chuẩn tắc
Streamlit	Nền tảng mã nguồn mở xây dựng giao diện Web cho ứng dụng khoa học dữ liệu
SVM	Support Vector Machine (Máy vector hỗ trợ)
Temperature inversion	Hiện tượng nghịch nhiệt — trạng thái khí quyển trong đó nhiệt độ tăng theo độ cao (ngược quy luật), tạo lớp chắn ngăn chất ô nhiễm khuếch tán lên trên
Time series forecasting	Dự báo chuỗi thời gian — bài toán ước lượng giá trị tương lai dựa trên chuỗi các quan sát được ghi nhận theo trình tự thời gian
VOCs	Volatile Organic Compounds (Các hợp chất hữu cơ dễ bay hơi)
Washout	Hiện tượng rửa trôi — quá trình mưa cuốn theo các hạt bụi lơ lửng trong khí quyển xuống bề mặt đất, làm giảm nồng độ $PM_{2.5}$
Weight decay	Hệ số phân rã trọng số trong thuật toán tối ưu, kiểm soát mức chính quy hóa L2
WHO	World Health Organization (Tổ chức Y tế Thế giới)
Winsorization	Phương pháp xử lý ngoại lai bằng cách cắt xén giá trị tại một ngưỡng phân vị xác định
WRF	Weather Research and Forecasting Model (Mô hình nghiên cứu và dự báo thời tiết)
XGBoost	Extreme Gradient Boosting
XLinear	Mô hình dự báo chuỗi thời gian dựa trên MLP với cơ chế Gating Block cho biến ngoại sinh

DANH SÁCH HÌNH VẼ

1.1	Kiến trúc tổng quan của mô hình đề xuất ST-XLinear	12
2.1	Sơ đồ tổng quan giải pháp hệ thống dự báo nồng độ $PM_{2.5}$	20
2.2	Phân bố các trạm quan trắc theo hai cụm miền Bắc và miền Nam	25
2.3	Quy trình làm sạch dữ liệu cho mỗi trạm quan trắc	26
2.4	Quy trình vận hành trực tiếp của Ensemble	40
3.1	MAE theo tầm nhìn dự báo — 3 block $\times$ 2 vùng (cùng thang đo)	47
3.2	RMSE theo tầm nhìn dự báo — 3 block $\times$ 2 vùng (cùng thang đo)	48
3.3	Bản đồ nhiệt R^2 — tất cả block $\times$ vùng (thang đo 0–1)	49
3.4	MAPE theo tầm nhìn dự báo — 3 block $\times$ 2 vùng (cùng thang đo)	50
3.5	Khoảng cách MAE giữa $T+1$ và $T+24$ — cùng thang đo	51
3.6	Phân bố RMSE — 3 block $\times$ 5 horizon (cùng thang đo)	52
3.7	Biểu đồ radar đa chỉ số tại $T+1$ — chuẩn hóa min-max, tất cả cấu hình	53
3.8	Chênh lệch hiệu suất giữa miền Bắc và miền Nam — tất cả cấu hình	54
3.9	So sánh MAE giữa ba chiến lược chia dữ liệu — tất cả mô hình	55
3.10	So sánh RMSE giữa ba chiến lược chia dữ liệu — tất cả mô hình	55
3.11	So sánh R^2 giữa ba chiến lược chia dữ liệu — tất cả mô hình	55
3.12	So sánh MAPE giữa ba chiến lược chia dữ liệu — tất cả mô hình	56
3.13	Hệ số góc suy giảm MAE theo tầm nhìn — tất cả cấu hình	57
3.14	Chênh lệch MAE giữa Ensemble và mô hình thành phần tốt nhất — giá trị dương cho thấy Ensemble kém hơn	58
3.15	Thời gian huấn luyện theo mô hình và chiến lược chia dữ liệu	59
3.16	Giao diện tổng quan — thanh điều khiển bên trái, thẻ chỉ số và biểu đồ lịch sử 24 giờ	60
3.17	Biểu đồ thu nhỏ xu hướng 24 giờ của sáu chỉ số ô nhiễm	61
3.18	Khu vực dự báo $PM_{2.5}$ — năm thẻ dự báo và biểu đồ nổi lịch sử–dự báo	61

DANH SÁCH BẢNG

1.1	Siêu tham số khối cấu trúc nền tảng của XGBoost	6
1.2	Siêu tham số khối tối ưu hóa và hệ thống của XGBoost	6
1.3	Siêu tham số khối cấu trúc mạng nội tại của XLinear	8
1.4	Siêu tham số khối huấn luyện và hàm mất mát của XLinear	8
1.5	Siêu tham số khối cấu trúc mạng nội tại của iTransformer	9
1.6	Siêu tham số khối huấn luyện và hàm mất mát của iTransformer	10
1.7	Siêu tham số khối cấu trúc mạng nội tại của E-STGCN	11
1.8	Siêu tham số khối huấn luyện và hàm mất mát của E-STGCN	11
1.9	Siêu tham số khối cấu trúc đồ thị mạng nội tại của ST-XLinear	13
1.10	Siêu tham số khối huấn luyện và hàm mất mát của ST-XLinear	14
1.11	Siêu tham số cấu hình Grid Search của phương pháp Ensemble	15
2.1	Danh sách công cụ và thư viện	22
2.2	Cấu hình phần cứng sử dụng trong nghiên cứu	22
2.3	Danh sách 17 biến thời tiết thu thập	23
2.4	Hệ thống 6 tiêu chí lọc	24
2.5	12 trạm được chọn, phân theo cụm vùng	25
2.6	Ngưỡng vật lý phát hiện ngoại lai	28
2.7	8 nhóm đặc trưng trong hệ thống	30
2.8	Danh sách các đặc trưng tương tác	31
2.9	Chiến lược chuẩn hóa dữ liệu theo 8 nhóm	33
2.10	Các cấu hình chia tập dữ liệu theo block-days	34
2.11	Tổng quan 6 mô hình nghiên cứu	35
2.12	Đặc trưng đầu vào theo từng loại mô hình	35
2.13	Cấu hình siêu tham số của mô hình XGBoost	36
2.14	Cấu hình siêu tham số của mô hình XLinear	37
2.15	Cấu hình siêu tham số của mô hình ESTGCN	38
2.16	Cấu hình siêu tham số của mô hình ST-XLinear	39
2.17	Cấu hình tham số khai phá Grid Search của Ensemble	40
2.18	Cấu hình siêu tham số của mô hình iTransformer	41
2.19	Không gian thực nghiệm đánh giá mô hình	42
3.1	Kết quả đánh giá trên block 5 — North	45
3.2	Kết quả đánh giá trên block 5 — South	45

3.3	Kết quả đánh giá trên block 7 — North	45
3.4	Kết quả đánh giá trên block 7 — South	46
3.5	Kết quả đánh giá trên block 30 — North	46
3.6	Kết quả đánh giá trên block 30 — South	46
3.7	ΔMAE ($= \text{MAE}_{T+24} - \text{MAE}_{T+1}$) trên tất cả cầu hình ($\mu g/m^3$)	51
3.8	Hệ số góc suy giảm MAE (slope, $\mu g/m^3$ mỗi giờ tầm nhìn)	57
3.9	Thời gian huấn luyện tổng (giây) — 5 tầm nhìn $\times$ 2 vùng	59

LỜI MỞ ĐẦU

1. LÝ DO CHỌN ĐỀ TÀI

Ô nhiễm không khí đang là một trong những vấn đề môi trường cấp bách nhất tại Việt Nam hiện nay. Quá trình đô thị hóa và công nghiệp hóa diễn ra nhanh chóng đã đẩy nồng độ bụi mịn $PM_{2.5}$ tại các thành phố lớn lên mức đáng lo ngại. Nghiên cứu trên dữ liệu 10 thành phố Việt Nam giai đoạn 2013–2022 cho thấy mỗi phần trăm tăng tỷ lệ đô thị hóa kéo theo nồng độ $PM_{2.5}$ tăng thêm $0,54 \mu g/m^3$ [1]. Tại Hà Nội, nồng độ $PM_{2.5}$ thường xuyên vượt ngưỡng khuyến nghị $15 \mu g/m^3$ của Tổ chức Y tế Thế giới [2], trong khi phát thải giao thông được xác nhận là nguồn đóng góp chính với mức ô nhiễm biến đổi rõ rệt theo mùa [3]. Tình trạng tương tự cũng được ghi nhận tại các vùng công nghiệp trên cả nước [4]. Hệ quả trực tiếp của thực trạng này là tác động nghiêm trọng đến sức khỏe cộng đồng: phơi nhiễm $PM_{2.5}$ kéo dài có mối liên hệ chặt chẽ với sự gia tăng tỷ lệ mắc các bệnh lý hô hấp, tim mạch và tử vong sớm [5], và tại Việt Nam, mỗi $1 \mu g/m^3$ $PM_{2.5}$ tăng thêm dẫn đến khoảng 2,5 ca bệnh hô hấp bổ sung trên 1.000 dân [1]. Trước thực trạng đó, việc xây dựng một hệ thống có khả năng dự báo sớm nồng độ $PM_{2.5}$ nhằm cảnh báo kịp thời cho cộng đồng và hỗ trợ cơ quan quản lý ra quyết định là nhu cầu mang tính cấp thiết.

Từ góc độ chuyên môn, bài toán dự báo nồng độ $PM_{2.5}$ đặt ra nhiều thách thức kỹ thuật. Nồng độ $PM_{2.5}$ tại một trạm quan trắc không chỉ phụ thuộc vào nguồn phát thải cục bộ mà còn chịu sự chi phối mạnh mẽ của các yếu tố khí tượng như nhiệt độ, độ ẩm, hướng gió và tốc độ gió [2], cùng với sự lan truyền ô nhiễm từ các khu vực lân cận. Các phương pháp mô hình hóa truyền thống như CMAQ, vốn dựa trên mô phỏng quá trình vật lý–hóa học của khí quyển, đòi hỏi dữ liệu kiểm kê phát thải chi tiết và nguồn lực tính toán lớn [3], khiến việc triển khai dự báo liên tục trong điều kiện thực tế gặp nhiều hạn chế. Trong khi đó, các phương pháp Machine Learning và Deep Learning có khả năng khai thác trực tiếp dữ liệu quan trắc lịch sử để xây dựng mô hình dự báo với chi phí vận hành thấp hơn. Tuy nhiên, tại Việt Nam hiện nay vẫn còn thiếu các nghiên cứu so sánh đồng thời nhiều kiến trúc mô hình trên cùng tập dữ liệu đa trạm, đặc biệt là các mô hình có khả năng khai thác quan hệ không gian giữa các trạm quan trắc. Khoảng trống này là cơ sở để đề án lựa chọn đề tài xây dựng và so sánh nhiều phương pháp dự báo $PM_{2.5}$ đa mốc thời gian, kết hợp khai thác cả đặc trưng thời gian lẫn không gian giữa các trạm quan trắc tại Việt Nam.

2. MỤC TIÊU NGHIÊN CỨU

Đề án đặt ra mục tiêu tổng quát là xây dựng và đánh giá hệ thống dự báo nồng độ $PM_{2.5}$ đa mốc thời gian ($T + 1, T + 3, T + 6, T + 12, T + 24$ giờ) tại Việt Nam, sử dụng kết hợp các phương pháp Machine Learning và Deep Learning trên dữ liệu đa trạm quan trắc. Để đạt được mục tiêu này, đề án triển khai năm mục tiêu cụ thể như sau.

Thứ nhất, xây dựng pipeline thu thập và tiền xử lý dữ liệu chất lượng không khí và khí tượng cho 12 trạm quan trắc (6 miền Bắc, 6 miền Nam), bao gồm các bước phát hiện lỗi cảm biến, xử lý dữ liệu đóng băng, loại bỏ ngoại lai, nội suy giá trị thiếu và chuẩn hóa đặc trưng theo từng nhóm biến.

Thứ hai, thiết kế các đặc trưng kỹ thuật dựa trên kiến thức hóa học khí quyển nhằm bổ sung thông tin có ý nghĩa vật lý cho mô hình dự báo, bao gồm các chỉ số phản ánh khả năng oxy hóa, nguy cơ hình thành aerosol sulfate, và mức độ ổn định nhiệt của khí quyển.

Thứ ba, huấn luyện và so sánh hiệu suất của sáu mô hình dự báo thuộc các kiến trúc khác nhau: XGBoost (tree-based), XLinear (linear projection), E-STGCN (graph convolution), ST-XLinear (spatio-temporal), Ensemble (kết hợp) và iTransformer (attention-based), trên cùng tập dữ liệu và cùng điều kiện đánh giá.

Thứ tư, đề xuất cơ chế Dynamic Graph — ma trận kề thay đổi theo hướng gió thực tế, nhằm mô hình hóa sự lan truyền ô nhiễm giữa các trạm quan trắc cho các mô hình spatio-temporal.

Thứ năm, triển khai ứng dụng web demo dự báo $PM_{2.5}$ trực tuyến, cho phép người dùng tra cứu dự báo tại

các trạm quan trắc, phục vụ mục đích cảnh báo ô nhiễm không khí.

3. ĐỐI TƯỢNG VÀ PHẠM VI NGHIÊN CỨU

Đối tượng nghiên cứu của đề án là nồng độ bụi mịn $PM_{2.5}$ ($\mu g/m^3$) — loại hạt có đường kính khí động học $\leq 2,5 \mu m$, có khả năng thâm nhập sâu vào phế nang phổi và xâm nhập vào hệ tuần hoàn máu. Đây là chỉ số ô nhiễm không khí được quan tâm hàng đầu do mối liên hệ trực tiếp với các bệnh lý hô hấp, tim mạch và tử vong sớm [5]. Bên cạnh biến mục tiêu $PM_{2.5}$, đề án sử dụng kết hợp hai nhóm dữ liệu đầu vào: dữ liệu chất lượng không khí (PM_{10} , CO , NO_2 , SO_2 , O_3) và dữ liệu khí tượng (nhiệt độ, độ ẩm, điểm sương, lượng mưa, tốc độ gió, hướng gió, gió giật, độ che phủ mây, nhiệt độ đất, độ ẩm đất). Sự kết hợp này xuất phát từ thực tế rằng nồng độ $PM_{2.5}$ chịu sự chi phối đồng thời của cả nguồn phát thải lẫn điều kiện khí tượng [2].

Phạm vi không gian của đề án bao gồm 12 trạm quan trắc chất lượng không khí, được chọn lọc từ mạng lưới 32 trạm ban đầu và chia thành hai cụm theo vùng địa lý: cụm miền Bắc gồm 6 trạm tại Hà Nội, Thanh Hóa, Hải Phòng và Nam Định; cụm miền Nam gồm 6 trạm tại TP. Hồ Chí Minh, Cần Thơ, Đồng Nai, Vĩnh Long, Trà Vinh và An Giang. Việc phân chia theo vùng nhằm phản ánh sự khác biệt về đặc điểm khí hậu, nguồn phát thải và mức độ biến động $PM_{2.5}$ giữa hai miền [1].

Phạm vi thời gian bao gồm dữ liệu quan trắc theo giờ từ tháng 01/2023 đến tháng 12/2025, tương đương khoảng 25.000 bản ghi mỗi trạm. Khoảng thời gian ba năm đảm bảo bao phủ đầy đủ các chu kỳ biến đổi theo mùa của $PM_{2.5}$, đặc biệt sự tương phản giữa mùa đông (nồng độ cao) và mùa hè (nồng độ thấp) tại miền Bắc Việt Nam [3].

Phạm vi dự báo bao gồm năm mốc thời gian: $T + 1$, $T + 3$, $T + 6$, $T + 12$ và $T + 24$ giờ, bao phủ từ dự báo ngắn hạn (phục vụ cảnh báo khẩn cấp) đến dự báo trung hạn (phục vụ lập kế hoạch hoạt động ngoài trời).

Giới hạn nghiên cứu: đề án tập trung vào dự báo giá trị nồng độ $PM_{2.5}$ dựa trên dữ liệu quan trắc mặt đất, không bao gồm dự báo các chỉ số ô nhiễm khác (PM_{10} , AQI tổng hợp), không sử dụng dữ liệu vệ tinh hay dữ liệu giao thông, và không thực hiện dự báo dài hạn vượt quá 24 giờ.

4. PHƯƠNG PHÁP NGHIÊN CỨU

Đề án áp dụng phương pháp nghiên cứu thực nghiệm, xây dựng và đánh giá các mô hình dự báo $PM_{2.5}$ theo quy trình gồm bốn giai đoạn chính: thu thập và tiền xử lý dữ liệu, thiết kế đặc trưng, xây dựng mô hình, và đánh giá hiệu suất.

Ở giai đoạn đầu, dữ liệu được thu thập từ hai nguồn: dữ liệu chất lượng không khí ($PM_{2.5}$, PM_{10} , CO , NO_2 , SO_2 , O_3) từ Weatherbit API và dữ liệu khí tượng (nhiệt độ, độ ẩm, điểm sương, lượng mưa, tốc độ gió, hướng gió, gió giật, mây, nhiệt độ đất, độ ẩm đất) từ Open-Meteo API, với tần suất theo giờ tại 32 trạm quan trắc trong giai đoạn 01/2023 – 12/2025. Hai nguồn dữ liệu được ghép nối theo dấu thời gian, sau đó trải qua quy trình tiền xử lý gồm phát hiện dữ liệu đóng băng do lỗi cảm biến quang học (OPC), phát hiện ngoại lai bằng phương pháp khoảng tứ phân vị (IQR), loại bỏ bản ghi trùng lặp, và nội suy giá trị thiếu bằng kết hợp nội suy tuyến tính và KNN. Từ 32 trạm ban đầu, 12 trạm đạt chất lượng dữ liệu được chọn lọc cho quá trình huấn luyện mô hình.

Ở giai đoạn thiết kế đặc trưng, đề án xây dựng sáu đặc trưng kỹ thuật mới dựa trên kiến thức hóa học khí quyển, phản ánh các cơ chế hình thành $PM_{2.5}$ thứ cấp và điều kiện phát tán ô nhiễm. Song song đó, các đặc trưng trễ (lag) và thống kê trượt (rolling) của $PM_{2.5}$ được bổ sung nhằm khai thác tính tự tương quan của chuỗi thời gian, cùng với mã hóa chu kỳ (sin/cos) cho các thành phần thời gian. Toàn bộ đặc trưng sau đó được chuẩn hóa theo tám chiến lược khác nhau tùy thuộc vào đặc điểm phân phối của từng nhóm biến, trong đó các bộ chuẩn hóa chỉ được khớp (fit) trên tập huấn luyện nhằm tránh rò rỉ dữ liệu. Dữ liệu được chia theo phương pháp block-based split với ba cấu hình chu kỳ 5, 7 và 30 ngày, mỗi chu kỳ gồm các phần huấn luyện, xác thực và kiểm thử liên tiếp.

Ở giai đoạn xây dựng mô hình, đề án huấn luyện và so sánh sáu mô hình thuộc các kiến trúc khác nhau:

XGBoost (tree-based), XLinear (linear projection kết hợp gating mechanism), ESTGCN (graph convolution kết hợp LSTM), ST-XLinear (spatio-temporal với dynamic graph), Ensemble (kết hợp trọng số XLinear và ESTGCN), và iTransformer (inverted attention). Các mô hình được huấn luyện riêng theo từng vùng (Bắc/Nam) và từng mốc dự báo ($T + 1$ đến $T + 24$ giờ). Đặc biệt, đồ án đề xuất cơ chế Dynamic Graph Builder cho mô hình ST-XLinear, trong đó ma trận kề giữa các trạm thay đổi theo hướng gió thực tế, phản ánh thực tế rằng ô nhiễm lan truyền chủ yếu theo chiều gió.

Ở giai đoạn đánh giá, hiệu suất các mô hình được đo bằng bốn chỉ số: RMSE, MAE, R^2 và MAPE, trên cả ba cấu hình block split và hai cụm vùng, nhằm đánh giá toàn diện tính chính xác và tính ổn định của từng phương pháp. Cuối cùng, mô hình có hiệu suất tốt nhất được tích hợp vào ứng dụng Streamlit, cho phép dự báo $PM_{2.5}$ trực tuyến tại 12 trạm quan trắc.

5. CẤU TRÚC CỦA ĐỒ ÁN

Ngoài phần mở đầu và tài liệu tham khảo, nội dung chính của đồ án được trình bày trong bốn chương.

Chương 1: Tổng quan lý thuyết và cơ sở nghiên cứu trình bày các kiến thức nền tảng liên quan đến đề tài, bao gồm tổng quan về ô nhiễm không khí và bụi mịn $PM_{2.5}$ tại Việt Nam, lý thuyết dự báo chuỗi thời gian, cơ sở lý thuyết của các mô hình Machine Learning và Deep Learning được sử dụng trong đồ án (XGBoost, XLinear, ESTGCN, ST-XLinear, iTransformer), khái niệm về mạng tích chập đồ thị (GCN) và mô hình spatio-temporal, cùng với các chỉ số đánh giá hiệu suất dự báo.

Chương 2: Phương tiện nghiên cứu – Phương pháp nghiên cứu mô tả chi tiết nguồn dữ liệu, mạng lưới trạm quan trắc, quy trình tiền xử lý dữ liệu gồm phát hiện lỗi cảm biến, xử lý ngoại lai và nội suy giá trị thiếu. Chương này cũng trình bày phương pháp thiết kế đặc trưng dựa trên kiến thức hóa học khí quyển, chiến lược chuẩn hóa theo nhóm biến, cách chia dữ liệu theo phương pháp block-based split, kiến trúc chi tiết của sáu mô hình dự báo, và cơ chế Dynamic Graph Builder.

Chương 3: Kết quả và thảo luận trình bày kết quả thí nghiệm so sánh hiệu suất của sáu mô hình trên năm mốc dự báo ($T + 1, T + 3, T + 6, T + 12, T + 24$ giờ), phân tích sự khác biệt hiệu suất giữa cụm trạm miền Bắc và miền Nam, đánh giá tính ổn định qua ba cấu hình chia dữ liệu, và thảo luận về nguyên nhân dẫn đến ưu thế của mô hình tốt nhất so với các phương pháp còn lại.

Chương 4: Kết luận và đề xuất tổng kết các kết quả đạt được của đồ án, nêu rõ những hạn chế còn tồn tại, và đề xuất các hướng phát triển trong tương lai nhằm cải thiện độ chính xác dự báo cũng như khả năng ứng dụng thực tế của hệ thống.

CHƯƠNG 1

TỔNG QUAN LÝ THUYẾT VÀ CƠ SỞ NGHIÊN CỨU

1. TỔNG QUAN VỀ Ô NHIỄM KHÔNG KHÍ VÀ $PM_{2.5}$

1.1. Ô nhiễm không khí tại Việt Nam

Ô nhiễm không khí đang là một trong những thách thức môi trường nghiêm trọng nhất trên phạm vi toàn cầu. Theo ước tính của Tổ chức Y tế Thế giới (WHO), ô nhiễm không khí gây ra khoảng 7 triệu ca tử vong sớm mỗi năm, trong đó các thành phố lớn tại châu Á có nồng độ $PM_{2.5}$ vượt gấp 10 lần mức khuyến nghị [6]. Tại Việt Nam, ô nhiễm không khí được xếp vào nhóm **5 yếu tố hàng đầu** gây gánh nặng bệnh tật và tử vong sớm trong năm 2019, chỉ đứng sau huyết áp cao, hút thuốc, tiểu đường và rủi ro dinh dưỡng [7].

Quá trình đô thị hóa nhanh chóng tại Việt Nam là một trong những nguyên nhân chính dẫn đến sự gia tăng ô nhiễm không khí. Nghiên cứu hồi quy trên dữ liệu 63 tỉnh thành cho thấy mỗi 1% gia tăng tỷ lệ đô thị hóa tương ứng với mức tăng **0,54 $\mu g/m^3$** nồng độ $PM_{2.5}$ [1]. Mật độ dân cư cao tại các đô thị kéo theo sự gia tăng phương tiện giao thông, hoạt động xây dựng và sản xuất công nghiệp, trong khi hạ tầng quản lý và xử lý ô nhiễm chưa phát triển tương xứng. Báo cáo của RTI International (2024) chỉ ra rằng khoảng 70% nước thải công nghiệp tại Việt Nam chưa được xử lý đúng quy trình, phản ánh một bức tranh tổng thể về áp lực ô nhiễm lên môi trường [4].

Xét về nguồn phát thải, giao thông đóng vai trò chủ đạo trong việc phát sinh các chất ô nhiễm như NO_2 , CO và $PM_{2.5}$ tại Hà Nội. Nghiên cứu của Ho et al. (2025) sử dụng mô hình CMAQ kết hợp dữ liệu phát thải giao thông cho thấy nồng độ các chất ô nhiễm từ nguồn này tăng cao đáng kể vào mùa đông [3]. Bên cạnh giao thông, các hoạt động công nghiệp và làng nghề truyền thống (gốm, hương, rèn) cũng đóng góp một lượng đáng kể chất ô nhiễm vào khí quyển [7]. Đặc biệt, hoạt động đốt rơm rạ và phụ phẩm nông nghiệp làm gia tăng nồng độ NO_2 tại các vùng như Duyên hải Bắc Trung Bộ, Đông Nam Bộ và Đồng bằng sông Cửu Long [7]. Ngoài các nguồn phát thải sơ cấp, $PM_{2.5}$ còn được hình thành thông qua các phản ứng hóa học thứ cấp trong khí quyển, khi SO_2 , NO_2 và các hợp chất hữu cơ dễ bay hơi (VOCs) chuyển hóa thành aerosol sulfate và nitrate [5].

Phân bố ô nhiễm không khí tại Việt Nam có sự khác biệt rõ rệt giữa các vùng miền. Khu vực **Đồng bằng sông Hồng** ghi nhận nồng độ $PM_{2.5}$ và NO_2 cao nhất cả nước, với nồng độ $PM_{2.5}$ trung bình năm dao động từ 12,8 đến 40,8 $\mu g/m^3$ trong năm 2019 [7]. Riêng Hà Nội, ước tính có khoảng 315 ca tử vong có thể tránh được mỗi năm nếu giảm nồng độ NO_2 xuống mức thời kỳ COVID-19, trong bối cảnh mật độ dân số khu vực này đạt khoảng 1.000 người/ km^2 [7]. Ngược lại, khu vực **miền Nam** ghi nhận mức ô nhiễm thấp hơn đáng kể, với số ca tử vong tránh được từ giảm NO_2 chỉ dao động từ 3 đến 37 ca tùy tỉnh [7]. Sự chênh lệch này được giải thích bởi đặc điểm khí hậu: mùa đông miền Bắc thường xuất hiện hiện tượng nghịch nhiệt, tầng trộn thấp và gió yếu, khiến các chất ô nhiễm bị giữ lại gần mặt đất và tích tụ [2, 3].

Biến động theo mùa là một đặc trưng quan trọng của ô nhiễm không khí tại Việt Nam. Vào giai đoạn **thu–đông**, nồng độ $PM_{2.5}$ tăng cao do hiện tượng nghịch nhiệt làm giảm chiều cao tầng trộn, kết hợp với việc tăng sử dụng nhiên liệu hóa thạch cho sưởi ấm [2, 3]. Mô phỏng từ mô hình CMAQ kết hợp WRF cho thấy nồng độ $PM_{2.5}$ tại Hà Nội ở độ cao 30 mét đạt 50–84 $\mu g/m^3$, vượt đáng kể Quy chuẩn kỹ thuật quốc gia QCVN 05:2013 (50 $\mu g/m^3$) và khuyến nghị của WHO (25 $\mu g/m^3$) [8]. Nồng độ này giảm dần theo độ cao, chỉ còn 34–40 $\mu g/m^3$ ở độ cao 320 mét, cho thấy ô nhiễm tập trung mạnh ở tầng thấp nơi con người sinh sống [2]. Vào **mùa hè**, nhờ lượng mưa lớn, tầng trộn cao và điều kiện khuếch tán thuận lợi, nồng độ ô nhiễm giảm đáng kể [2].

Giai đoạn giãn cách xã hội do đại dịch COVID-19 đã cung cấp một “thí nghiệm tự nhiên” quý giá, minh chứng rõ ràng cho mối quan hệ nhân quả giữa hoạt động con người và chất lượng không khí. Trong thời gian phong tỏa tháng 4 năm 2020 tại Hà Nội, nồng độ $PM_{2.5}$ **giảm 75,8%** và NO_2 **giảm 41,8%** so với cùng kỳ [7]. Trên phạm vi toàn quốc 63 tỉnh thành, mức giảm $PM_{2.5}$ trung bình năm dao động từ 5,7% đến 10,3% [7]. Nếu duy trì được mức chất lượng không khí tương đương giai đoạn phong tỏa, ước tính có thể tránh được **3.807 ca tử vong** do

$PM_{2.5}$ (tiết kiệm khoảng 793 triệu USD) và **2.451 ca tử vong** do NO_2 (tiết kiệm khoảng 510,6 triệu USD) [7]. Những con số này nhấn mạnh tầm quan trọng của việc phát triển các hệ thống dự báo chất lượng không khí chính xác, nhằm hỗ trợ cảnh báo sớm và cung cấp cơ sở khoa học cho các chính sách kiểm soát ô nhiễm tại Việt Nam.

1.2. Bụi mịn $PM_{2.5}$

Bụi mịn $PM_{2.5}$ (Particulate Matter 2.5) là thuật ngữ chỉ các hạt vật chất lơ lửng trong không khí có đường kính khí động học **nhỏ hơn hoặc bằng $2,5 \mu m$** . Do kích thước cực nhỏ, $PM_{2.5}$ có khả năng xâm nhập sâu vào phế nang phổi, thậm chí đi vào máu và các cơ quan nội tạng, gây ra nhiều bệnh lý nghiêm trọng về hô hấp, tim mạch và ung thư [5]. Tổ chức Y tế Thế giới (WHO) khuyến nghị nồng độ $PM_{2.5}$ trung bình năm không nên vượt quá $5 \mu g/m^3$ (hướng dẫn năm 2021) [9], tuy nhiên hầu hết các đô thị lớn tại châu Á, bao gồm Việt Nam, đều vượt xa ngưỡng này [6].

Về nguồn gốc hình thành, $PM_{2.5}$ được phân thành hai loại chính. $PM_{2.5}$ **sơ cấp** là các hạt bụi được phát thải trực tiếp vào khí quyển từ quá trình đốt cháy nhiên liệu hóa thạch (xăng, dầu diesel, than đá), khí thải công nghiệp, đốt sinh khối (rơm rạ, gỗ), bụi đường và hoạt động xây dựng [3, 1]. $PM_{2.5}$ **thứ cấp** được hình thành thông qua các phản ứng hóa học trong khí quyển, khi các chất tiền thân dạng khí như SO_2 , NO_x (NO và NO_2), amoniac (NH_3) và các hợp chất hữu cơ dễ bay hơi (VOCs) trải qua quá trình oxy hóa, ngưng tụ và chuyển đổi pha, tạo thành các hạt aerosol sulfate (SO_4^{2-}), nitrate (NO_3^-) và carbon hữu cơ thứ cấp (SOA) [5]. Tỷ lệ đóng góp giữa $PM_{2.5}$ sơ cấp và thứ cấp phụ thuộc vào đặc điểm nguồn phát thải và điều kiện khí tượng của từng khu vực, trong đó tại các đô thị lớn như Hà Nội, $PM_{2.5}$ thứ cấp có thể chiếm tỷ trọng đáng kể do mật độ phát thải NO_x và SO_2 từ giao thông và công nghiệp cao [3].

Nồng độ $PM_{2.5}$ trong khí quyển chịu ảnh hưởng mạnh mẽ bởi các yếu tố khí tượng. **Nhiệt độ** ảnh hưởng đến cấu trúc nhiệt của khí quyển; khi nhiệt độ bề mặt giảm nhanh hơn các tầng trên, hiện tượng nghịch nhiệt hình thành, tạo ra một “lớp nắp” ngăn cản sự khuếch tán thẳng đứng của chất ô nhiễm [2]. Nghiên cứu tại Hà Nội cho thấy vào mùa đông, hiện tượng nghịch nhiệt làm giảm đáng kể chiều cao tầng trộn, khiến nồng độ $PM_{2.5}$ ở tầng thấp (30 mét) đạt $50\text{--}84 \mu g/m^3$, trong khi ở độ cao 320 mét chỉ còn $34\text{--}40 \mu g/m^3$ [2, 8]. **Độ ẩm tương đối** đóng vai trò kép: độ ẩm cao thúc đẩy phản ứng hóa học tạo $PM_{2.5}$ thứ cấp (đặc biệt quá trình oxy hóa SO_2 thành sulfate trong pha nước), nhưng khi đạt đến mức bão hòa, mưa lại đóng vai trò rửa trôi bụi mịn khỏi khí quyển [2]. **Tốc độ và hướng gió** quyết định khả năng vận chuyển và phân tán các chất ô nhiễm; gió yếu khiến $PM_{2.5}$ tích tụ tại nguồn, trong khi gió mạnh giúp pha loãng nhưng cũng có thể vận chuyển ô nhiễm xuyên biên giới từ các khu vực công nghiệp lân cận [3].

Biến động theo mùa của $PM_{2.5}$ tại Việt Nam thể hiện đặc trưng rõ rệt. Vào **mùa đông** (tháng 11 đến tháng 3), nồng độ $PM_{2.5}$ đạt mức cao nhất trong năm do sự kết hợp của ba yếu tố: (i) hiện tượng nghịch nhiệt thường xuyên, (ii) gió mùa Đông Bắc vận chuyển ô nhiễm từ các khu công nghiệp phía Bắc, và (iii) gia tăng phát thải từ hoạt động sưởi ấm bằng nhiên liệu hóa thạch [2, 3]. Ngược lại, vào **mùa hè** (tháng 5 đến tháng 9), lượng mưa lớn kết hợp với tầng trộn cao và bức xạ mặt trời mạnh tạo điều kiện khuếch tán thuận lợi, giúp nồng độ $PM_{2.5}$ giảm đáng kể [2]. Phân tích của Ho et al. (2025) trên dữ liệu mô phỏng CMAQ tại Hà Nội cho thấy nồng độ các chất ô nhiễm từ nguồn giao thông cũng tuân theo biến động mùa tương tự, với đỉnh vào mùa đông và đáy vào mùa hè [3]. Đặc điểm biến động mùa vụ này đặt ra yêu cầu quan trọng đối với các mô hình dự báo: hệ thống phải có khả năng nắm bắt tính mùa vụ và thích ứng với các điều kiện khí tượng thay đổi để đảm bảo độ chính xác dự báo trong mọi thời điểm của năm.

1.3. Tác động của $PM_{2.5}$ đến sức khỏe con người

Bụi mịn $PM_{2.5}$ được xem là chất ô nhiễm không khí nguy hiểm nhất đối với sức khỏe con người, do kích thước cực nhỏ cho phép các hạt bụi vượt qua hàng rào bảo vệ tự nhiên của hệ hô hấp. Trong khi các hạt bụi thô (PM_{10}) bị giữ lại ở mũi và đường thở trên, $PM_{2.5}$ có khả năng xâm nhập sâu vào tận phế nang phổi, từ đó khuếch tán qua màng phế nang – mao mạch vào hệ tuần hoàn máu và phân bố đến các cơ quan nội tạng như tim, gan, thận

và não [5].

Về tác động lên **hệ hô hấp**, tiếp xúc lâu dài với $PM_{2.5}$ làm tăng nguy cơ mắc các bệnh viêm phế quản mãn tính, hen suyễn, bệnh phổi tắc nghẽn mãn tính (COPD) và ung thư phổi. Các hạt bụi mịn khi lắng đọng trong phế nang kích hoạt phản ứng viêm, tạo ra các gốc tự do (ROS – Reactive Oxygen Species) gây tổn thương mô phổi và suy giảm chức năng hô hấp [5]. Đối với **hệ tim mạch**, nghiên cứu tổng quan của Le et al. (2024) chỉ ra rằng $PM_{2.5}$ và NO_2 có mối liên hệ trực tiếp với các bệnh lý tim mạch bao gồm nhồi máu cơ tim, đột quỵ và xơ vữa động mạch. Cơ chế bệnh sinh bao gồm phản ứng viêm hệ thống, stress oxy hóa và rối loạn chức năng nội mô mạch máu [5]. Ngoài ra, các nghiên cứu gần đây còn ghi nhận mối liên hệ giữa phơi nhiễm $PM_{2.5}$ với các bệnh lý thần kinh, tiểu đường type 2 và suy giảm chức năng nhận thức [6].

Trên phạm vi toàn cầu, ô nhiễm không khí gây ra khoảng **7 triệu ca tử vong sớm** mỗi năm, trong đó $PM_{2.5}$ chiếm phần lớn gánh nặng bệnh tật [6]. Tại Việt Nam, ô nhiễm không khí được xếp trong nhóm 5 yếu tố nguy cơ hàng đầu gây gánh nặng bệnh tật năm 2019, ngang hàng với các yếu tố truyền thống như huyết áp cao và hút thuốc [7]. Nghiên cứu định lượng của Hoang et al. (2023) trên dữ liệu 63 tỉnh thành đã ước tính cụ thể thiệt hại sức khỏe từ ô nhiễm không khí: nếu nồng độ $PM_{2.5}$ được duy trì ở mức thời kỳ giãn cách COVID-19, Việt Nam có thể tránh được **3.807 ca tử vong** mỗi năm, tương đương giá trị kinh tế khoảng **793 triệu USD**. Tương tự, việc giảm NO_2 có thể tránh được **2.451 ca tử vong**, tiết kiệm khoảng **510,6 triệu USD** [7].

Phân bố thiệt hại sức khỏe có sự chênh lệch rõ rệt giữa các vùng miền, phản ánh sự khác biệt về mức độ ô nhiễm. Khu vực Đồng bằng sông Hồng, đặc biệt là Hà Nội với mật độ dân số khoảng 1.000 người/ km^2 , chịu tác động nặng nề nhất với ước tính **315 ca tử vong** có thể tránh được mỗi năm chỉ riêng từ việc giảm NO_2 [7]. Trong khi đó, các tỉnh miền Nam với nồng độ ô nhiễm thấp hơn ghi nhận con số chỉ từ 3 đến 37 ca tùy địa phương [7]. Sự phân bố không đồng đều này cho thấy các hệ thống dự báo chất lượng không khí cần có khả năng **phân giải theo không gian** (spatial resolution), đặc biệt tại các khu vực đô thị mật độ cao, nhằm phục vụ hiệu quả cho công tác cảnh báo sức khỏe cộng đồng.

Những bằng chứng trên khẳng định rằng ô nhiễm $PM_{2.5}$ không chỉ là vấn đề môi trường mà còn là **vấn đề y tế công cộng và kinh tế xã hội** có quy mô lớn. Điều này đặt ra nhu cầu cấp thiết về việc xây dựng các hệ thống dự báo nồng độ $PM_{2.5}$ chính xác, có khả năng cung cấp cảnh báo sớm trước 1 đến 24 giờ, giúp cơ quan quản lý ban hành khuyến cáo sức khỏe kịp thời và người dân chủ động bảo vệ bản thân, đặc biệt trong các đợt ô nhiễm nghiêm trọng vào mùa đông.

2. CƠ SỞ LÝ THUYẾT KỸ THUẬT

2.1. Bài toán dự báo chuỗi thời gian

Dự báo chuỗi thời gian là bài toán ước lượng giá trị tương lai của một biến số dựa trên chuỗi các quan sát được ghi nhận theo trình tự thời gian. Cho trước chuỗi thời gian $\mathbf{x} = \{x_1, x_2, \dots, x_T\}$ với T bước thời gian đã quan sát, mục tiêu của bài toán là xây dựng hàm ánh xạ f sao cho:

$$\hat{x}_{T+h} = f(x_{T-L+1}, x_{T-L+2}, \dots, x_T; \theta) \quad (1.1)$$

trong đó L là độ dài cửa sổ quan sát, h là tầm nhìn dự báo và θ là tập tham số của mô hình. Trong bài toán đa biến (multivariate), đầu vào mở rộng thành ma trận $\mathbf{X} \in \mathbb{R}^{L \times d}$ với d đặc trưng (features), bao gồm cả biến mục tiêu và các biến ngoại sinh như nhiệt độ, độ ẩm, tốc độ gió [10, 11].

2.1.1. Dự báo đơn bước và đa tầm nhìn

Dựa trên số bước thời gian cần dự báo, bài toán được phân thành hai dạng chính. **Dự báo đơn bước** chỉ ước lượng giá trị tại một thời điểm duy nhất $T + 1$, phù hợp cho các ứng dụng cần phản ứng nhanh như cảnh báo ô nhiễm tức thì. Nghiên cứu của Silveira et al. (2025) cho thấy LSTM và GRU đạt hiệu suất cao trên bài toán 1-step,

tuy nhiên sai số tăng nhanh khi mở rộng sang 20-step [12]. **Dự báo đa tầm nhìn** ước lượng đồng thời nhiều bước tương lai $\{\hat{x}_{T+1}, \hat{x}_{T+3}, \dots, \hat{x}_{T+H}\}$, phục vụ lập kế hoạch trung và dài hạn [13]. Bài toán multi-horizon đặt ra thách thức lớn hơn do sai số tích lũy và sự suy giảm tương quan giữa đầu vào và đầu ra khi tầm nhìn tăng. Trong đề án này, hệ thống được thiết kế để benchmark trên **5 tầm nhìn**: $T + 1$, $T + 3$, $T + 6$, $T + 12$ và $T + 24$ giờ, tương ứng với các kịch bản từ cảnh báo tức thì đến dự báo trong ngày.

2.1.2. Đặc điểm chuỗi thời gian $PM_{2.5}$

Chuỗi thời gian nồng độ $PM_{2.5}$ sở hữu nhiều đặc trưng phức tạp, đặt ra yêu cầu cao đối với các mô hình dự báo.

Xu hướng dài hạn. Nồng độ $PM_{2.5}$ thể hiện xu hướng biến đổi theo thời gian, phản ánh các thay đổi cấu trúc trong phát thải và chính sách môi trường. Nghiên cứu trên dữ liệu 63 tỉnh thành Việt Nam cho thấy nồng độ $PM_{2.5}$ giảm 5,7–10,3% trong giai đoạn 2020–2021 so với 2019 do tác động của giãn cách xã hội [7]. Tuy nhiên, quá trình đô thị hóa liên tục (mỗi 1% tăng đô thị hóa $\rightarrow +0,54 \mu g/m^3$) tạo ra xu hướng tăng dài hạn đối lập [1]. Sự đan xen giữa các xu hướng ngược chiều này đòi hỏi mô hình phải có khả năng phân tách và nắm bắt thành phần trend một cách linh hoạt.

Tính mùa vụ. Chuỗi $PM_{2.5}$ tại Việt Nam thể hiện tính mùa vụ rõ rệt ở nhiều chu kỳ lồng nhau. Ở *chu kỳ năm*, nồng độ đạt đỉnh vào mùa đông (tháng 11–3) do nghịch nhiệt và gió mùa Đông Bắc, và đạt đáy vào mùa hè (tháng 5–9) nhờ mưa rửa trôi [2, 3]. Ở *chu kỳ ngày*, nồng độ thường tăng cao vào giờ cao điểm giao thông (6–9h sáng và 17–20h tối) do phát thải từ phương tiện cơ giới [3]. Ở *chu kỳ tuần*, nồng độ cuối tuần thường thấp hơn ngày thường do giảm hoạt động sản xuất và giao thông. Các mô hình dự báo cần nhận diện và mã hóa được các chu kỳ mùa vụ đa tầng này.

Tính không dừng. Chuỗi $PM_{2.5}$ thường không thỏa mãn điều kiện dừng, nghĩa là trung bình, phương sai và cấu trúc tự tương quan thay đổi theo thời gian. Nguồn gốc của tính không dừng bao gồm: biến đổi xu hướng do chính sách môi trường, đột biến do các sự kiện cực đoan (cháy rừng, đốt rơm rạ), và sự thay đổi điều kiện khí tượng theo mùa [2]. Mô phỏng CMAQ tại Hà Nội cho thấy nồng độ $PM_{2.5}$ dao động trong khoảng rất rộng từ 34 đến 84 $\mu g/m^3$ chỉ trong cùng một mùa đông, phản ánh sự biến động cao [8]. Tính không dừng đặt ra thách thức lớn cho các phương pháp thống kê truyền thống (ARIMA, SARIMA) vốn yêu cầu chuỗi dừng, và là một trong những động lực thúc đẩy việc áp dụng các mô hình học sâu có khả năng học biểu diễn phi tuyến [12].

Phụ thuộc không gian. Khác với nhiều bài toán chuỗi thời gian cổ điển, nồng độ $PM_{2.5}$ tại một trạm quan trắc không chỉ phụ thuộc vào lịch sử của chính nó mà còn chịu ảnh hưởng mạnh bởi các trạm lân cận thông qua quá trình vận chuyển khí quyển. Nghiên cứu của Dam et al. (2024) chỉ ra rằng nồng độ $PM_{2.5}$ có gradient rõ rệt theo chiều thẳng đứng (50–84 $\mu g/m^3$ ở 30m so với 34–40 $\mu g/m^3$ ở 320m), cho thấy ô nhiễm phân bố không đồng nhất trong không gian [2]. Trên mặt phẳng ngang, hướng gió và vận tốc gió quyết định mô hình lan truyền ô nhiễm giữa các khu vực. Panja et al. (2025) đề xuất mô hình E-STGCN sử dụng ma trận kề (adjacency matrix) dựa trên hàm Gaussian kernel của khoảng cách Haversine để biểu diễn mối tương quan không gian giữa các trạm [14]. Tuy nhiên, cách tiếp cận khoảng cách tĩnh này chưa phản ánh đầy đủ tính động của quá trình vận chuyển ô nhiễm, vốn thay đổi liên tục theo điều kiện gió — đây chính là khoảng trống mà đề án này hướng đến bằng việc đề xuất **Dynamic Graph Builder** tích hợp thông tin hướng gió và vận tốc gió vào quá trình xây dựng đồ thị không gian.

Tóm lại, sự kết hợp đồng thời của xu hướng dài hạn, tính mùa vụ đa tầng, tính không dừng và phụ thuộc không gian khiến bài toán dự báo $PM_{2.5}$ trở thành một trong những bài toán phức tạp nhất trong lĩnh vực dự báo chuỗi thời gian. Điều này đòi hỏi sự kết hợp linh hoạt giữa nhiều lớp mô hình — từ Machine Learning truyền thống đến Deep Learning và Spatio-temporal Graph Networks — nhằm khai thác hiệu quả cả thông tin thời gian lẫn không gian.

2.2. Nhóm mô hình Machine Learning

2.2.1. Gradient Boosting và XGBoost

Gradient Boosting là phương pháp học ensemble dựa trên nguyên lý **boosting**: thay vì huấn luyện một mô hình mạnh duy nhất, phương pháp này kết hợp tuần tự nhiều mô hình yếu, trong đó mỗi mô hình mới được huấn luyện để sửa chữa sai số còn lại của tập mô hình hiện tại. Cụ thể, tại bước lặp thứ t , mô hình f_t được thêm vào để tối thiểu hóa gradient âm của hàm mất mát trên phần dư, tạo ra dự đoán tích lũy:

$$\hat{y}_i^{(t)} = \hat{y}_i^{(t-1)} + \eta \cdot f_t(\mathbf{x}_i) \quad (1.2)$$

trong đó η là hệ số Shrinkage kiểm soát đóng góp của mỗi cây, giúp chống overfitting [15].

XGBoost (eXtreme Gradient Boosting) là một triển khai tối ưu của Gradient Boosting do Chen và Guestrin (2016) đề xuất, sử dụng cây quyết định (CART) làm weak learner. Hàm mục tiêu của XGBoost bao gồm hai thành phần:

$$\mathcal{L}(\theta) = \sum_{i=1}^n l(y_i, \hat{y}_i) + \sum_{t=1}^T \Omega(f_t) \quad (1.3)$$

trong đó $l(y_i, \hat{y}_i)$ là hàm mất mát (thường là squared error cho bài toán hồi quy) đo sai lệch giữa giá trị thực và dự đoán, và $\Omega(f_t) = \gamma \cdot |T_{\text{leaves}}| + \frac{1}{2} \lambda \sum_{j=1}^{|T_{\text{leaves}}|} w_j^2$ là hạng tử chính quy hóa phạt độ phức tạp của cây thông qua số lá $|T_{\text{leaves}}|$ và giá trị trọng số w_j tại mỗi lá [15]. Hai siêu tham số γ (minimum loss reduction) và λ (L2 regularization) cho phép kiểm soát sự cân bằng giữa khả năng khớp dữ liệu và tính tổng quát.

Quá trình tìm Split Finding trong XGBoost sử dụng xấp xỉ Taylor bậc hai của hàm mục tiêu. Tại mỗi nút, thuật toán tính gradient bậc nhất $g_i = \partial l / \partial \hat{y}_i$ và gradient bậc hai $h_i = \partial^2 l / \partial \hat{y}_i^2$, sau đó chọn phân tách tối đa hóa mức giảm mất mát (Gain):

$$\text{Gain} = \frac{1}{2} \left[\frac{G_L^2}{H_L + \lambda} + \frac{G_R^2}{H_R + \lambda} - \frac{(G_L + G_R)^2}{H_L + H_R + \lambda} \right] - \gamma \quad (1.4)$$

trong đó G_L, H_L và G_R, H_R lần lượt là tổng gradient bậc nhất và bậc hai của tập mẫu thuộc nhánh trái và phải [15]. Ngoài ra, XGBoost triển khai kỹ thuật **Column Subsampling** tương tự Random Forest, giúp giảm overfitting và tăng tốc huấn luyện.

XGBoost sở hữu nhiều ưu điểm phù hợp cho bài toán dự báo chất lượng không khí. *Thứ nhất*, mô hình xử lý hiệu quả các đặc trưng không đồng nhất — bao gồm biến liên tục (nhiệt độ, tốc độ gió), biến rời rạc (giờ, ngày trong tuần) và biến có phân phối khác nhau — mà không yêu cầu chuẩn hóa đầu vào [15]. *Thứ hai*, cơ chế early stopping cho phép dừng huấn luyện khi hiệu suất trên tập validation không cải thiện, tránh overfitting trên dữ liệu nhiễu vốn phổ biến trong dữ liệu quan trắc môi trường. *Thứ ba*, XGBoost cung cấp chỉ số feature importance dựa trên tần suất sử dụng và mức gain trung bình, hỗ trợ khả năng diễn giải mô hình — một yếu tố quan trọng trong nghiên cứu môi trường [16]. Nghiên cứu của Tırınk (2025) trên dữ liệu AQI 8 năm tại Thổ Nhĩ Kỳ cho thấy XGBoost đạt $R^2 = 0,999$ và $RMSE = 0,234$, vượt trội so với LightGBM và SVM [16]. Al-Nuaimi et al. (2025) còn chứng minh XGBoost có thể nén thành mô hình “tiny” chỉ 13 kB với mức giảm R^2 khoảng 0,07, mở ra khả năng triển khai trên thiết bị IoT biên [17].

Mô hình XGBoost trong hệ thống được điều khiển bởi tập siêu tham số chuyên biệt. Để đảm bảo tính chặt chẽ trong quá trình biểu diễn, các siêu tham số được quy hoạch thành hai khối cấu trúc chính:

Bảng 1.1. Siêu tham số khối cấu trúc nền tảng của XGBoost

Siêu tham số	Ý nghĩa
<i>n_estimators</i>	Số lượng vòng lặp tăng cường tối đa, quyết định giới hạn số cây hồi quy thành phần được khởi tạo.
<i>max_depth</i>	Độ sâu tối đa phân vùng của một cây quyết định, giới hạn cấp bậc tương tác phi tuyến của các đặc trưng.
<i>min_child_weight</i>	Tổng giá trị đạo hàm bậc hai (Hessian) tối thiểu yêu cầu tại một nút lá, nhằm tạo điều kiện dừng phân tách sớm trên các phân nhóm nhiễu.

Bảng 1.2. Siêu tham số khối tối ưu hóa và hệ thống của XGBoost

Siêu tham số	Ý nghĩa
<i>learning_rate</i>	Hệ số thu hẹp (learning rate) kiểm soát mức đóng góp của mỗi cây mới vào mô hình tổng hợp.
<i>subsample</i>	Tỷ lệ lấy mẫu ngẫu nhiên theo hàng cho mỗi vòng xây dựng cây, giúp kiểm soát phương sai.
<i>colsample_bytree</i>	Tỷ lệ lấy mẫu ngẫu nhiên theo cột (đặc trưng) cho mỗi cây, giảm sự chi phối của một số biến đầu vào.
<i>early_stopping_rounds</i>	Số vòng boosting liên tiếp không cải thiện sai số trên tập kiểm định trước khi kích hoạt ngắt sớm.
<i>eval_metric</i>	Chỉ số đánh giá (mặc định: RMSE) dùng để theo dõi hiệu suất mô hình trên tập kiểm định.
<i>reg_alpha</i>	Hệ số chính quy hóa L1 trên trọng số lá cây, thúc đẩy tính thưa bằng cách đưa các trọng số nhỏ về không.
<i>reg_lambda</i>	Hệ số chính quy hóa L2 trên trọng số lá cây, hạn chế giá trị trọng số quá lớn để tránh quá khớp.
<i>tree_method</i>	Thuật toán xây dựng cây (ví dụ: hist, gpu_hist), quyết định cách tìm điểm phân tách tối ưu.
<i>device</i>	Thiết bị phần cứng thực thi tính toán (CPU hoặc GPU).
<i>n_jobs</i>	Số luồng CPU song song được sử dụng trong quá trình huấn luyện.
<i>random_state</i>	Giá trị khởi tạo bộ sinh số ngẫu nhiên, đảm bảo tính tái lập của thí nghiệm.

Không gian Siêu tham số (Hyperparameter Space): Ngoài các siêu tham số trên, pipeline XGBoost còn bao gồm các tham số thiết kế đặc trưng ảnh hưởng gián tiếp đến hiệu suất mô hình: cấu hình lag ($\{1, 2, 3, 6, 12, 24, 36, 48, 60, 72\}$ bước), cửa sổ rolling ($\{3, 6, 12, 24, 48\}$ bước), số lượng trạm lân cận k trong thuật toán KNN không gian, và danh sách biến khí tượng tương lai được tích hợp theo từng tầm nhìn dự báo. Toàn bộ giá trị cụ thể được sử dụng trong thực nghiệm sẽ được trình bày chi tiết tại Chương 2.

2.3. Nhóm mô hình Deep Learning — Temporal

Trong lĩnh vực dự báo chuỗi thời gian, các mô hình Deep Learning temporal đã phát triển qua nhiều thế hệ kiến trúc. Thế hệ đầu tiên dựa trên Recurrent Neural Networks (RNN), đại diện là LSTM với cơ chế ba cổng (quên, đầu vào, đầu ra) và GRU với cấu trúc hai cổng đơn giản hơn, cho phép học các phụ thuộc dài hạn trong chuỗi [12].

Các biến thể như BiLSTM-GRU [18] và CNN-LSTM [19] tiếp tục cải thiện hiệu suất bằng cách kết hợp đa chiều hoặc tích hợp trích xuất đặc trưng cục bộ. Tuy nhiên, nhóm mô hình RNN có hai hạn chế cố hữu: (i) xử lý tuần tự khiến tốc độ huấn luyện chậm và khó song song hóa, và (ii) hiệu suất suy giảm trên chuỗi rất dài do thông tin bị “nén” qua bottleneck hidden state. Những hạn chế này thúc đẩy sự phát triển của các kiến trúc phi hồi quy — bao gồm MLP-based và Transformer-based — vốn xử lý toàn bộ cửa sổ đầu vào đồng thời và đạt hiệu suất cạnh tranh hoặc vượt trội trên nhiều benchmark.

2.3.1. *XLinear*

XLinear là mô hình dự báo chuỗi thời gian dài hạn dựa trên MLP (Multi-Layer Perceptron) do Chen et al. (2026) đề xuất, được thiết kế đặc biệt cho bài toán có biến ngoại sinh [10]. Kiến trúc XLinear tổ chức luồng dữ liệu thành hai đường dẫn song song:

- *Đường dẫn nội sinh*: xử lý biến mục tiêu ($PM_{2.5}$), sử dụng phép chiếu tuyến tính ánh xạ trực tiếp cửa sổ đầu vào L sang cửa sổ dự báo H .
- *Đường dẫn ngoại sinh*: xử lý các biến khí tượng (nhiệt độ, độ ẩm, gió, áp suất), sử dụng **Gating Block** để chọn lọc thông tin hữu ích.

Gating Block là thành phần cốt lõi của XLinear, hoạt động theo cơ chế:

$$\text{Gating}(\mathbf{x}) = \sigma(W_g \cdot \mathbf{x} + b_g) \odot (W_v \cdot \mathbf{x} + b_v) \quad (1.5)$$

trong đó σ là hàm sigmoid đóng vai trò “cổng” lọc, và phần tuyến tính cung cấp giá trị đặc trưng. Cơ chế này cho phép mô hình tự động đánh giá mức độ đóng góp của từng biến ngoại sinh đối với dự báo, loại bỏ nhiễu từ các biến không liên quan [10]. XLinear sử dụng hàm mất mát AsymmetricHuberLoss, phạt nặng hơn đối với sai số dự đoán thấp (under-prediction) so với dự đoán cao — phù hợp trong bài toán dự báo ô nhiễm, nơi việc bỏ sót đợt ô nhiễm nghiêm trọng nguy hiểm hơn cảnh báo sai. Ưu điểm nổi bật của XLinear là mô hình nhẹ (lightweight), tốc độ huấn luyện nhanh, và đạt hiệu suất cạnh tranh hoặc vượt trội so với các mô hình Transformer phức tạp hơn trên nhiều benchmark chuỗi thời gian [10].

Không gian Siêu tham số (Hyperparameter Space): Mô hình XLinear cấu thành từ tập hợp các thông số định lượng được phân bổ theo hai khối chính:

Bảng 1.3. Siêu tham số khối cấu trúc mạng nội tại của XLinear

Siêu tham số	Ý nghĩa
<i>seq_len</i>	Số bước thời gian lịch sử được nạp vào mô hình làm cửa sổ quan sát đầu vào.
<i>pred_len</i>	Số bước thời gian tương lai mà mô hình cần dự báo (tầm nhìn dự báo).
<i>enc_in</i>	Số lượng biến đầu vào (kênh) của chuỗi thời gian đa biến.
<i>features</i>	Chế độ dự báo: đa biến đầu vào – đơn biến đầu ra (MS) hoặc đa biến – đa biến (MM).
<i>d_model</i>	Số chiều của Embedding Dimension.
<i>t_ff</i>	Số nơ-ron trong lớp Feed-Forward của mô-đun thời gian (Temporal Block).
<i>c_ff</i>	Số nơ-ron trong lớp Feed-Forward của mô-đun biến ngoại sinh (Cross-variate Block).
<i>embed_dropout</i>	Tỷ lệ Dropout áp dụng ngay sau lớp Embedding đầu vào.
<i>head_dropout</i>	Tỷ lệ Dropout áp dụng trước lớp chiếu đầu ra cuối cùng (Prediction Head).
<i>t_dropout</i>	Tỷ lệ Dropout bên trong mô-đun thời gian.
<i>c_dropout</i>	Tỷ lệ Dropout bên trong mô-đun biến ngoại sinh.
<i>usenorm</i>	Tham số bật/tắt chuẩn hóa RevIN (Reversible Instance Normalization) để xử lý tính không dừng của chuỗi.

Bảng 1.4. Siêu tham số khối huấn luyện và hàm mất mát của XLinear

Siêu tham số	Ý nghĩa
<i>learning_rate</i>	Tốc độ học của thuật toán tối ưu AdamW, kiểm soát bước cập nhật trọng số mỗi vòng lặp.
<i>weight_decay</i>	Hệ số phân rã trọng số L2, giúp hạn chế hiện tượng quá khớp bằng cách phạt các trọng số có giá trị lớn.
<i>T_max</i>	Số epoch trong nửa chu kỳ của bộ lập lịch CosineAnnealingLR, xác định nhịp giảm tốc độ học.
<i>eta_min</i>	Giá trị tốc độ học tối thiểu mà bộ lập lịch Cosine không giảm xuống dưới.
<i>delta</i>	Ngưỡng chuyển đổi của hàm HuberLoss: dùng MSE khi sai số nhỏ hơn δ , dùng MAE khi lớn hơn.
<i>alpha</i>	Hệ số bất đối xứng trong AsymmetricHuberLoss, phạt nặng hơn khi mô hình dự báo thấp hơn thực tế.
<i>epochs</i>	Số vòng lặp tối đa duyệt qua toàn bộ tập huấn luyện.
<i>batch_size</i>	Số mẫu dữ liệu được nạp vào mô hình trong mỗi bước cập nhật tham số.
<i>patience</i>	Số epoch liên tiếp không cải thiện trên tập kiểm định trước khi kích hoạt Early Stopping.
<i>corr_threshold</i>	Ngưỡng hệ số tương quan Pearson tối thiểu để một đặc trưng được giữ lại làm đầu vào.

2.3.2. *iTransformer*

iTransformer (Inverted Transformer) là kiến trúc Transformer được Liu et al. (2024) thiết kế lại cho bài toán dự báo chuỗi thời gian đa biến [11]. Khác với Transformer truyền thống — vốn áp dụng cơ chế attention trên chiều thời gian (mỗi bước thời gian là một token) — *iTransformer* thực hiện **Inversion**: mỗi *Feature/Channel* được coi là một token độc lập. Cụ thể, cho ma trận đầu vào $\mathbf{X} \in \mathbb{R}^{L \times d}$ với L bước thời gian và d đặc trưng, *iTransformer* thực hiện:

1. *Embedding*: mỗi chuỗi đơn biến $\mathbf{x}^{(j)} \in \mathbb{R}^L$ (với $j = 1, \dots, d$) được ánh xạ thành vector embedding thông qua phép chiếu tuyến tính, tạo thành d token.
2. *Attention*: cơ chế self-attention hoạt động trên d token, học Cross-variate Dependency — ví dụ: mối quan hệ giữa $PM_{2.5}$, nhiệt độ và tốc độ gió.
3. *Feed-Forward*: mạng MLP xử lý từng token để mã hóa thông tin thời gian trong mỗi biến.
4. *Projection*: ánh xạ embedding trở lại không gian dự báo $\mathbb{R}^H$ cho mỗi biến.

Thiết kế đảo ngược này mang lại hai lợi thế quan trọng: (i) attention giữa các biến cho phép mô hình nắm bắt tương quan phức tạp giữa $PM_{2.5}$ và các yếu tố khí tượng mà không cần feature engineering thủ công; và (ii) MLP trên chiều thời gian xử lý hiệu quả chuỗi dài mà không gặp vấn đề độ phức tạp $O(L^2)$ của temporal attention [11]. Trên các benchmark chuỗi thời gian đa biến chuẩn, *iTransformer* đạt hiệu suất vượt trội so với các biến thể Transformer trước đó (Autoformer, FEDformer, PatchTST), đồng thời duy trì chi phí tính toán hợp lý [11].

Bảng 1.5. Siêu tham số khối cấu trúc mạng nội tại của *iTransformer*

Siêu tham số	Ý nghĩa
<i>seq_len</i>	Số bước thời gian lịch sử được nạp vào mô hình để phân tích.
<i>pred_len</i>	Số bước thời gian tương lai cần dự báo (tầm nhìn dự báo).
<i>enc_in</i>	Số lượng biến đầu vào, tương ứng với số lượng token trong cơ chế đảo ngược của <i>iTransformer</i> .
<i>d_model</i>	Số chiều của vector biểu diễn đặc trưng cho mỗi biến (token) sau khi ánh xạ.
<i>n_heads</i>	Số lượng head trong cơ chế Multi-Head Self-Attention, giúp nhận diện tính tương quan giữa các biến từ nhiều khía cạnh.
<i>e_layers</i>	Số lượng block (lớp) Transformer Encoder được xếp chồng lên nhau.
<i>d_ff</i>	Số lượng nơ-ron trong lớp ẩn của khối Feed-Forward nằm trong mỗi block Transformer.
<i>activation</i>	Hàm kích hoạt áp dụng tại lớp Feed-Forward (ví dụ: GELU).
<i>dropout</i>	Tỷ lệ vô hiệu hóa nơ-ron ngẫu nhiên trong mạng, giúp ngăn chặn hiện tượng quá khớp.
<i>use_norm</i>	Tham số bật/tắt cơ chế RevIN để xử lý các chuỗi thời gian có đặc tính không dừng.

Bảng 1.6. Siêu tham số khối huấn luyện và hàm mất mát của iTransformer

Siêu tham số	Ý nghĩa
<i>learning_rate</i>	Tốc độ học của thuật toán tối ưu AdamW, kiểm soát bước cập nhật trọng số mạng.
<i>weight_decay</i>	Hệ số phân rã trọng số L2, giúp điều chuẩn mô hình và giảm tình trạng quá khớp.
<i>T_max</i>	Số epoch trong nửa chu kỳ của bộ lập lịch giảm tốc độ học Cosine.
<i>eta_min</i>	Giá trị tốc độ học tối thiểu cho phép trong quá trình huấn luyện.
<i>alpha</i>	Hệ số cân bằng giữa sai số tuyệt đối (MAE) và bình phương sai số (MSE) trong hàm mất mát.
<i>epochs</i>	Tổng số vòng lặp huấn luyện tối đa trên toàn bộ tập dữ liệu.
<i>batch_size</i>	Kích thước khối dữ liệu (mini-batch) được xử lý đồng thời trên GPU.
<i>patience</i>	Số vòng lặp không có sự suy giảm sai số trên tập kiểm định trước khi kích hoạt ngắt sớm (early stopping).

2.4. Nhóm mô hình Spatio-Temporal

Các mô hình trình bày ở mục 1.2.2 và 1.2.3 khai thác Temporal Dependency nhưng xử lý mỗi trạm quan trắc một cách độc lập, chưa mô hình hóa mối quan hệ không gian giữa các trạm. Trong thực tế, nồng độ $PM_{2.5}$ tại một vị trí chịu ảnh hưởng mạnh bởi phát thải và điều kiện khí tượng từ các khu vực lân cận thông qua quá trình vận chuyển khí quyển [2]. Để khai thác phụ thuộc không gian này, mạng lưới N trạm quan trắc được biểu diễn dưới dạng **đồ thị** $\mathcal{G} = (\mathcal{V}, \mathcal{E}, \mathbf{A})$, trong đó mỗi đỉnh là một trạm, mỗi cạnh biểu diễn mối quan hệ không gian, và ma trận kề $\mathbf{A} \in \mathbb{R}^{N \times N}$ mã hóa cường độ liên kết giữa các trạm [14].

Trên nền tảng biểu diễn đồ thị, Graph Convolution cho phép cập nhật biểu diễn đặc trưng của mỗi nút bằng cách **Message Passing**: biểu diễn $\mathbf{H}$ được biến đổi tuyến tính qua ma trận trọng số $\mathbf{W}$, sau đó nhân với ma trận kề $\mathbf{A}$ để tổng hợp thông tin không gian, tức $\mathbf{H}' = \phi(\mathbf{A} \cdot \mathbf{H} \cdot \mathbf{W})$ [14]. Phép tích chập đồ thị đóng vai trò thành phần nền tảng trong cả hai mô hình spatio-temporal được sử dụng trong đề án: E-STGCN và ST-XLinear.

2.4.1. E-STGCN

E-STGCN (Enhanced Spatio-Temporal Graph Convolutional Network) là mô hình kết hợp phép tích chập đồ thị và LSTM để khai thác đồng thời phụ thuộc không gian lẫn thời gian trong dữ liệu đa trạm, được Panja et al. (2025) đề xuất cho bài toán dự báo chất lượng không khí [14]. Kiến trúc E-STGCN xử lý qua hai giai đoạn nối tiếp:

(i) *Giai đoạn không gian — GraphConv*: Tại mỗi bước thời gian t , ma trận đặc trưng $\mathbf{X}_t \in \mathbb{R}^{N \times F}$ (với N trạm, F đặc trưng) được biến đổi tuyến tính, sau đó nhân với ma trận kề $\mathbf{A}$ để tổng hợp thông tin từ các trạm lân cận. Kết quả được kết hợp với biểu diễn gốc theo cơ chế Concatenation và kích hoạt bằng hàm ReLU:

$$\mathbf{H}_t = \text{ReLU}([\mathbf{X}_t \mathbf{W} \parallel \mathbf{A} \cdot \mathbf{X}_t \mathbf{W}]) \quad (1.6)$$

trong đó $\parallel$ ký hiệu phép nối, tạo ra biểu diễn tích hợp cả thông tin nội tại lẫn thông tin từ lân cận không gian.

(ii) *Giai đoạn thời gian — LSTM*: Chuỗi đầu ra $\{\mathbf{H}_1, \dots, \mathbf{H}_T\}$ của GraphConv qua T bước thời gian được đưa vào mạng LSTM xử lý độc lập cho từng nút. Trạng thái ẩn cuối cùng h_T tổng hợp toàn bộ thông tin lịch sử, sau đó ánh xạ qua lớp tuyến tính sang cửa sổ dự báo [14].

Ma trận kề trong E-STGCN được xây dựng **một lần** trước khi huấn luyện, sử dụng Gaussian kernel trên

khoảng cách Haversine d_{ij} giữa các trạm:

$$A_{ij} = \exp \left(-\frac{d_{ij}^2}{\sigma^2} \right) \quad (1.7)$$

trong đó σ^2 là phương sai thực nghiệm, sau đó chuẩn hóa theo hàng. Đây là ma trận kề **tĩnh**, giả định mối quan hệ không gian cố định theo thời gian. Hạn chế chính của cách tiếp cận này là chưa phản ánh tính động của quá trình vận chuyển ô nhiễm: trong thực tế, cường độ lan truyền phụ thuộc mạnh vào hướng gió và vận tốc gió tại từng thời điểm — trạm xuôi gió ảnh hưởng lớn hơn so với trạm ngược gió, ngay cả khi ở cùng khoảng cách [14].

Không gian Siêu tham số (Hyperparameter Space): Mô hình E-STGCN sử dụng một tập hợp các siêu tham số nhằm quản lý độ phức tạp thông tin giữa luồng không gian và luồng thời gian, bao gồm:

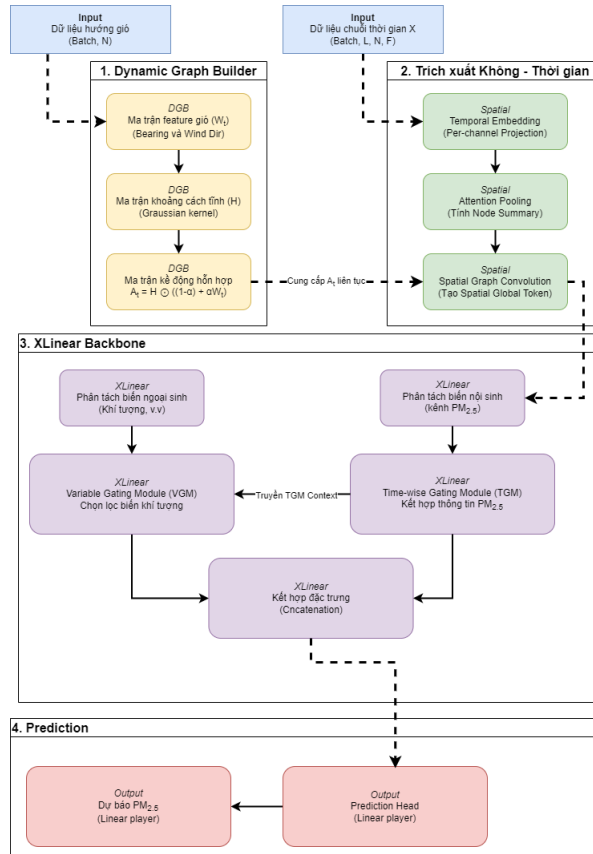
Bảng 1.7. Siêu tham số khối cấu trúc mạng nội tại của E-STGCN

Siêu tham số	Ý nghĩa
<i>seq_len</i>	Số bước thời gian lịch sử làm đầu vào cho mạng không-thời gian.
<i>pred_len</i>	Số bước thời gian tương lai cần dự báo đồng thời trên tất cả các trạm.
<i>out_feat</i>	Số chiều đặc trưng đầu ra của lớp Graph Convolution.
<i>lstm_units</i>	Số nơ-ron ẩn trong lớp LSTM, quyết định dung lượng biểu diễn đặc trưng thời gian.
<i>combination_type</i>	Phương thức kết hợp đặc trưng gốc và đặc trưng lân cận: Concatenation hoặc Addition.
<i>sigma2</i>	Phương sai σ^2 trong Gaussian kernel, kiểm soát tốc độ suy giảm trọng số theo khoảng cách giữa các trạm.

Bảng 1.8. Siêu tham số khối huấn luyện và hàm mất mát của E-STGCN

Siêu tham số	Ý nghĩa
<i>learning_rate</i>	Tốc độ học khởi tạo của thuật toán tối ưu AdamW.
<i>weight_decay</i>	Hệ số chính quy hóa L2 (Weight Decay) nhằm hạn chế hiện tượng Overfitting.
<i>delta</i>	Ngưỡng chuyển đổi của hàm HuberLoss: dùng MSE khi sai số $< \delta$, dùng MAE khi sai số $\geq \delta$.
<i>epochs</i>	Số vòng lặp huấn luyện tối đa trên toàn bộ tập dữ liệu.
<i>batch_size</i>	Số mẫu dữ liệu trong mỗi Mini-batch.
<i>patience</i>	Số epoch liên tiếp không cải thiện trên tập Validation trước khi kích hoạt Early Stopping.

2.4.2. Mô hình ST-XLinear đề xuất



Hình 1.1. Kiến trúc tổng quan của mô hình đề xuất ST-XLinear

ST-XLinear (Spatio-Temporal XLinear) là mô hình mạng thần kinh nhân tạo do đề án đề xuất, kết hợp sức mạnh phân tích thời gian của kiến trúc XLinear [10] với cơ chế học biểu diễn không gian thông qua module Dynamic Graph Builder. Kiến trúc này được thiết kế nhằm khắc phục hai hạn chế lớn trong các nghiên cứu trước đây: (i) XLinear nguyên bản chỉ trích xuất đặc trưng theo chiều thời gian mà bỏ qua sự tương tác không gian giữa các trạm quan trắc, và (ii) các mô hình như E-STGCN [14] chỉ sử dụng ma trận kề tĩnh dựa trên khoảng cách, không phản ánh được tính động lực học của quá trình lan truyền ô nhiễm theo chiều gió.

Dựa trên Hình 1.1, luồng hoạt động của mô hình ST-XLinear được chia thành các giai đoạn chính như sau:

1. Xây dựng Ma trận kết động (Dynamic Graph Builder): Thay vì sử dụng đồ thị cố định, module này liên tục tính toán ma trận kết A_t thay đổi theo thời gian thực dựa trên sự pha trộn giữa hai yếu tố:

- Yếu tố bề mặt tĩnh (Khoảng cách) H :** Khoảng cách vật lý (Haversine) giữa mọi cặp trạm i và j được chuyển hóa qua hàm Gaussian kernel: $H_{ij} = \exp(-d_{ij}^2/\sigma^2)$, thiết lập một nền tảng liên kết cơ sở cho các trạm gần nhau.
- Yếu tố động lực học (Gió) W_t :** Tại mỗi bước thời gian t , góc phương vị (Bearing) β_{ij} từ trạm i đến j được đối chiếu với hướng gió quan trắc $\theta_i^{(t)}$. Hệ số vận chuyển ô nhiễm được tính bằng $W_{ij}^{(t)} = \frac{\cos(\beta_{ij} - \theta_i^{(t)}) + 1}{2}$. Giá trị này đạt cực đại khi gió thổi thẳng từ trạm i sang j .
- Tổng hợp:** Ma trận kết động cuối cùng bám sát nguyên lý vật lý môi trường được pha trộn qua công thức:

$$A_t = H \odot [(1 - \alpha) + \alpha \cdot W_t] \quad (1.8)$$

2. Trích xuất đặc trưng không-thời gian: Dữ liệu đầu vào $\mathbf{X}$ (gồm biến mục tiêu $PM_{2.5}$ và các biến khí tượng) đi qua lớp **Temporal Embedding** (phép chiếu tuyến tính độc lập cho từng kênh) để chuyển thông tin thời gian thành vector đặc trưng. Sau đó, lớp **Attention Pooling** tổng hợp các kênh thành một Node Summary cho mỗi trạm.

Node Summary kết hợp cùng ma trận kề động $\mathbf{A}_t$ đi vào lớp tích chập không gian **Spatial GCN** để tổng hợp thông tin từ các trạm lân cận:

$$\mathbf{S}^{\text{spatial}} = \text{LayerNorm}(\text{GELU}(\text{Linear}([\mathbf{S} \parallel \mathbf{A}_t \cdot \mathbf{S}]) + \mathbf{S})) \quad (1.9)$$

Kết quả sinh ra một *Spatial Global Token* chứa đựng cả lịch sử thời gian cục bộ lẫn ngữ cảnh không gian toàn cục.

3. Khối xương sống XLinear (Backbone): Khác với XLinear nguyên bản sử dụng Learnable Token ngẫu nhiên, ST-XLinear tích hợp trực tiếp *Spatial Global Token* vào luồng xử lý biến nội sinh.

- Khối **Time-wise Gating Module (TGM)** tiếp nhận biến nội sinh ($PM_{2.5}$) và ngữ cảnh không gian này để đánh giá tầm quan trọng của các mốc thời gian trong quá khứ.
- Ngữ cảnh đầu ra của TGM tiếp tục làm thông tin dẫn đường (guide context) đi vào khối **Variable-wise Gating Module (VGM)** để tiến hành sàng lọc nhiễu, quyết định biến ngoại sinh (nhiệt độ, độ ẩm, v.v.) nào có ý nghĩa lớn nhất đối với dự báo.

Hai đầu ra cuối cùng được Concatenation và đi qua lớp **Prediction Head** để xuất kết quả dự báo nồng độ $PM_{2.5}$ tại từng trạm.

Dưới đây là phần mô tả siêu tham số của mô hình, tập trung vào ý nghĩa và vai trò của từng siêu tham số:

Bảng 1.9. Siêu tham số khối cấu trúc đồ thị mạng nội tại của ST-XLinear

Siêu tham số	Ý nghĩa
seq_len	Số bước thời gian lịch sử làm đầu vào cho mô hình.
$pred_len$	Số bước thời gian tương lai cần dự báo tại mỗi trạm.
d_model	Kích thước Embedding Dimension cho biểu diễn đặc trưng ẩn của chuỗi thời gian.
t_ff	Số nơ-ron trong lớp Feed-Forward của khối Temporal Gating Module.
c_ff	Số nơ-ron trong lớp Feed-Forward của khối Variable-wise Gating Module.
$dropout$	Tỷ lệ Dropout áp dụng trong mạng để hạn chế Overfitting.
$alpha_graph$	Trọng số $\alpha \in [0, 1]$ cân bằng giữa ma trận kề tĩnh (khoảng cách Haversine) và ma trận kề động (hướng gió).

Bảng 1.10. Siêu tham số huấn luyện và hàm mất mát của ST-XLinear

Siêu tham số	Ý nghĩa
<i>learning_rate</i>	Tốc độ học khởi tạo của thuật toán tối ưu AdamW.
<i>weight_decay</i>	Hệ số chính quy hóa L2 (Weight Decay) nhằm hạn chế Overfitting.
<i>T_max</i>	Số epoch cho nửa chu kỳ của bộ lập lịch CosineAnnealingLR.
<i>eta_min</i>	Giá trị tốc độ học tối thiểu mà bộ lập lịch Cosine không được giảm vượt quá.
<i>mse_w</i>	Trọng số cân bằng giữa thành phần MSE và MAE trong hàm CombinedLoss.
<i>delta</i>	Ngưỡng chuyển đổi của hàm HuberLoss: dùng MSE khi sai số $< \delta$, dùng MAE khi sai số $\geq \delta$.
<i>epochs</i>	Số vòng lặp huấn luyện tối đa trên toàn bộ tập dữ liệu.
<i>batch_size</i>	Số lượng mẫu dữ liệu mỗi Mini-batch.
<i>patience</i>	Số epoch liên tiếp không cải thiện trên tập Validation trước khi dừng huấn luyện sớm (Early Stopping).

Không gian Siêu tham số (Hyperparameter Space):

2.4.3. Phương pháp Ensemble

Phương pháp Ensemble Learning là một kỹ thuật mạnh mẽ nhằm nâng cao hiệu suất dự báo và tính ổn định của hệ thống thông qua việc kết hợp dự đoán từ nhiều mô hình thành phần khác nhau. Nguyên lý cốt lõi của Ensemble dựa trên thực tế là các Base Learners, do sự khác biệt về kiến trúc và cách trích xuất đặc trưng, thường mắc phải các loại sai số phân bố khác nhau. Việc kết hợp chúng giúp triệt tiêu Variance (phương sai), khắc phục điểm yếu cục bộ của từng mô hình và giảm thiểu rủi ro quá khớp.

Trong hệ thống dự báo này, phương pháp Ensemble được thiết kế để kết hợp trực tiếp đầu ra của hai kiến trúc tiêu biểu có đặc thù phân tích khác nhau: mô hình dựa trên MLP (như XLinear, chuyên biệt về nắm bắt tính chu kỳ và lọc nhiễu ngoại sinh) và mô hình dựa trên đồ thị (như ESTGCN, chuyên biệt về khai thác dòng chảy không gian). Quy tắc kết hợp được sử dụng là Weighted Average. Cụ thể, giá trị dự báo cuối cùng $\hat{y}$ được tính bằng chập tuyến tính giữa giá trị dự báo của hai mô hình thành phần:

$$\hat{y} = \alpha \cdot \hat{y}_{XLinear} + (1 - \alpha) \cdot \hat{y}_{ESTGCN} \quad (1.10)$$

trong đó, $\hat{y}_{XLinear}$ và $\hat{y}_{ESTGCN}$ lần lượt là dự báo nồng độ $PM_{2.5}$ xuất ra từ hai mô hình, và $\alpha \in [0, 1]$ là trọng số kết hợp.

Với phương pháp luận này, α không phải là tham số có thể học được (learnable parameter) bằng Gradient Descent trong quá trình huấn luyện mô hình, mà được xem như một Hyperparameter. Để đảm bảo tính khách quan và đạt hiệu suất tối ưu, α được xác định thông qua **Grid Search** trên tập Validation. Phương pháp dò tìm này được kiểm soát bởi các tham số không gian cấu hình chuyên biệt như sau:

Bảng 1.11. Siêu tham số cấu hình Grid Search của phương pháp Ensemble

Siêu tham số	Ý nghĩa
α	Trọng số kết hợp trong khoảng $[0, 1]$, quyết định tỷ lệ đóng góp kết quả của bộ ST-XLinear so với E-STGCN.
$metric$	Chỉ số đánh giá tiêu chuẩn (ở đây là MAE trung bình) dùng để chọn giá trị α tối ưu nhất trên tập Validation.
$step$	Khoảng cách giữa các giá trị α liên tiếp trong chuỗi quét Grid Search, quyết định độ mịn của mảng tìm kiếm.

Cách tiếp cận này tận dụng được điểm mạnh từ các mô hình thành phần mà không làm tăng đáng kể tài nguyên tính toán.

2.5. Các chỉ số đánh giá hiệu suất

Để đánh giá một cách toàn diện, khách quan độ chính xác và khả năng tổng quát hóa của các mô hình dự báo $PM_{2.5}$, bước Evaluation đóng vai trò tối quan trọng. Không có một chỉ số đơn lẻ nào phản ánh hoàn hảo mọi khía cạnh của sai số dự báo; do đó, thông lệ nghiên cứu khoa học khuyến nghị sử dụng kết hợp nhiều chỉ số thống kê khác nhau để có cái nhìn đa chiều [20, 13]. Trong đồ án này, các mô hình được so sánh chéo dựa trên bốn chỉ số đo lường chính.

2.5.1. Root Mean Square Error (RMSE)

Root Mean Square Error (Sai số toàn phương trung bình căn) là một trong những chỉ số đánh giá độ phân tán định lượng phổ biến nhất trong các bài toán hồi quy và dự báo môi trường. Nó được định nghĩa là căn bậc hai của trung bình cộng bình phương các khoảng cách giữa giá trị dự báo và giá trị quan trắc thực tế, có cùng đơn vị với biến mục tiêu ($\mu g/m^3$):

$$RMSE = \sqrt{\frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2} \quad (1.11)$$

trong đó y_i là giá trị nồng độ $PM_{2.5}$ thực tế ở quan trắc thứ i , $\hat{y}_i$ là giá trị dự báo tương ứng, và N là tổng số cỡ mẫu đánh giá.

Đặc tính quan trọng nhất của RMSE đến từ thao tác bình phương sai số trước khi lấy trung bình. Điều này khiến RMSE **phát hiện** các sai số lớn (Outlier). Trong bối cảnh dự báo chất lượng không khí, đặc tính này cực kỳ hữu ích: việc mô hình bỏ sót một sự kiện nồng độ $PM_{2.5}$ tăng vọt đột ngột sẽ lập tức phản ánh bằng mức RMSE tăng cao. Theo Chai và Draxler (2014), RMSE đáng tin cậy hơn các chỉ số tuyệt đối khi phân phối sai số dự đoán tiến gần phân phối chuẩn Gaussian, đồng thời RMSE thỏa mãn bất đẳng thức tam giác để được xem là một Distance Metric hợp lệ [20].

2.5.2. Mean Absolute Error (MAE)

Mean Absolute Error (Sai số tuyệt đối trung bình) là một chỉ số đo lường độ lớn trung bình của sai số trong tập dự báo, bỏ qua dấu của chúng. Khác với RMSE, MAE không sử dụng thao tác bình phương mà trực tiếp lấy giá trị tuyệt đối của hiệu số giữa kết quả dự báo và quan trắc thực tế, sau đó tính trung bình cộng:

$$MAE = \frac{1}{N} \sum_{i=1}^N |y_i - \hat{y}_i| \quad (1.12)$$

Với cấu trúc tuyến tính này, mỗi sai số đóng góp vào giá trị trung bình với tỷ lệ thuận theo độ lớn tuyệt đối của riêng nó. Willmott và Matsuura (2005) lập luận rằng MAE là chỉ số tự nhiên và rõ ràng hơn so với RMSE [21]. Do không phạt nặng các điểm ngoại lai, MAE mang tính Robust hơn trong các bộ dữ liệu có nhiều nhiễu bất thường, giúp đánh giá trung lực hiệu suất trung bình của mô hình. Độ chênh lệch giữa RMSE và MAE ($RMSE \geq MAE$) phản ánh mức độ phân tán của phân phối sai số.

2.5.3. Coefficient of Determination (R^2)

Coefficient of Determination (Hệ số quyết định), thường được ký hiệu là R^2 , là một chỉ số thống kê phản ánh tỷ lệ phần trăm sự biến thiên (phương sai) của biến mục tiêu mà mô hình dự báo có thể nắm bắt và giải thích được bằng các biến độc lập. Định nghĩa tổng quát của hệ số R^2 áp dụng cho cả hồi quy tuyến tính và phi tuyến tính (như mạng nơ-ron hay cây quyết định xgboost) [22, 16] được biểu diễn qua tỷ số giữa tổng bình phương phần dư (SS_{res}) và tổng bình phương toàn phần (SS_{tot}):

$$R^2 = 1 - \frac{SS_{res}}{SS_{tot}} = 1 - \frac{\sum_{i=1}^N (y_i - \hat{y}_i)^2}{\sum_{i=1}^N (y_i - \bar{y})^2} \quad (1.13)$$

trong đó, $\bar{y}$ là giá trị trung bình lượng $PM_{2.5}$ của dữ liệu thực tế đánh giá (y_i).

Hệ số R^2 thường nhận giá trị trong khoảng $[0, 1]$. Giá trị R^2 tiến gần 1 cho thấy mô hình bám sát gần như hoàn hảo mọi dao động của dữ liệu mục tiêu. Nếu $R^2 = 0$, mô hình chỉ dự đoán bằng giá trị trung bình $\bar{y}$, không học được quy luật nào. R^2 có thể âm khi mô hình dự báo kém hơn cả việc dùng giá trị trung bình.

2.5.4. Mean Absolute Percentage Error (MAPE)

Mean Absolute Percentage Error (Sai số phần trăm tuyệt đối trung bình) đo lường độ chính xác dưới dạng tỷ lệ phần trăm, mang lại ưu điểm vượt trội về khả năng diễn giải trực quan cho người trực tiếp sử dụng hệ thống so với các chỉ số số tuyệt đối (metric đơn vị) như RMSE hay MAE. Công thức MAPE là bình quân của sai số tuyệt đối quy đổi về tỷ lệ phần trăm dựa trên giá trị gốc:

$$MAPE = \frac{100}{N} \sum_{i=1}^N \left| \frac{y_i - \hat{y}_i}{y_i} \right| \quad (1.14)$$

Mặc dù phổ biến và dễ sử dụng để so sánh hiệu năng giữa các bộ dữ liệu khác nhau [13], MAPE vẫn có một số nhược điểm đã được Armstrong và Collopy (1992) lưu ý. *Thứ nhất*, khi giá trị thực tế (y_i) rất nhỏ hoặc bằng không, mẫu số sẽ khiến chỉ số tiến về vô cực. *Thứ hai*, MAPE có thiên hướng phạt nặng Overpredict mạnh hơn Underpredict trên cùng độ lớn sai số tuyệt đối. Chính vì vậy, trong đồ án, MAPE được sử dụng đồng thời cùng MAE và RMSE để có cái nhìn tham chiếu đầy đủ.

2.6. Các phương pháp chuẩn hóa dữ liệu

Trong các bài toán dự báo chuỗi thời gian đa biến, đặc biệt là dự báo nồng độ chất ô nhiễm như $PM_{2.5}$, các biến đầu vào (khí tượng, nồng độ các chất) thường có thang đo, đơn vị và đặc tính phân phối rất khác biệt. Việc đưa trực tiếp các giá trị thô này vào các mạng nơ-ron học sâu hoặc các thuật toán tối ưu hóa bằng gradient có thể dẫn đến hiện tượng bùng nổ đạo hàm, hội tụ chậm, hoặc khiến mô hình bị thiên lệch về phía các đặc trưng có giá trị tuyệt đối lớn.

Do đó, việc tiền xử lý và chuẩn hóa dữ liệu là bước bắt buộc. Dựa trên quá trình phân tích đặc thù phân phối của từng nhóm biến quan trắc [23], hệ thống áp dụng linh hoạt các phương pháp biến đổi và chuẩn hóa được hỗ trợ thông qua thư viện Scikit-learn [24] như sau:

2.6.1. Biến đổi Logarit (Log1p)

Biến đổi logarit được áp dụng chủ yếu cho các biến có phân phối lệch phải với độ lệch lớn, một hiện tượng rất phổ biến ở các đo lường nồng độ chất ô nhiễm cục bộ. Nhằm xử lý an toàn các trường hợp giá trị bằng không (như lượng mưa hoặc nồng độ cực thấp), hệ thống sử dụng hàm $\log 1p$ thay vì logarit tự nhiên tiêu chuẩn [25]:

$$x' = \ln(1 + x)$$

Phép biến đổi phi tuyến này giúp thu hẹp đuôi phân phối dài, kéo cấu trúc dữ liệu về dạng gần đối xứng hơn. Điều này làm giảm đáng kể mức độ ảnh hưởng của các giá trị cực đoan trước khi dữ liệu được đưa qua các bộ chuẩn hóa tuyến tính.

2.6.2. Cắt xén ngoại lai (Clipping Percentile)

Đối với các biến chứa giá trị ngoại lai dị thường sinh ra do lỗi cảm biến hoặc các hiện tượng thời tiết cực đoan đột ngột, việc giữ nguyên chúng có thể làm lệch phương sai của dải giá trị bình thường sau khi chuẩn hóa. Kỹ thuật cắt xén, dựa trên nền tảng của phương pháp Winsorization [26], được hệ thống áp dụng ở các ngưỡng phân vị cao (ví dụ: percentile thứ 99 hoặc 99,5):

$$x' = \min(x, P_q)$$

trong đó P_q là giá trị tại phân vị thứ q của tập dữ liệu. Phương pháp này thiết lập một ngưỡng trần an toàn, gọt bớt các đỉnh nhọn dị biệt mà không làm biến dạng cấu trúc phân phối của phần lớn dữ liệu hợp lệ còn lại.

2.6.3. Chuẩn hóa Z-score (StandardScaler)

Phương pháp Standard Scaler chuẩn hóa dữ liệu dựa trên nguyên lý dịch chuyển và thay đổi tỷ lệ, giả định biến có phân phối xấp xỉ phân phối chuẩn. Mỗi điểm dữ liệu được chuyển đổi thành điểm Z-score thông qua việc trừ đi giá trị trung bình (μ) và chia cho độ lệch chuẩn (σ) của toàn tập mẫu [27, 28]:

$$x' = \frac{x - \mu}{\sigma}$$

Sau khi chuẩn hóa, biến đầu ra sẽ có trung bình bằng 0 và phương sai bằng 1. Kỹ thuật này được áp dụng cho các đặc trưng khí tượng có phân phối gần chuẩn và ít chứa điểm ngoại lai, điển hình như nhiệt độ, nhiệt độ điểm sương, độ ổn định nhiệt hoặc nhiệt độ đất.

2.6.4. Chuẩn hóa mạnh (RobustScaler)

Với các biến có phân phối không chuẩn và chứa đựng nhiều điểm ngoại lai thực tế — ví dụ như nồng độ SO_2 , O_3 , tốc độ gió hoặc chính bản thân biến mục tiêu $PM_{2.5}$ — các chỉ số μ và σ ở phương pháp chuẩn sẽ bị kéo lệch nghiêm trọng. Robust Scaler khắc phục điểm yếu này bằng cách sử dụng các đại lượng thống kê kháng nhiễu là Median (Q_2) và Interquartile Range ($IQR = Q_3 - Q_1$) [29]:

$$x' = \frac{x - Q_2}{Q_3 - Q_1}$$

Bằng cách loại bỏ sự chi phối của các giá trị cực đoan tại hai đầu mút phân phối, Robust Scaler giúp mô hình học sâu nắm bắt được tri thức cốt lõi của chuỗi thời gian mà không bị "đánh lừa" bởi các đợt nhiễu sóng ngắn hạn.

2.6.5. Chuẩn hóa Min-Max (MinMaxScaler)

Phương pháp Min-Max thực hiện phép co giãn tuyến tính toàn bộ dải dữ liệu về một khoảng giới hạn cố định (thường là $[0, 1]$) [27]:

$$x' = \frac{x - x_{\min}}{x_{\max} - x_{\min}}$$

Kỹ thuật này đặc biệt tối ưu cho các biến mà bản chất vật lý của chúng đã có biên độ và giới hạn cực trị rõ ràng, chẳng hạn như độ ẩm tương đối (0 – 100%), độ che phủ mây, độ ẩm đất, hoặc các biến lượng mưa đã qua cắt xén.

2.7. Các công trình nghiên cứu liên quan

Để xây dựng cơ sở khoa học và định vị được những đóng góp của đồ án, việc rà soát và đánh giá các nghiên cứu đi trước về dự báo nồng độ ô nhiễm $PM_{2.5}$ cả trong nước và quốc tế là hết sức cần thiết. Các hướng tiếp cận đang phân hóa rất đa dạng dựa trên cả mô hình vật lý–hóa học truyền thống và các phương pháp Machine Learning / Deep Learning hiện đại.

2.7.1. Nghiên cứu trong nước

Tại Việt Nam, các nghiên cứu chuyên sâu về phân bố ô nhiễm không khí và ảnh hưởng sức khỏe đang ngày càng được chú trọng do mức độ báo động tại các đô thị lớn. Khởi điểm từ khía cạnh vĩ mô, nghiên cứu của Bui và Nghiem (2025) đã chứng minh được mối liên hệ tuyến tính giữa mật độ đô thị hóa và mức độ ô nhiễm thông qua mô phỏng hồi quy trên 63 tỉnh thành: mỗi 1% gia tăng đô thị hóa sẽ kéo theo nồng độ $PM_{2.5}$ tăng **0,54 $\mu g/m^3$** [1]. Cùng đánh giá trên bài toán y tế công cộng, Le et al. (2024) [5] và Hoang et al. (2023) [7] đã định lượng được mối liên hệ giữa phơi nhiễm bụi mịn thứ cấp với các bệnh lý tim mạch và hô hấp, đồng thời ước tính thiệt hại kinh tế lên đến hàng trăm triệu USD mỗi năm — cho thấy tiềm năng phòng tránh hàng nghìn ca tử vong sớm nếu duy trì được chất lượng không khí ở mức thời kỳ giãn cách COVID-19.

Về phương pháp mô hình hóa, các nghiên cứu trong nước chủ yếu sử dụng hệ thống mô phỏng vật lý–hóa học truyền thống, tiêu biểu là CMAQ (Community Multiscale Air Quality). Cụ thể, Ho et al. (2025) sử dụng mô hình này kết hợp với hồ sơ phát thải giao thông nhằm phân tích cơ chế lan truyền các chất ô nhiễm tại Hà Nội theo biến động mùa vụ [3]. Tương tự, Nguyen et al. (2024) triển khai mô phỏng trên hệ thống CMAQ kết hợp WRF, đạt khả năng bao phủ không gian rộng nhưng sai số vẫn ở mức cao ($MAPE \approx 63\%$) trong các điều kiện khí tượng phức tạp [8]. Bên cạnh đó, Dam et al. (2024) thông qua phân tích dữ liệu quan trắc thực địa đã chỉ ra gradient nồng độ $PM_{2.5}$ theo chiều thẳng đứng rất rõ rệt, liên quan chặt chẽ đến hiện tượng nghịch nhiệt: nồng độ ở 30m là 50–84 $\mu g/m^3$, trong khi ở 320m chỉ còn 34–40 $\mu g/m^3$ [2].

2.7.2. Nghiên cứu ngoài nước

Trái ngược với sự thống trị của các mô hình cơ học hóa tại Việt Nam, xu thế nghiên cứu toàn cầu trong vài năm trở lại đây tập trung cao độ vào nhóm Machine Learning và Deep Learning.

Ứng dụng Gradient Boosting: XGBoost và LightGBM thường được triển khai nhờ tốc độ xử lý nhanh, minh bạch dữ liệu đầu vào. Tırnık (2025) đã so sánh hiệu năng dự báo AQI trên bộ dữ liệu 8 năm tại Türkiye và kết luận XGBoost đạt hiệu năng vượt trội so với LightGBM và SVM [16]. Với yêu cầu IoT ở trạm giám sát rẻ tiền biên, Al-Nuaimi et al. (2025) đã nén mô hình XGBoost xuống chỉ 13 kB mà vẫn duy trì hiệu năng chấp nhận được [17].

Ứng dụng mô hình Deep Learning Temporal: Các mô hình hồi quy LSTM và GRU khai thác phụ thuộc thời gian thông qua cơ chế cổng. Silveira et al. (2025) cho thấy LSTM đạt hiệu suất cao trên cả bài toán Single-step lẫn Multi-horizon nhờ khả năng giải quyết vấn đề Vanishing Gradient [12]. Zhang et al. (2025) [19] đề xuất kết hợp CNN và LSTM để trích xuất đặc trưng cục bộ cho dự báo $PM_{2.5}$ tại Bắc Kinh (đạt $RMSE = 5,236$ trong biến

thiên 6 giờ). Gần đây, He et al. (2024) kết hợp BiLSTM và GRU để nắm bắt phụ thuộc thời gian cả hai chiều [18]. Tuy vậy, hạn chế chung của họ RNN vẫn là xử lý tuần tự, không thể song song hóa, dẫn đến thời gian huấn luyện lớn trên chuỗi dài.

Kiến trúc Transformer và mô hình Spatio-Temporal: Để khắc phục hạn chế về tính tuần tự, các kiến trúc Transformer đã được áp dụng vào dự báo chuỗi thời gian. Điển hình, iTransformer [11] đảo ngược chiều Self-Attention từ chiều thời gian sang chiều biến, cho phép xử lý song song hiệu quả. Về mô hình không-thời gian, Panja et al. (2025) đề xuất E-STGCN kết hợp Graph Convolution với LSTM: ma trận kề được xây dựng từ Gaussian kernel trên khoảng cách Haversine giữa các trạm, cho phép mô hình nắm bắt sự lan truyền $PM_{2.5}$ theo cấu trúc không gian [14].

2.7.3. Nhận xét và khoảng trống nghiên cứu

Việc tổng hợp các tài liệu của học giả trong nước lẫn quốc tế trên nhiều phương diện (sức khỏe cộng đồng [7], hóa môi trường [3], mạng học sâu nâng cao [11]) cho thấy bức tranh tổng quan đồng thời làm lộ rõ một số khoảng trống tồn đọng trong nền tảng nghiên cứu ứng dụng cho bài toán tại Việt Nam:

1. **Thiếu hụt hệ thống đánh giá đối chuẩn (Benchmark) đồng thời:** Trên cùng dữ liệu quan trắc $PM_{2.5}$ tại nước ta, đa số các công trình hoặc dùng các bộ quan sát quá cũ (thập kỷ trước) để thử thuật toán Machine Learning nhỏ lẻ, hoặc dùng khung mô phỏng truyền thống tốn kém máy chủ CMAQ. Chưa có nghiên cứu nào xây dựng hệ thống Benchmark so sánh trực tiếp giữa Machine Learning cổ điển, Sequence Model, Transformer và Spatio-Temporal Graph trên bộ dữ liệu Việt Nam nhiều năm với khung đánh giá Multi-horizon.
2. **Cấu trúc không gian đồ thị chưa khai thác đặc tính động lực học lưu chất:** Hầu hết các kỹ thuật Graph Network truyền thống trong dự báo dòng chảy ô nhiễm không khí (kể cả E-STGCN mới nhất) đều áp dụng mô hình liên kết ma trận đồ thị dạng lưới bằng khoảng cách tính [14]. Cách tiếp cận này bỏ qua vai trò quyết định của gió trong quá trình vận chuyển ô nhiễm: một trạm nằm xuôi theo chiều gió có khả năng ảnh hưởng cao hơn rất nhiều so với trạm ngược gió, ngay cả khi khoảng cách vật lý nhỏ hơn.
3. **Quá trình Feature Engineering chưa dựa trên nguyên lý khí quyển học:** Điển hình do giới hạn về mặt dữ liệu, công tác thiết kế đặc trưng bổ trợ thường được bỏ qua đối với vùng nhiệt đới phức tạp tự nhiên. Chưa có thực nghiệm nào bóc tách trích xuất các dạng chỉ báo liên quan đến aerosol sulfate hay chỉ số quy luật bức xạ của ánh sáng làm Context Guide cho các kênh DL model Việt Nam.

Những khoảng trống nêu trên chính là cơ sở để đề án đề xuất hệ thống ST-XLinear tích hợp Dynamic Graph Builder cùng quy trình Feature Engineering dựa trên nguyên lý khí quyển học, được trình bày chi tiết tại các chương tiếp theo.

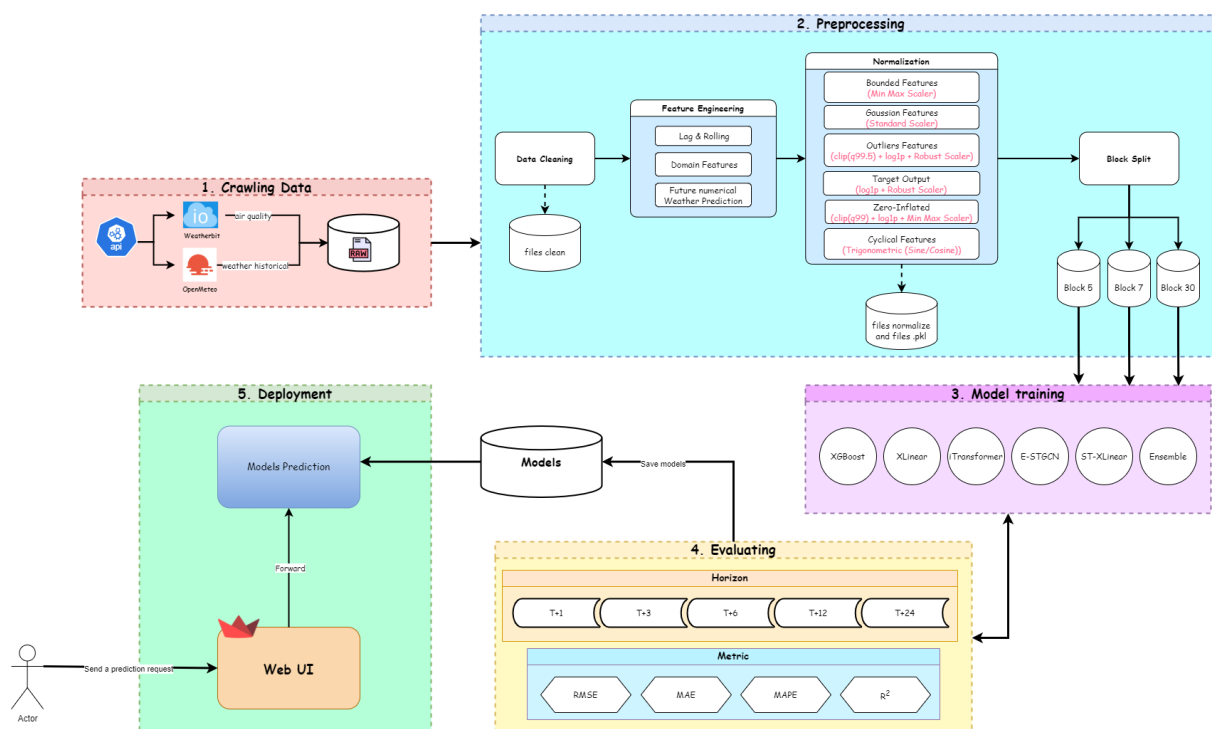
CHƯƠNG 2

PHƯƠNG TIỆN NGHIÊN CỨU - PHƯƠNG PHÁP NGHIÊN CỨU

Chương này trình bày chi tiết phương tiện và phương pháp nghiên cứu, tương ứng với Khối 1 đến Khối 5 trong sơ đồ tổng quan giải pháp đã trình bày tại (Hình 2.1). Nội dung bao gồm: (i) phương tiện nghiên cứu — ngôn ngữ lập trình, thư viện, nguồn dữ liệu và hạ tầng tính toán; (ii) quy trình thu thập và tiền xử lý dữ liệu từ 32 trạm quan trắc trong giai đoạn 2023–2025; (iii) kỹ thuật đặc trưng với 134 biến chia thành 8 nhóm; (iv) chiến lược chuẩn hóa và phân tách dữ liệu; (v) cấu hình huấn luyện chi tiết cho 6 kiến trúc mô hình; (vi) phương pháp đánh giá hiệu năng; và (vii) triển khai ứng dụng dự báo trên nền tảng web.

1. SƠ ĐỒ TỔNG QUAN GIẢI PHÁP

Hình 2.1 trình bày sơ đồ tổng quan giải pháp của hệ thống dự báo nồng độ $PM_{2.5}$, được tổ chức thành năm khối chức năng liên kết tuần tự từ khâu thu thập dữ liệu đến khâu triển khai ứng dụng.



Hình 2.1. Sơ đồ tổng quan giải pháp hệ thống dự báo nồng độ $PM_{2.5}$

Khối 1 — Thu thập dữ liệu (Crawl Data). Dữ liệu thô được thu thập tự động từ hai nguồn API: nền tảng Weatherbit cung cấp dữ liệu chất lượng không khí ($PM_{2.5}$, PM_{10} , CO , O_3 , NO_2 , SO_2) và nền tảng OpenMeteo cung cấp dữ liệu khí tượng lịch sử (nhiệt độ, độ ẩm, nhiệt độ điểm sương, lượng mưa, mây, tốc độ gió, hướng gió, gió giật, nhiệt độ và độ ẩm đất). Dữ liệu từ 12 trạm quan trắc trong giai đoạn 2023–2025 được lưu trữ dưới dạng tệp thô trước khi đưa vào quy trình xử lý.

Khối 2 — Tiền xử lý dữ liệu (Process). Dữ liệu thô trải qua bốn giai đoạn xử lý nối tiếp, mỗi giai đoạn tạo ra sản phẩm trung gian phục vụ giai đoạn tiếp theo:

- *Data Cleaning*: Thực hiện ghép nối dữ liệu không khí và khí tượng, phát hiện và gán cờ các bản ghi bất thường (dữ liệu đóng băng, lỗi cảm biến $PM_{2.5}$, giá trị ngoại lai), loại bỏ bản ghi trùng lặp, nội suy giá trị khuyết thiếu, và tạo các đặc trưng phái sinh. Sản phẩm đầu ra là các tệp dữ liệu sạch (files clean).

- *Feature Engineering*: Tinh chiết các đặc trưng mới dựa trên nguyên lý hóa khí quyển (chỉ số oxidation potential, humid sulfate risk, thermal stability), phân tách thành phần gió (sin/cos), và trích xuất đặc trưng trượt (lag features, rolling mean, rolling std) cùng mã hóa chu kỳ thời gian.
- *Normalization*: Áp dụng các chiến lược chuẩn hóa khác nhau tùy theo đặc tính phân phối của từng nhóm biến, bao gồm các tổ hợp *Log1p*, *RobustScaler*, *StandardScaler* và *MinMaxScaler*. Các bộ biến đổi (scalers) được khớp (fit) trên tập huấn luyện và lưu trữ dưới dạng tệp .pkl để phục vụ quá trình giải chuẩn hóa khi suy luận.
- *Block Split*: Phân chia dữ liệu theo cấu trúc khối thời gian tuần hoàn (cyclic block splitting) với ba cấu hình: Block 5 (chu kỳ 5 ngày: 3 ngày train, 1 ngày val, 1 ngày test), Block 7 (chu kỳ 7 ngày: 5 ngày train, 1 ngày val, 1 ngày test) và Block 30 (chu kỳ 30 ngày: 20 ngày train, 5 ngày val, 5 ngày test). Chiến lược chia theo khối tuần hoàn đảm bảo mỗi tập con đều bao phủ được các điều kiện khí tượng đa dạng qua các mùa, thay vì tập trung vào một giai đoạn thời gian cố định.

Khối 3 — Huấn luyện mô hình (Model Train). Dữ liệu sau phân chia được đưa vào hệ thống đối chuẩn (benchmark) song song giữa sáu kiến trúc mô hình: XGBoost, XLinear, iTransformer, E-STGCN, ST-XLinear (mô hình đề xuất) và Ensemble. Trọng số của các mô hình sau huấn luyện được lưu trữ vào cơ sở dữ liệu mô hình (Models) để phục vụ cả quá trình đánh giá lẫn triển khai.

Khối 4 — Đánh giá hiệu suất (Evaluation). Kết quả dự báo được đánh giá trên năm tầm nhìn ($T + 1$, $T + 3$, $T + 6$, $T + 12$, $T + 24$ giờ), sử dụng bốn chỉ số: *RMSE* [20], *MAE* [21], *MAPE* [13] và R^2 [22]. Việc đánh giá đa tầm nhìn và đa chỉ số cho phép so sánh hiệu suất của từng kiến trúc trên các kịch bản dự báo ngắn hạn đến dài hạn.

Khối 5 — Triển khai ứng dụng (Deployment). Mô hình đạt hiệu suất phù hợp được nạp từ cơ sở dữ liệu mô hình vào module suy luận (Model Prediction), sau đó chuyển tiếp kết quả dự báo lên giao diện Web UI xây dựng trên nền tảng Streamlit, cung cấp khả năng giám sát chất lượng không khí và cảnh báo sớm.

Sơ đồ giải pháp trên là khung tham chiếu xuyên suốt cho các chương tiếp theo: **Chương 2** trình bày chi tiết phương tiện và phương pháp nghiên cứu tương ứng với Khối 1 đến Khối 3, trong khi **Chương 3** phân tích kết quả thực nghiệm từ Khối 4 và thảo luận về hiệu quả triển khai tại Khối 5.

2. PHƯƠNG TIỆN NGHIÊN CỨU

2.1. Ngôn ngữ lập trình và thư viện

Danh sách các công cụ và thư viện chính được sử dụng trong nghiên cứu được tổng hợp tại Bảng 2.1.

Bảng 2.1. Danh sách công cụ và thư viện

Công cụ	Chức năng	Phiên bản
Python	Ngôn ngữ lập trình	3.10+
Pandas, NumPy	Xử lý dữ liệu bảng, tính toán số học	≥ 2.0
scikit-learn	KNNImputer, RobustScaler, StandardScaler, MinMaxScaler	≥ 1.3
XGBoost	Gradient boosting	≥ 2.0
PyTorch	Deep learning	≥ 2.1
PyTorch Geometric	Xử lý dữ liệu đồ thị	≥ 2.4
Streamlit	Ứng dụng web	≥ 1.30
Matplotlib, Seaborn	Trực quan hóa	—

2.2. Phần cứng

Toàn bộ quá trình tiền xử lý dữ liệu, huấn luyện mô hình và triển khai ứng dụng được thực hiện trên máy tính xách tay với cấu hình được trình bày tại Bảng 2.2.

Bảng 2.2. Cấu hình phần cứng sử dụng trong nghiên cứu

Thành phần	Thông số
CPU	Intel Core i5-12500H (12 nhân, 16 luồng, xung tối đa 4.5 GHz)
RAM	16 GB DDR5 bus 3200 MHz
GPU	NVIDIA GeForce RTX 3050 Laptop (4 GB GDDR6, nhân CUDA)

Bộ xử lý i5-12500H với 12 nhân cho phép thực hiện song song các tác vụ tiền xử lý dữ liệu trên $\approx 1,63$ triệu bản ghi. RAM 16 GB đảm bảo khả năng nạp toàn bộ ma trận đặc trưng vào bộ nhớ cho các thao tác chuẩn hóa và chia khối. GPU RTX 3050 với 4 GB VRAM được sử dụng để tăng tốc huấn luyện các mô hình học sâu (ESTGCN, ST-XLinear, iTransformer, XLinear) thông qua cơ chế tính toán song song trên nhân CUDA, giúp quá trình lan truyền ngược và tối ưu AdamW hội tụ trong giới hạn thời gian thực tế phục vụ nghiên cứu.

3. THU THẬP DỮ LIỆU

Dữ liệu đầu vào gồm hai nguồn chính: dữ liệu chất lượng không khí và dữ liệu thời tiết lịch sử, được thu thập song song cho cùng 32 trạm với cùng khoảng thời gian và tần suất.

3.1. Dữ liệu chất lượng không khí

Hệ thống thu thập dữ liệu chất lượng không khí được khai thác thông qua dịch vụ nguồn mở Weatherbit API. Nhằm đảm bảo mức độ chi tiết và tính đại diện cho bài toán dự báo chuỗi thời gian, dữ liệu được thu thập liên tục từ ngày 01/01/2023 đến 01/12/2025 tạo thành một chuỗi quan trắc liên tục dài khoảng 25.536 giờ tại mỗi trạm. Với tần suất 1 quan trắc/giờ, mạng lưới trải dài trên 32 trạm phân bố rộng khắp 13 tỉnh/thành phố, đem lại khả năng đối chiếu dữ liệu bề mặt đáng tin cậy. Tổng cộng 7 biến đặc trưng đo lường được sử dụng bao gồm: chỉ số AQI tổng hợp, hai phân loại bụi hạt ($PM_{2.5}$, PM_{10}) và khối 4 biến khí hỗn hợp (CO , NO_2 , SO_2 , O_3). Trong đó, nồng độ $PM_{2.5}$ đóng vai trò là biến mục tiêu định hướng cho quá trình hội tụ của toàn bộ hệ thống mô hình dự báo.

3.2. Dữ liệu thời tiết lịch sử

Dữ liệu thời tiết lịch sử được thu thập thông qua Open-Meteo API, dựa trên bộ dữ liệu tái phân tích ERA5 của Trung tâm Dự báo Khí tượng Hạn vừa Châu Âu (ECMWF). ERA5 kết hợp dữ liệu quan trắc thực tế từ các trạm khí tượng, vệ tinh và phao biển với mô hình khí tượng số thông qua phương pháp đồng hóa dữ liệu, tạo ra bộ dữ liệu lưới toàn cầu có độ phân giải không gian $0,25^\circ \times 0,25^\circ$. Độ phân giải này tương đương mỗi ô lưới có kích thước khoảng 28×28 km tại vĩ độ Việt Nam ($\approx 10\text{--}21^\circ N$), nghĩa là các giá trị khí tượng đại diện cho trung bình không gian trên một ô vuông cạnh 28 km thay vì giá trị đo tại một điểm duy nhất.

Dữ liệu được thu thập liên tục từ ngày 01/01/2023 đến 01/12/2025, với tần suất 1 bản ghi/giờ, đồng nhất hoàn toàn với nguồn dữ liệu chất lượng không khí. Tổng cộng 17 biến khí tượng thuộc 7 nhóm được thu thập (Bảng 2.3).

Bảng 2.3. Danh sách 17 biến thời tiết thu thập

Nhóm	Biến	Đơn vị	Số biến
Nhiệt độ	Nhiệt độ không khí, điểm sương, nhiệt độ cảm nhận	$^\circ C$	3
Độ ẩm	Độ ẩm tương đối	%	1
Giáng thủy	Lượng mưa	mm/h	1
Mây	Độ phủ mây	%	1
Gió	Tốc độ gió, hướng gió, gió giật	m/s, $^\circ$, m/s	3
Nhiệt độ đất	Tại 4 tầng sâu: 0–7, 7–28, 28–100, 100–255 cm	$^\circ C$	4
Độ ẩm đất	Tại 4 tầng sâu: 0–7, 7–28, 28–100, 100–255 cm	m^3/m^3	4

Ngoài các yếu tố khí tượng cơ bản ảnh hưởng đến sự phân tán ô nhiễm (nhiệt độ, độ ẩm, tốc độ gió), nhóm nhiệt độ đất và độ ẩm đất (8 biến đo tại 4 tầng sâu từ 0 đến 255 cm) phản ánh điều kiện nhiệt lực học bề mặt — yếu tố quyết định khả năng đối lưu và chiều cao tầng ranh giới khí quyển, từ đó ảnh hưởng trực tiếp đến nồng độ bụi $PM_{2.5}$ tầng thấp.

3.3. Siêu dữ liệu

Tập siêu dữ liệu chứa tọa độ địa lý (vĩ độ, kinh độ), tỉnh/thành phố và quận/huyện của từng trạm. Thông tin tọa độ được sử dụng để tính khoảng cách Haversine giữa các cặp trạm, từ đó xây dựng ma trận kề cho các mô hình không gian–thời gian (ESTGCN, ST-XLinear).

Khoảng cách Haversine là đại lượng đo lường khoảng cách vòng lớn ngắn nhất giữa hai điểm trên bề mặt

của một hình cầu (trong trường hợp này là Trái Đất), dựa trên tọa độ vĩ độ và kinh độ của chúng. Khác với khoảng cách Euclidean (khoảng cách đường thẳng) vốn giả định bề mặt quan sát là một mặt phẳng, công thức Haversine xét đến độ cong của bề mặt Trái Đất. Đặc tính này mang lại độ chính xác cao hơn đáng kể khi tính toán khoảng cách thực tế giữa các trạm quan trắc địa lý đặt cách xa nhau.

Về mặt toán học, khoảng cách d giữa hai trạm có tọa độ vĩ độ, kinh độ lần lượt là (ϕ_1, λ_1) và (ϕ_2, λ_2) (được tính bằng đơn vị radian) được xác định thông qua hệ phương trình:

$$a = \sin^2\left(\frac{\phi_2 - \phi_1}{2}\right) + \cos(\phi_1) \cos(\phi_2) \sin^2\left(\frac{\lambda_2 - \lambda_1}{2}\right) \quad (2.1)$$

$$c = 2 \cdot \text{atan2}(\sqrt{a}, \sqrt{1-a}) \quad (2.2)$$

$$d = R \cdot c \quad (2.3)$$

trong đó, $R \approx 6371$ km là bán kính trung bình của Trái Đất. Giá trị d thu được chính là nền tảng để thiết lập cường độ liên kết không gian ban đầu giữa các nút mạng trong đồ thị. Tổng quy mô dữ liệu thô đạt khoảng 1,63 triệu bản ghi ($32 \text{ trạm} \times 25.536 \text{ giờ} \times 2 \text{ nguồn}$), tạo nền tảng bao quát cho mạng cảm biến đa trạm.

4. KHẢO SÁT VÀ CHỌN LỌC TRẠM QUAN TRẮC

4.1. Sự cần thiết của bước chọn lọc

Trong 32 trạm ban đầu, không phải trạm nào cũng đáp ứng yêu cầu về chất lượng dữ liệu và tính đại diện vùng. Các vấn đề quan sát được bao gồm: tỷ lệ dữ liệu khuyết cao (một số trạm $> 40\%$), cảm biến hỏng gây dữ liệu đóng băng, dữ liệu trùng lặp giữa các trạm cùng khu vực ($r > 0.99$), hoặc trạm cô lập không có trạm lân cận để mô hình spatio-temporal khai thác.

4.2. Hệ thống tiêu chí lọc

Sáu tiêu chí được thiết kế và đánh giá tuần tự trên 32 trạm.

Bảng 2.4. Hệ thống 6 tiêu chí lọc

Ký hiệu	Tiêu chí	Ngưỡng	Phương pháp đánh giá
R1	Data Integrity	Missing $PM_{2.5} < 20\%$	Đếm số giờ NaN / tổng số giờ kỳ vọng
R2	Frozen Sensor	Frozen events < 50	Đếm số đoạn có rolling std $< 10^{-6}$ trên cửa sổ 12h
R3	Spatial Clustering	≥ 1 trạm khác trong bán kính 100 km	Tính khoảng cách Haversine giữa tất cả các cặp trạm
R4	Data Uniqueness	Hệ số tương quan Pearson $r < 0.99$	Tính r giữa chuỗi $PM_{2.5}$ của các cặp trạm cùng cụm
R5	Climate Homogeneity	Cùng vùng khí hậu trong cụm	Phân loại theo ranh giới địa lý Bắc/Nam
R6	Variance	Cụm có đa dạng loại trạm	Kiểm tra phân bố: đô thị / ngoại ô / ven biển

Hệ thống tiêu chí này được chia thành ba nhóm cấp độ đánh giá chặt chẽ. Cụ thể, các tiêu chí R1–R2 nhằm


bảo đảm tính toàn vẹn và giới hạn lỗi đóng băng dữ liệu nội tại ở từng trạm đơn lẻ. Nhóm R3–R4 kiểm soát các mối quan hệ không gian, loại bỏ khu vực cô lập với hệ số r trùng lặp vượt ngưỡng, tối ưu hóa biểu diễn học không gian. Cuối cùng, nhóm R5–R6 phân tách khí hậu và phương diện địa giới, bảo chứng cho sự đa dạng đặc trưng của từng cụm khu vực nghiên cứu.

4.3. Kết quả chọn lọc


Sau khi áp dụng 6 tiêu chí, 12/32 trạm (37.5%) vượt qua toàn bộ và được chia thành 2 cụm vùng (Bảng 2.5).

Bảng 2.5. 12 trạm được chọn, phân theo cụm vùng

Cụm	ID	Tỉnh/Thành — Quận/Huyện
Bắc (North)	1	Hà Nội — Cầu Giấy
	4	Thanh Hóa — Thọ Xuân
	5	Hà Nội — Gia Lâm
	16	Hải Phòng — Đồ Sơn
	17	Hải Phòng — Hồng Bàng
	27	Nam Định — TP. Nam Định
Nam (South)	7	TP. HCM — Quận 1
	18	Cần Thơ — Ninh Kiều
	24	Đồng Nai — Biên Hòa
	30	Vĩnh Long — TP. Vĩnh Long
	31	Trà Vinh — TP. Trà Vinh
	32	An Giang — Rạch Giá



(a) Cụm trạm khu vực miền Bắc



(b) Cụm trạm khu vực miền Nam

Hình 2.2. Phân bố các trạm quan trắc theo hai cụm miền Bắc và miền Nam


Các vòng tròn màu xanh biểu diễn bán kính lân cận của từng trạm. Điểm màu xanh là trạm được chọn, điểm màu đỏ là các vị trí lân cận.

Việc phân 2 cụm Bắc/Nam dựa trên đặc tính phân phối $PM_{2.5}$: cụm Bắc có biên độ $PM_{2.5}$ theo mùa lớn (trung bình mùa đông gấp 2–3 lần mùa hè), trong khi cụm Nam có nồng độ $PM_{2.5}$ ổn định hơn quanh năm. Do sự khác biệt phân phối này, mỗi cụm được huấn luyện mô hình dự báo riêng biệt.

5. TIỀN XỬ LÝ DỮ LIỆU — LÀM SẠCH

Quy trình làm sạch dữ liệu được thực hiện độc lập cho mỗi trạm quan trắc, bao gồm 7 bước tuần tự chia thành 3 giai đoạn chính (Hình 2.3):

Quy trình tiền xử lý dữ liệu được tiến hành tuần tự qua ba giai đoạn có mối liên hệ chặt chẽ với nhau. Khởi đầu với **giai đoạn ghép nối và chuẩn bị** (Bước 1–2), hai nguồn dữ liệu độc lập về chất lượng không khí và khí tượng tại mỗi trạm được đồng bộ hóa dựa trên nhãn thời gian. Ngay sau đó, biến hướng gió được mã hóa tuần hoàn và một chỉ mục giờ liên tục được thiết lập nhằm định vị chính xác các khoảng dữ liệu bị khuyết. Dựa trên nền tảng này, hệ thống chuyển sang **giai đoạn phát hiện và gán nhãn lỗi** (Bước 3–5) bằng cách quét tuần tự toàn bộ chuỗi để nhận diện ba nhóm dị thường chính: hiện tượng đóng băng cảm biến, các giá trị ngoại lai và lỗi xuất phát từ cảm biến quang học. Những điểm dữ liệu vi phạm sẽ được hệ thống tự động gán nhãn cảnh báo hoặc loại bỏ. Cuối cùng, tại **giai đoạn làm sạch và phục hồi** (Bước 6–7), các bản ghi trùng lặp được tinh giản hoàn toàn. Những khoảng trống dữ liệu để lại sẽ được khôi phục linh hoạt: phương pháp nội suy tuyến tính được áp dụng cho các gián đoạn ngắn, trong khi thuật toán K-láng giềng gần nhất (KNN) được sử dụng để xử lý các khoảng mất mát lớn. Kết thúc quy trình, tập dữ liệu thô đã được chuyển hóa thành một chuỗi thời gian liên tục, toàn vẹn và sẵn sàng cho bước kỹ nghệ đặc trưng tiếp theo.



Hình 2.3. Quy trình làm sạch dữ liệu cho mỗi trạm quan trắc

Quy trình gồm 3 giai đoạn và 7 bước tuần tự. Đầu vào là dữ liệu thô đã ghép nối, đầu ra là chuỗi thời gian liên tục sẵn sàng cho bước kỹ thuật đặc trưng.

5.1. Bước 1 — Mã hóa tuần hoàn và phân tách thành phần gió

Trong dữ liệu khí tượng, hướng gió (đơn vị độ) là một biến đặc trưng mang tính tuần hoàn cao, nơi các giá trị 0° và 360° cùng biểu diễn một thực thể vật lý duy nhất là hướng Bắc. Tuy nhiên, sự chênh lệch số học cực đại giữa hai giá trị này ($|360 - 0| = 360$) tạo ra một điểm gãy nghiêm trọng trong không gian đặc trưng. Hiện tượng này khiến các mô hình học máy và mạng nơ-ron dễ hiểu lầm rằng gió hướng 1° và 359° là hai trạng thái đối lập về mặt địa lý, trong khi thực tế chúng gần như trùng khít. Để khắc phục triệt để sự gián đoạn này, hướng gió gốc θ cần được chuyển đổi sang đơn vị radian và mã hóa vào không gian hai chiều thông qua các hàm lượng giác sin và cosin theo các công thức sau:

$$W_{sin} = \sin\left(\theta \times \frac{\pi}{180}\right) \quad (2.4)$$

$$W_{cos} = \cos\left(\theta \times \frac{\pi}{180}\right) \quad (2.5)$$

Việc phân tách này không chỉ đơn thuần là thay đổi đơn vị đo lường mà còn mang ý nghĩa vật lý quan trọng trong phân tích động lực học khí quyển. Thành phần W_{sin} đại diện cho vector gió dọc theo trục Đông – Tây (nhận giá trị dương khi gió thổi từ phía Đông và âm khi từ phía Tây), trong khi W_{cos} đại diện cho trục Bắc – Nam (nhận giá trị dương khi gió từ phía Bắc và âm khi từ phía Nam). Kết quả là hướng gió được biểu diễn bởi một cặp giá trị biến thiên liên tục trong khoảng $[-1, 1]$, tạo thành một vector đơn vị trên vòng tròn lượng giác. Cách tiếp cận này giúp loại bỏ hoàn toàn sự nhảy vọt về giá trị tại điểm chuyển giao $0^\circ/360^\circ$, hỗ trợ mô hình học sâu nắm bắt được các tương quan không gian một cách chính xác và ổn định hơn. Sau khi quá trình mã hóa hoàn tất, biến hướng gió gốc sẽ được loại bỏ để tối ưu hóa không gian đầu vào và tránh gây nhiễu cho quá trình huấn luyện.

5.2. Bước 2 — Kiểm tra khoảng thời gian

Hệ thống tạo chỉ mục giờ đầy đủ từ 00:00 ngày 01/01/2023 đến 23:00 ngày 01/12/2025 (tổng cộng 25.536 mốc giờ kỳ vọng cho mỗi trạm). Dữ liệu gốc được gán vào chỉ mục này; các mốc giờ thiếu dữ liệu sẽ tự động nhận giá trị rỗng. Bước này giúp xác định chính xác tỷ lệ dữ liệu khuyết theo công thức: $(\text{số giờ rỗng} / \text{tổng số giờ kỳ vọng}) \times 100\%$.

5.3. Bước 3 — Phát hiện dữ liệu đóng băng

Hiện tượng đóng băng xảy ra khi cảm biến gặp sự cố phần cứng hoặc mất kết nối, khiến giá trị đầu ra không thay đổi trong nhiều giờ liên tiếp. Mục tiêu của bước này là phát hiện và gán nhãn các khung giờ đóng băng để mô hình nhận biết dữ liệu không đáng tin cậy.

Phương pháp phát hiện thực hiện tính độ lệch chuẩn trượt trên cửa sổ 12 giờ (yêu cầu tối thiểu 6 quan sát hợp lệ, lấy tâm giữa cửa sổ) cho toàn bộ 11 biến quan trắc chủ chốt. Cụ thể, các biến này bao gồm 7 biến ô nhiễm (AQI , $PM_{2.5}$, PM_{10} , CO , NO_2 , SO_2 , O_3) và 4 biến khí tượng đi kèm (nhiệt độ, độ ẩm tương đối, điểm sương, tốc độ gió). Nếu độ lệch chuẩn tại một mốc thời gian bất kỳ có giá trị $< 10^{-6}$ (tức gần như không biến thiên), khung giờ đó được gán nhãn đóng băng. Cửa sổ 12 giờ được lựa chọn vì đủ dài để phát hiện tình trạng đóng băng xuyên đêm, và phép lấy tâm giữa cửa sổ cho phép nhận diện chính xác các rìa biên của đoạn lỗi.

5.4. Bước 4 — Phát hiện ngoại lai

Dữ liệu chất lượng không khí thu thập từ các trạm quan trắc có thể chứa các giá trị bất thường do lỗi thiết bị, nhiễu truyền dẫn hoặc các sự kiện phát thải cực đoan. Mục tiêu của bước này là xác định và gán nhãn các giá trị ngoại lai để tách biệt khỏi dữ liệu hợp lệ, tránh ảnh hưởng đến quá trình huấn luyện mô hình. Ngoại lai được phát hiện qua hai tầng bổ trợ.

Tầng 1 — Ngưỡng vật lý: Mỗi biến được áp dụng khoảng giá trị hợp lệ dựa trên các quy chuẩn kỹ thuật (Bảng 2.6). Các giá trị nằm ngoài khoảng hợp lệ sẽ được gán nhãn ngoại lai.

Bảng 2.6. Ngưỡng vật lý phát hiện ngoại lai

Biến	Min	Max	Đơn vị	Nguồn tham chiếu
AQI	0	500	—	[30]
$PM_{2.5}$	0	600	$\mu g/m^3$	[30]
PM_{10}	0	1.000	$\mu g/m^3$	[31]
CO	0	20.000	$\mu g/m^3$	[31]
NO_2	0	400	$\mu g/m^3$	[31]
SO_2	0	500	$\mu g/m^3$	[32]
O_3	0	350	$\mu g/m^3$	Quan trắc thực tế
Nhiệt độ	0	50	$^{\circ}C$	Biên khí hậu Việt Nam
Độ ẩm	0	100	%	Giới hạn vật lý
Tốc độ gió	0	20	m/s	Giá trị theo giờ

Ngưỡng tối đa cho các chất ô nhiễm được xác định dựa trên Quy chuẩn kỹ thuật quốc gia QCVN 05:2023/BTNMT [31] và QCVN 06:2009/BTNMT [32]. Riêng chỉ số AQI và ngưỡng $PM_{2.5}$ áp dụng theo thang đo của Cơ quan Bảo vệ Môi trường Hoa Kỳ [30], trong đó mức $600 \mu g/m^3$ tương ứng với ngưỡng nguy hại cao nhất. Đối với các biến khí tượng, giới hạn được thiết lập theo biên khí hậu đặc trưng của Việt Nam.

Tầng 2 — Khoảng tứ phân vị: Áp dụng bổ sung cho 6 biến ô nhiễm với hệ số $3 \times IQR$ nhằm bảo toàn các giá trị tăng vọt thực tế (ví dụ: bụi mịn mùa đông tại Hà Nội) [23]. Giá trị x được coi là ngoại lai nếu:

$$x < Q_1 - 3 \times IQR \quad \text{hoặc} \quad x > Q_3 + 3 \times IQR \quad (2.6)$$

5.5. Bước 5 — Phát hiện lỗi cảm biến quang học

Cảm biến đếm hạt quang học (OPC) có thể phát sinh lỗi phản cứng khiến giá trị đo bụi $PM_{2.5}$ và PM_{10} tăng đột biến mà không phản ánh điều kiện ô nhiễm thực tế. Mục tiêu của bước này là phân biệt giữa đợt tăng nồng độ thực và lỗi thiết bị, từ đó loại bỏ các điểm dữ liệu sai lệch.

Phương pháp phát hiện yêu cầu ba điều kiện phải đồng thời thỏa mãn. Thứ nhất, nồng độ $PM_{2.5}$ vượt quá ngưỡng $Q_3 + 3 \times IQR$ (với IQR được tính trượt theo tháng để loại trừ ảnh hưởng mùa vụ). Thứ hai, nồng độ PM_{10} cũng đồng thời vượt ngưỡng $Q_3 + 3 \times IQR$, xác nhận lỗi xuất phát từ buồng đo chung. Thứ ba, tỷ lệ biến đổi tuyệt đối theo giờ của các chất khí (CO , NO_2 , SO_2) phải duy trì dưới 50%, chứng tỏ không có đợt phát thải thực tế nào đang xảy ra. Chỉ khi cả ba điều kiện đều được kích hoạt, giá trị $PM_{2.5}$ và PM_{10} tại mốc thời gian đó mới bị loại bỏ và chuyển sang bước điền khuyết.

5.6. Bước 6 — Xóa trùng lặp

Quá trình thu thập dữ liệu liên tục từ các API công cộng có thể phát sinh hiện tượng trùng lặp nhãn thời gian do chồng lấn giữa các phiên thu thập hoặc cơ chế thử lại của máy chủ nguồn. Mục tiêu của bước này là đảm bảo mỗi mốc thời gian chỉ xuất hiện duy nhất một lần trong chuỗi dữ liệu.

Hệ thống quét toàn bộ chỉ mục thời gian và loại bỏ mọi bản ghi trùng lặp, chỉ giữ lại bản ghi đầu tiên theo thứ tự xuất hiện. Chiến lược ưu tiên bản ghi đầu dựa trên cơ sở: phiên thu thập sớm nhất thường phản ánh dữ liệu

gần nhất với thời điểm quan trắc thực tế. Bước này ngăn ngừa nguy cơ cùng một điểm dữ liệu bị đếm nhiều lần trong quá trình xây dựng cửa sổ trượt và tính toán thống kê ở các giai đoạn sau.

5.7. Bước 7 — Điền giá trị khuyết

Sau khi hoàn tất các bước phát hiện lỗi (đóng băng, ngoại lai, lỗi cảm biến) và xóa trùng lặp, chuỗi dữ liệu chứa các khoảng trống cần được điền khuyết trước khi đưa vào mô hình. Quy trình điền khuyết được thực hiện qua 3 bước tuần tự.

Để khôi phục tính liên tục của chuỗi thời gian, hệ thống áp dụng một chiến lược điền khuyết lai linh hoạt tùy thuộc vào quy mô của khoảng gián đoạn. Đối với các khoảng trống ngắn hạn (nhỏ hơn hoặc bằng 6 giờ liên tiếp), phương pháp nội suy tuyến tính theo trục thời gian được ưu tiên sử dụng, dựa trên đặc tính biến thiên trơn tru và không đột ngột của các yếu tố khí tượng trong quy mô vài giờ. Ngược lại, với các khoảng khuyết dữ liệu lớn (trên 6 giờ), hệ thống chuyển sang sử dụng thuật toán K-láng giềng gần nhất (KNN Imputation) [33] nhằm khai thác tối đa tương quan đa biến. Một bước tiền xử lý mang tính quyết định trước khi chạy KNN là toàn bộ các biến phải được chuẩn hóa tạm thời về cùng một thang đo. Thao tác này ngăn chặn rủi ro các biến có dải giá trị tuyệt đối lớn lấn át các biến có dải giá trị nhỏ trong phép tính toán khoảng cách Euclidean. Thuật toán KNN sau đó được thiết lập với $K = 12$ (tương đương nửa chu kỳ ngày đêm của khí quyển) kết hợp cùng trọng số nghịch đảo khoảng cách, giúp các mẫu dữ liệu càng gần gũi về mặt cấu trúc sẽ càng đóng góp lớn vào giá trị ước lượng. Cuối cùng, tại bước hậu xử lý, toàn bộ dữ liệu khuyết sau khi điền được giải chuẩn hóa về lại đơn vị đo lường gốc, đồng thời các giá trị âm (nếu vô tình phát sinh từ biên giới của phép nội suy) được giới hạn cứng về mức 0 nhằm bảo toàn nghiêm ngặt ý nghĩa vật lý thực tế của nồng độ chất ô nhiễm.

6. KỸ THUẬT ĐẶC TRƯNG

6.1. Tổng quan và lý do thực hiện

Các biến thô thu thập từ trạm quan trắc chỉ phản ánh giá trị tức thời tại mỗi mốc thời gian, chưa chứa thông tin về xu hướng lịch sử, mức biến động và các mối tương tác giữa các biến. Các nghiên cứu về dự báo chuỗi thời gian chỉ ra rằng hiệu năng mô hình phụ thuộc đáng kể vào chất lượng đặc trưng đầu vào [15]. Vì vậy, bước kỹ thuật đặc trưng là cần thiết để:

Quá trình kỹ nghệ đặc trưng đóng vai trò cốt lõi trong việc nâng cao khả năng học biểu diễn của mô hình thông qua nhiều khía cạnh phân tích. Trước hết, việc áp dụng phép trễ cung cấp ngữ cảnh lịch sử quan trọng tại các mốc thời gian trước đó ($t-1, t-3, \dots, t-24$ giờ), cho phép hệ thống tự động nắm bắt được quy luật quán tính tự nhiên của chuỗi. Bên cạnh đó, các phép thống kê trượt như trung bình, độ lệch chuẩn và giá trị cực đại trên các cửa sổ 12–24 giờ cung cấp thước đo định lượng về xu hướng nền và mức độ biến động gần đây của nồng độ $PM_{2.5}$. Hơn nữa, do nồng độ bụi mịn chịu sự chi phối phức tạp từ nhiều yếu tố đan xen, các đặc trưng tương tác được xây dựng nhằm biểu diễn những hiệu ứng phi tuyến kết hợp giữa nguồn phát thải, điều kiện khí tượng và phản ứng hóa học mà từng biến đơn lẻ không thể lột tả trọn vẹn. Cuối cùng, để củng cố khả năng nhận diện quy luật thời gian, hệ thống tiến hành mã hóa tuần hoàn bằng các hàm lượng giác, qua đó tích hợp liền mạch các tín hiệu chu kỳ mang tính quy luật như lưu lượng giao thông theo giờ, hoạt động sản xuất theo tuần và biến động khí hậu theo mùa. Từ 24 biến thô ban đầu (7 biến ô nhiễm và 17 biến thời tiết), hệ thống tạo ra tổng cộng 134 đặc trưng phân thành 8 nhóm chính (Bảng 2.7).

Bảng 2.7. 8 nhóm đặc trưng trong hệ thống

Nhóm	Tên nhóm	Số lượng
1	Đặc trưng thô	16
2	Đặc trưng tương tác	16
3	Cờ chất lượng dữ liệu	5
4	Trễ $PM_{2.5}$	7
5	Thống kê trượt $PM_{2.5}$	6
6	Trễ ô nhiễm và thời tiết	31
7	Mã hóa thời gian	14
8	Thời tiết tương lai	≈ 20
Tổng cộng		≈ 134

Nhóm 1–2 mã hóa trạng thái quan trắc hiện tại và các mối tương tác vật lý–hóa học phi tuyến. Nhóm 3 cung cấp nhãn chất lượng dữ liệu. Nhóm 4–6 khai thác thông tin lịch sử thông qua phép trễ và thống kê trượt trên chuỗi thời gian, trong đó tất cả đều được dịch chuyển 1 bước thời gian nhằm ngăn chặn rò rỉ dữ liệu. Nhóm 7 mã hóa chu kỳ tuần hoàn theo giờ, ngày và năm bằng hàm lượng giác $\sin / \cos$. Nhóm 8 bổ sung thông tin thời tiết tại thời điểm tương lai (dịch chuyển theo tầm nhìn dự báo), được thiết kế để tích hợp với nguồn dữ liệu dự báo khí tượng số (NWP) khi triển khai thực tế.

6.2. Đặc trưng tương tác

Các đặc trưng tương tác được thiết kế để nắm bắt các mối quan hệ phi tuyến và các chỉ số vật lý/hóa học ảnh hưởng đến nồng độ bụi mịn (Bảng 2.8).

Bảng 2.8. Danh sách các đặc trưng tương tác

Đặc trưng	Công thức	Ý nghĩa	Cơ sở
Tiềm năng oxy hóa	$O_3 \times (SO_2 + NO_2)$	Chỉ số oxy hóa thứ cấp	Khả năng oxy hóa khí quyển thúc đẩy chuyển hóa tiền chất thành bụi thứ cấp
Tổng tải ô nhiễm	$CO + SO_2 + NO_2$	Tổng nồng độ các chất từ quá trình đốt cháy	Đặc trưng cho lượng phát thải sơ cấp từ nguồn đốt nhiên liệu hóa thạch
Chỉ số nguồn phát	$\log(NO_2 + 1) - \log(SO_2 + 1)$	Dương: giao thông; Âm: công nghiệp	Tỷ lệ log giữa hai nguồn phát chính
Nguy cơ sulfate ẩm	$\text{độ ẩm} \times SO_2$	Chỉ số hình thành aerosol sulfate	Phản ứng oxy hóa pha lỏng chuyển hóa SO_2 thành sulfate (SO_4^{2-}) khi ẩm cao
Ổn định nhiệt	$T_{air} - T_{soil_0}$	Dương: đối lưu; Âm: nghịch nhiệt	Chênh lệch nhiệt bề mặt–khí quyển
Tiềm năng cuốn bụi	$v_{wind}/(\theta_{soil} + 1)$	Chỉ số cuốn bụi cơ học	Tỷ lệ lực gió trên sức kết dính đất
Chỉ số trì trệ	$1/(v_{wind} + 1)$	Mức độ trì trệ không khí	Nghịch đảo tốc độ phân tán
Tỷ lệ bụi	$PM_{2.5}/PM_{10}$	Tỷ lệ bụi mịn so với bụi thô	Chỉ số nhận diện đặc điểm nguồn thải và mức độ thâm nhập bụi mịn vào hệ hô hấp
Độ hụt điểm sương	$T_{air} - T_{dew}$	Khoảng cách đến ngưỡng ngưng tụ	Định nghĩa khí tượng chuẩn
Biến thiên nhiệt độ	$T(t) - T(t - 6)$	Biến thiên trong 6 giờ	Sai phân bậc nhất chu kỳ

Các đặc trưng tương tác chia thành ba nhóm chức năng: (i) nhóm chỉ thị nguồn phát thải (tiềm năng oxy hóa, tổng tải ô nhiễm, chỉ số nguồn phát) phản ánh cường độ và nguồn gốc ô nhiễm; (ii) nhóm điều kiện khí tượng (ổn định nhiệt, chỉ số trì trệ, tiềm năng cuốn bụi) mô tả khả năng đối lưu và phân tán; và (iii) nhóm chuyển hóa hóa học (nguy cơ sulfate ẩm) định lượng nguy cơ hình thành aerosol sulfate trong điều kiện độ ẩm cao [5].

6.3. Các nhóm đặc trưng còn lại

Nhóm 3 — Cờ chất lượng dữ liệu: Bao gồm 5 biến nhị phân phản ánh trạng thái dữ liệu tại mỗi bước thời gian: cờ đóng băng cảm biến, cờ ngoại lai, cờ lỗi cảm biến quang học, nhãn ngày nghỉ/cuối tuần, và cờ cảnh báo nồng độ $PM_{2.5}$ vượt ngưỡng $75 \mu g/m^3$ trong giờ liền kề trước. Các biến này cho phép mô hình nhận biết và điều chỉnh dự báo khi dữ liệu đầu vào có chất lượng thấp hoặc rơi vào các khung thời gian đặc biệt.

Nhóm 4 — Trễ $PM_{2.5}$: Gồm 7 đặc trưng trích xuất thông tin lịch sử của biến mục tiêu tại 5 mốc trễ ($t - 1, t - 3, t - 6, t - 12, t - 24$) giờ. Lý do sử dụng phép trễ là vì nồng độ $PM_{2.5}$ có tính quán tính cao — giá trị tại các mốc gần đây là chỉ báo mạnh cho giá trị tương lai. Nhóm này còn bao gồm biến thiên bậc nhất $\Delta PM_{2.5}(t) = PM_{2.5}(t) - PM_{2.5}(t - 1)$ và hệ số hồi quy tuyến tính trên cửa sổ 12 giờ để đo xu hướng.

Nhóm 5 — Thống kê trượt $PM_{2.5}$: Bổ sung 6 đặc trưng gồm trung bình, độ lệch chuẩn và giá trị cực đại

trên hai cửa sổ 12 và 24 giờ. Thống kê trượt được sử dụng vì giá trị đơn lẻ tại từng mốc thời gian không phản ánh được mức nền và mức biến động của ô nhiễm; các thống kê tổng hợp giúp mô hình phân biệt giữa giai đoạn ổn định và giai đoạn biến động. Toàn bộ đặc trưng trong Nhóm 4 và Nhóm 5 đều được dịch chuyển 1 bước thời gian nhằm ngăn chặn rò rỉ dữ liệu.

Nhóm 6 — Trễ ô nhiễm và thời tiết: Tổng hợp 31 đặc trưng trễ của 5 biến ô nhiễm phụ (PM_{10} , CO , SO_2 , O_3 , NO_2) tại các mốc trễ tương tự, kết hợp với các biến khí tượng phải sinh như biến thiên lượng mưa, chênh lệch nhiệt độ và chỉ số trị trệ gió. Nhóm này cung cấp ngữ cảnh đa biến, phản ánh mối tương quan chéo giữa các chất ô nhiễm và điều kiện khí tượng.

Nhóm 7 — Mã hóa thời gian: Bao gồm 14 đặc trưng mã hóa thông tin thời gian: các biến lịch cơ bản (giờ, ngày trong tuần, tháng, ngày trong năm) và các phép biến đổi lượng giác sin / cos tương ứng để biểu diễn tính tuần hoàn. Mã hóa lượng giác được sử dụng thay vì giá trị số nguyên vì nó bảo toàn tính liên tục tại điểm chuyển giữa các chu kỳ (ví dụ: 23 giờ $\rightarrow$ 0 giờ).

Nhóm 8 — Thời tiết tương lai: Cung cấp khoảng 20 đặc trưng ngoại sinh bao gồm nhiệt độ, lượng mưa, tốc độ gió và hướng gió tại thời điểm tương lai (được dịch chuyển theo tầm nhìn dự báo h).

Trong pha huấn luyện và đánh giá, hệ thống sử dụng trực tiếp các giá trị *thực tế đã được quan trắc* tại thời điểm $T + h$. Cách tiếp cận này tạo ra một kịch bản "thời tiết hoàn hảo", giúp cô lập sai số. Nó cho phép đo lường giới hạn trên về năng lực cốt lõi của các kiến trúc mạng nơ-ron trong việc học quy luật lan truyền ô nhiễm, tránh việc mô hình học phải những độ lệch từ các dự báo thời tiết.

Tuy nhiên, khi triển khai hệ thống vào hoạt động thực tế, dữ liệu quan trắc của tương lai là chưa tồn tại. Lúc này, toàn bộ các đặc trưng của Nhóm 8 bắt buộc phải được thay thế bằng đầu ra từ các mô hình **Dự báo thời tiết bằng phương pháp số**. Khác với học máy, NWP là các hệ thống cốt lõi của ngành khí tượng học (như mô hình GFS, ECMWF hay WRF), sử dụng siêu máy tính để giải các phương trình vi phân nhiệt động lực học và thủy động lực học phức tạp, từ đó mô phỏng sự vận động của khí quyển để đưa ra dự báo thời tiết. Đầu ra dự báo từ các mô hình NWP này (thường được tích hợp qua các API dữ liệu như OpenMeteo) sẽ đóng vai trò là các tham số dẫn đường, hỗ trợ mô hình ST-XLinear suy luận ra nồng độ $PM_{2.5}$ tương lai.

Lưu ý về rò rỉ dữ liệu: Các nhóm từ 1 đến 7 chỉ sử dụng thông tin trong quá khứ thông qua các phép trễ hoặc thống kê trượt đã dịch chuyển. Nhóm 8 sử dụng thông tin tương lai nhưng đây là thiết kế có chủ đích để tích hợp năng lực của các hệ thống dự báo thời tiết vào mô hình dự báo ô nhiễm.

7. CHUẨN HÓA DỮ LIỆU

7.1. Nguyên tắc chung

Các mô hình dựa trên gradient descent yêu cầu dữ liệu đầu vào được chuẩn hóa để tránh hiện tượng các biến có thang đo lớn chi phối quá trình hội tụ. Tuy nhiên, do mỗi biến có đặc tính phân phối riêng biệt (lệch phải, chứa ngoại lai, hoặc có biên giá trị rõ ràng), đề tài áp dụng chiến lược chuẩn hóa chia theo 8 nhóm, trong đó mỗi nhóm sử dụng tổ hợp phương pháp phù hợp nhất. Để đảm bảo nguyên tắc chống rò rỉ dữ liệu, các bộ chuẩn hóa chỉ được khớp tham số duy nhất trên tập huấn luyện, sau đó mới thực hiện biến đổi cho toàn bộ dữ liệu.

7.2. Chi tiết chiến lược

Chi tiết về phương pháp chuẩn hóa và đặc tính phân phối của 8 nhóm biến được tổng hợp tại Bảng 2.9.

Bảng 2.9. Chiến lược chuẩn hóa dữ liệu theo 8 nhóm

#	Biến đại diện	Phương pháp	Đặc tính phân phối
1	CO , tiềm năng oxy hóa, tổng tải ô nhiễm	$\log_{1p}$ [25] $\rightarrow$ StandardScaler [28]	Lệch phải, độ lệch > 2 ; $\log_{1p}$ giảm độ lệch trước khi chuẩn hóa
2	SO_2 , nguy cơ sulfate ẩm, $PM_{2.5}$, các biến trễ $PM_{2.5}$	$\log_{1p}$ [25] $\rightarrow$ RobustScaler [29, 34]	Lệch phải và có ngoại lai thực; RobustScaler dùng trung vị/IQR
3	Lượng mưa, tiềm năng cuốn bụi	Cắt p99 [26] $\rightarrow \log_{1p}$ [25] $\rightarrow$ MinMaxScaler [27]	Nhiều giá trị 0 ($\approx 70\%$), đuôi phân phối dài
4	PM_{10} , NO_2	Cắt p99,5 [26] $\rightarrow \log_{1p}$ [25] $\rightarrow$ RobustScaler [34]	Ngoại lai ở mức vừa phải
5	O_3 , tốc độ gió, gió giật, độ lệch chuẩn trượt $PM_{2.5}$	RobustScaler [34]	Phân phối gần đối xứng nhưng có ngoại lai
6	Nhiệt độ, điểm sương, ổn định nhiệt, nhiệt độ đất	StandardScaler [28]	Phân phối gần chuẩn, ít ngoại lai
7	Độ ẩm, mây, độ ẩm đất	MinMaxScaler [27]	Có biên giá trị rõ ràng $[0, 100]$ hoặc $[0, 1]$
8	Cờ chất lượng, mã hóa tuần hoàn	Không chuẩn hóa	Nhị phân (0/1) hoặc đã nằm trong $[-1, 1]$

Nguyên tắc chọn phương pháp chuẩn hóa dựa trên đặc tính phân phối thống kê của từng nhóm biến. Các biến có phân phối lệch phải (độ lệch > 2) áp dụng phép biến đổi $\log(x+1)$ trước khi chuẩn hóa nhằm giảm độ lệch và ổn định phương sai [24]. Các biến chứa ngoại lai thực tế sử dụng RobustScaler vì phương pháp này dựa trên trung vị và khoảng tứ phân vị thay vì trung bình và độ lệch chuẩn, do đó ít bị ảnh hưởng bởi các giá trị cực đoan [29]. Các biến có biên giới rõ ràng (độ ẩm $\in [0, 100]$, mây $\in [0, 100]$, độ ẩm đất $\in [0, 1]$) sử dụng MinMaxScaler để ánh xạ về khoảng $[0, 1]$. Nhóm biến nhị phân và biến đã nằm trong $[-1, 1]$ không cần chuẩn hóa thêm.

7.3. Lưu trữ bộ chuẩn hóa

Mỗi trạm quan trắc được cấu hình một tệp lưu trữ bộ chuẩn hóa riêng biệt chứa toàn bộ các thông số đã khớp trên tập huấn luyện. Tệp này được sử dụng trong quá trình suy luận để thực hiện phép biến đổi ngược, đưa kết quả dự báo từ không gian chuẩn hóa về đơn vị đo gốc ($\mu g/m^3$).

8. CHIA TẬP DỮ LIỆU

8.1. Vấn đề với chia dữ liệu truyền thống

Phương pháp chia theo trình tự thời gian với tỷ lệ 70% huấn luyện, 15% kiểm định và 15% kiểm thử là cách tiếp cận phổ biến cho dữ liệu chuỗi thời gian. Tuy nhiên, phương pháp này tồn tại hạn chế đối với dữ liệu chất lượng không khí do tập kiểm thử thường chỉ chứa dữ liệu của một mùa cuối cùng. Điều này dẫn đến kết quả đánh

giá bị ảnh hưởng bởi thiên kiến mùa vụ và không phản ánh chính xác khả năng tổng quát hóa của mô hình qua các điều kiện thời tiết khác nhau trong năm.

8.2. Chiến lược chia theo khối ngày

Để giải quyết hạn chế trên, đề tài áp dụng chiến lược chia theo khối ngày tuần hoàn [35]. Cơ chế này thực hiện gán nhãn tập dữ liệu dựa trên vị trí của ngày trong một chu kỳ lặp lại theo công thức:

$$p = (t_{\text{hiện tại}} - t_{\text{cơ sở}}) \pmod{D} \quad (2.7)$$

Trong đó, D là độ dài của chu kỳ. Với mỗi chu kỳ, D_{train} ngày đầu tiên được gán cho tập huấn luyện, D_{val} ngày tiếp theo cho tập kiểm định và D_{test} ngày cuối cùng cho tập kiểm thử. Phương pháp này giúp đảm bảo mỗi tập dữ liệu đều chứa các đặc trưng của tất cả các tháng trong năm. Chi tiết các cấu hình được trình bày tại Bảng 2.10.

Bảng 2.10. Các cấu hình chia tập dữ liệu theo block-days

Cấu hình	D (ngày)	Train	Val	Test	Tỷ lệ xấp xỉ
block5	5	3	1	1	60/20/20
block7	7	5	1	1	71/14/14
block30	30	20	5	5	67/17/17

Toàn bộ 6 mô hình đều được huấn luyện song song trên cả 3 cấu hình phân tách (block5, block7, block30), tạo thành không gian thực nghiệm tổng cộng $6 \times 2 \times 5 \times 3 = 180$ tổ hợp (mô hình $\times$ vùng $\times$ horizon $\times$ block). Mục tiêu của việc huấn luyện đồng thời trên cả 3 cấu hình là đánh giá toàn diện ảnh hưởng của chiến lược chia dữ liệu đến hiệu năng dự báo, từ đó xác định đồng thời cấu hình block tối ưu và mô hình tốt nhất cho từng kịch bản dự báo cụ thể. Việc chốt mô hình và cấu hình block dựa trên kết quả so sánh định lượng (MAE, RMSE, R^2 , MAPE) trên cả 3 trục đánh giá (horizon, vùng, block) sẽ được trình bày chi tiết tại Chương 3.

9. HUẤN LUYỆN MÔ HÌNH

9.1. Tổng quan

Hệ thống huấn luyện triển khai 6 kiến trúc mô hình theo mức độ phức tạp tăng dần: XGBoost (gradient boosting trên dữ liệu bảng), XLinear (mạng tuyến tính với cơ chế gating), ESTGCN (tích chập đồ thị kết hợp LSTM), ST-XLinear (kiến trúc đề xuất tích hợp không gian), Ensemble (kết hợp trọng số tuyến tính), và iTransformer (Transformer đảo ngược kênh). Không gian thực nghiệm tổng thể bao gồm 2 cụm vùng (Bắc 6 trạm, Nam 6 trạm) $\times$ 5 tầm nhìn dự báo ($T + 1, T + 3, T + 6, T + 12, T + 24$ giờ) $\times$ 3 cấu hình block (block5, block7, block30).

Với mỗi cấu hình block, pipeline tạo ra bộ dữ liệu train/val/test riêng biệt, sau đó huấn luyện toàn bộ 6 mô hình trên bộ dữ liệu đó. Kết quả đánh giá trên cả 3 cấu hình được so sánh chéo tại Chương 3 để chốt mô hình tốt nhất và cấu hình block tối ưu tương ứng.

Bảng 2.11. Tổng quan 6 mô hình nghiên cứu

#	Mô hình	Loại	Dạng Input	Tham chiếu
1	XGBoost	Gradient Boosting	Tabular 1D	[15]
2	XLinear	Linear + Gating	Sequence 2D	[10]
3	ESTGCN	Graph + LSTM	Graph-Sequence 3D	[14]
4	ST-XLinear	XLinear + Spatial GCN	Graph-Sequence 3D	Đề xuất
5	Ensemble	Weighted Averaging	Kết hợp XLinear + ESTGCN	Đề xuất
6	iTransformer	Inverted Transformer	Sequence 2D	[11]

Bảng 2.11 cho thấy sự phân tầng rõ rệt về dạng dữ liệu đầu vào: XGBoost xử lý vector bảng phẳng 1D (mỗi mẫu là một dòng độc lập); XLinear và iTransformer xử lý chuỗi thời gian 2D (batch $\times$ steps $\times$ features); ESTGCN và ST-XLinear mở rộng thêm chiều không gian tạo thành tensor 3D (batch $\times$ steps $\times$ nodes $\times$ features). Ensemble kết hợp đầu ra của XLinear và ESTGCN để khai thác đồng thời thông tin thời gian và không gian.

Bảng 2.12. Đặc trưng đầu vào theo từng loại mô hình

Mô hình	Kích thước Input	Cửa sổ
XGBoost	($N_{samples}, \sim 230$ đặc trưng)	1 step
XLinear	(batch, 48, $N_{features}$)	48h
ESTGCN	(batch, 48, $N_{nodes}, N_{features}$)	48h
ST-XLinear	(batch, 48, $N_{nodes}, N_{features}$)	48h
iTransformer	(batch, 48, $N_{features}$)	48h

Sự khác biệt chính giữa các kiến trúc nằm ở cách tiếp cận dữ liệu đầu vào (Bảng 2.12). XGBoost xử lý từng bước thời gian một cách độc lập, bù trừ bằng vector đặc trưng dày đặc bao gồm lag, rolling và neighbor. Các mô hình deep learning (XLinear, ESTGCN, ST-XLinear, iTransformer) sử dụng cửa sổ trượt 48 giờ để khai thác phụ thuộc thời gian. Riêng ESTGCN và ST-XLinear bổ sung thêm chiều không gian $N_{nodes} = 6$ (số trạm trong mỗi cụm), cho phép học tương quan liên trạm thông qua ma trận kề.

9.2. Mô hình 1 – XGBoost

a) Cấu trúc dữ liệu Khác với các mô hình deep learning sử dụng cửa sổ trượt, XGBoost xử lý từng bước thời gian t dưới dạng một vector đặc trưng bảng phẳng, trong đó mỗi dòng đứng độc lập. Để bù trừ cho việc không khai thác trực tiếp cấu trúc chuỗi, mỗi mẫu đầu vào tích hợp một vector đặc trưng dày đặc gồm nhiều thành phần. **Đặc trưng cơ sở** bao gồm 134 biến chuẩn hóa tại thời điểm t (8 nhóm đã mô tả tại Mục 2.5). **Lag** $PM_{2.5}$ gồm 10 giá trị trễ tại các mốc $t - 1, t - 2, \dots, t - 72$ giờ. **Lag hóa chất** gồm 25 giá trị trễ của 5 biến ô nhiễm phụ ($PM_{10}, SO_2, NO_2, O_3, CO$).

Rolling $PM_{2.5}$ cung cấp 15 thống kê trượt (trung bình, độ lệch chuẩn và giá trị cực đại) trên 5 cửa sổ thời gian khác nhau. **Thời tiết tương lai** gồm 4 biến khí tượng dịch chuyển theo horizon dự báo. **Time encoding** bổ sung mã hóa tuần hoàn sin / cos cho thời gian. **Spatial neighbor** tích hợp 23 đặc trưng trung bình từ $K = 5$ trạm lân cận gần nhất (tính theo khoảng cách Haversine), cung cấp ngữ cảnh không gian. **Station one-hot** sử dụng 12 cột nhị phân mã hóa định danh trạm. Tổng số chiều vector đầu vào đạt khoảng 230+ đặc trưng.

Biến mục tiêu được xác định là $PM_{2.5}.shift(-horizon_h)$, tương ứng với giá trị tại thời điểm $t + horizon$. Hệ thống huấn luyện riêng biệt cho mỗi cặp (vùng $\times$ horizon $\times$ block), tổng cộng có 30 mô hình XGBoost được tạo ra.

b) Hệ siêu tham số và cấu hình huấn luyện Quá trình cấu hình tham số cho XGBoost tập trung vào việc ngăn chặn sự phát triển nhánh quá mức trên một không gian chiều đặc trưng lớn (đạt tới hơn 200 đặc trưng).

Bảng 2.13. Cấu hình siêu tham số của mô hình XGBoost

Siêu tham số	Giá trị thiết lập
<i>tree_method</i>	'hist'
<i>n_estimators</i>	300
<i>max_depth</i>	7
<i>min_child_weight</i>	5
<i>learning_rate</i>	0.08
<i>subsample</i>	0.8
<i>colsample_bytree</i>	0.8
<i>early_stopping_rounds</i>	30
<i>eval_metric</i>	'rmse'
<i>reg_alpha</i>	0.1
<i>reg_lambda</i>	1.0
<i>device</i>	'cuda/cpu'
<i>n_jobs</i>	-1
<i>random_state</i>	42

Lý do lựa chọn: Để xử lý hiệu quả không gian đầu vào lớn, hệ thống áp dụng kỹ thuật tách mốc theo biểu đồ gốc (*tree_method* = 'hist'), giúp giảm độ phức tạp tính toán tính bậc thấp. Giá trị *n_estimators* = 300 biểu diễn sức chứa mạng vừa đủ cho tín hiệu dự báo ngắn hạn mà không làm bùng nổ thời gian huấn luyện. Tốc độ học (*learning_rate* = 0.08) cung cấp nhịp hội tụ mục tiêu trơn tru. Giới hạn độ sâu phân nhánh *max_depth* = 7 kết hợp với ngưỡng kiểm duyệt nhánh lá *min_child_weight* = 5 thiết lập cấu trúc cây học sâu vừa phải, triệt tiêu sự phân hoá học vệt. Việc chỉ định tỷ lệ lấy mẫu ngẫu nhiên *subsample* = 0.8 và *colsample_bytree* = 0.8 tác động như cơ chế Dropout cục bộ. Đặc biệt, các hệ số điều chuẩn L1 (*reg_alpha* = 0.1) và L2 (*reg_lambda* = 1.0) đóng

vai trò kiểm soát phần dư trọng số, ép phân cấp cây chia đều cho các nhóm đặc trưng rời rạc. Vòng lặp quan sát $early_stopping_rounds = 30$ xác lập cơ chế dừng thông minh khi hàm lỗi mục tiêu ($eval_metric = 'rmse'$) trở nên bão hòa. Khối vận hành thuật toán cũng khai thác triệt để sức mạnh phần cứng bằng khả năng điều hướng tính qua $device = 'cuda/cpu'$ cùng giới hạn cấp phát đa luồng $n_jobs = -1$ để song song hóa tối đa quy trình huấn luyện, cùng cố tính chặt chẽ cấu trúc bằng hằng số tái lập sinh ngẫu nhiên $random_state = 42$.

9.3. Mô hình 2 — XLinear

a) Lựa chọn đặc trưng (Feature Selection) Sự bùng nổ chiều đặc trưng thường làm phân tán cơ chế công thời gian của bộ mạng dự báo. Để gia tăng tỷ lệ tín hiệu hữu ích, bước chọn lọc định lượng được thực thi ngay trên dữ liệu đầu vào: loại bỏ hoàn toàn các loại biến khí tượng có hệ số tương quan tuyến tính Pearson tuyệt đối thấp ($corr_threshold = 0.05$) đối với phân phối $PM_{2.5}$. Giai đoạn này cũng chủ động gạt bỏ các biến cò ròi rạc mang tính điểm chu kỳ (như cò tình trạng lỗi thiết bị, dấu ngắt cuối tuần) để duy trì tính liên tục của hàm số luân chuyển, ngăn trạng thái cấu trúc dữ liệu thừa thớt kích hoạt suy biến nội tại chuỗi hàm tính của deep learning.

b) Hệ siêu tham số và cấu hình huấn luyện Thuật toán hồi quy quyền tính lai tập trung khai thác tính quy nạp qua hệ siêu tham số trọng điểm nhắm tới việc triệt tiêu đạo hàm bùng nổ và hàm mất mát Asymmetric.

Bảng 2.14. Cấu hình siêu tham số của mô hình XLinear

Siêu tham số	Giá trị thiết lập
seq_len	48
$pred_len$	1
enc_in	Tùy biến ($N_{features}$)
$features$	'MS'
d_model	128 (Bắc) / 256 (Nam)
t_ff	256 (Bắc) / 512 (Nam)
c_ff	256 (Bắc) / 512 (Nam)
$embed_dropout$	0.1
$head_dropout$	0.1
$t_dropout$	0.1
$c_dropout$	0.1
$usenorm$	False
$learning_rate$	5×10^{-4}
$weight_decay$	10^{-4}
T_max	20
eta_min	10^{-5}
$delta$	1.0
$alpha$	2.0
$epochs$	20
$batch_size$	128
$patience$	5
$corr_threshold$	0.05
$gradient_clip$	1.0

Lý do lựa chọn: Hành vi phân phối của $PM_{2.5}$ thể hiện độ lệch phải cực đoan, do đó lỗi Asymmetric Huber thiết lập $delta = 1.0$ và biên sai lệch rủi ro $alpha = 2.0$ cường chế mức phạt gấp đôi đối với các điểm mẫu dự đoán rủi ro thiếu. Về khối cấu trúc, chuỗi cửa sổ truy vết $seq_len = 48$ ánh xạ ra mục tiêu suy diễn cố định tại

$pred_len = 1$ (dạng đa biến quy về đơn biến $features = 'MS'$), đi kèm tổng thể enc_in biến động trượt theo số lượng đặc trưng giữ lại. Thuộc tính $usenorm = False$ cũng được khóa lại do dữ liệu thực nghiệm đã trải qua bước chuẩn hóa mạnh. Kích cỡ lớp mạng d_model được điều phối cục bộ mở rộng ở miền Nam (256 so với 128 ở miền Bắc) thông qua tầng phân giải t_ff và c_ff tương xứng, giúp thu nạp những dao động nhỏ lẻ. Cấp độ phân rã $embed_dropout$, $head_dropout$, $t_dropout$ và $c_dropout$ (đều đặt giá trị 0.1) cùng lô $batch_size = 128$ hỗ trợ đắc lực bình chuẩn hóa gradient. Cuối cùng, thuật toán AdamW vận hành linh hoạt ở $learning_rate = 5 \times 10^{-4}$ kết hợp $weight_decay = 10^{-4}$, đi cùng chu kỳ giảm tốc qua $T_max = 20$ với đáy trần $eta_min = 10^{-5}$ để kìm hãm mạng tĩnh không phân rã vô hạn; tập dữ liệu theo đó nội suy qua $epochs = 20$ vòng (ngắt sớm $patience = 5$) dưới sự kiểm soát bộ chặn phân kỳ $gradient_clip = 1.0$.

9.4. Mô hình 3 — ESTGCN

a) Liên kết ma trận đồ thị Truyền thông điệp qua mạng học sâu chia sẻ phụ thuộc chặt chẽ vào độ kết dính vật lý của ma trận kề lưới (A). Đặc trưng kết nối không gian giữa các trạm thực địa được ánh xạ thông qua khoảng cách vòng lớn bán kính cầu (Haversine). Biến đổi Gaussian áp đặt hệ số phi tuyến để làm suy giảm theo hàm đồ thị mũ những kết nối vượt quá dải tương đối hợp lệ:

$$A(i, j) = \exp\left(-\frac{d^2(i, j)}{\sigma^2}\right), \quad \sigma^2 = \text{std}(d[d > 0])^2 \quad (2.8)$$

Phép chuẩn hóa hàng $A \leftarrow A / \sum A$ ngay sau đó điều phối tổng lưu lượng thông điệp xuất phát từ một hệ lưới trạm quy tụ hoàn toàn về ngưỡng biểu diễn không lấp đầy 1.0. Thuộc tính này chặn đứng nguy cơ phát tán số nguyên vector khi thực thi tập tích chập liên hoàn dọc theo tầng cấu trúc sâu.

b) Hệ siêu tham số và dự báo nhiều bước (Multi-step Output) Khác với quy trình định vị đơn điểm, ESTGCN phải đảm đương năng lực phóng chiếu luồng tập thông tin toàn cảnh $T + 24$ song song. Do đó cấu hình sẽ chú trọng tăng áp hàm lượng bộ nhớ lưu đồ thị tổng quát.

Bảng 2.15. Cấu hình siêu tham số của mô hình ESTGCN

Siêu tham số	Giá trị thiết lập
seq_len	48
$pred_len$	24
out_feat	10
$lstm_units$	64
$combination_type$	'concat'
$sigma2$	$\text{std}(d)^2$
$learning_rate$	10^{-3}
$weight_decay$	10^{-4}
$delta$	1.0
$epochs$	100
$batch_size$	256
$patience$	15

Lý do lựa chọn: Cấu trúc ESTGCN mô phỏng phóng chiếu đồng thời phương trình kỳ vọng tương lai thông qua cửa sổ thời gian lịch sử $seq_len = 48$ ánh xạ ra mốc đích $pred_len = 24$ điểm. Ở cấp độ GCN không gian,

các nút đồ thị được khai thác và tính tiến dọc kênh biểu kiến $out_feat = 10$, kết nối với số nơ-ron trạng thái $lstm_units = 64$ cung cấp khối lượng bộ nhớ tính vừa phản ứng tốt biến thiên chuỗi, vừa ngăn luân chuyển quá tải. Tại vòng giao tiếp này, phương án $combination_type = 'concat'$ hỗ trợ tích hợp bảo lưu toàn vẹn nguyên gốc đặc trưng liên tuyến đồ thị (dưới hệ quy chuẩn phương sai tính tiến $\sigma^2 = \text{std}(d)^2$) thay vì cộng dồn làm mờ tín hiệu. Việc ôm đồm dữ liệu buộc cơ cấu thiết lập lô ma trận diện rộng $batch_size = 256$ điều hành mảng bức tranh tính không gian chồng lấp. Mô hình yêu cầu chu kỳ chạy quy mô dài hạn $epochs = 100$ luôn được bảo vệ bởi khóa hãm sớm $patience = 15$. Thuật toán học AdamW vận hành nhịp nhảy độ dốc $learning_rate = 10^{-3}$, đồng thời cường chế hạn mức phương sai qua trọng số $weight_decay = 10^{-4}$. Biên phân hạn mất mát HuberLoss tại điểm nê $\delta = 1.0$ tiếp tục duy trì sức cân bền vững kháng nhiễu các hạt lưu lượng ngoại vi bất ổn phân phối.

9.5. Mô hình 4 — ST-XLinear

a) Thích ứng dung lượng động Hệ quả từ độ trễ khuếch tán không khí khổng chế tỷ lệ truyền dẫn thông tin gốc trên biên độ nhiễu loạn. Ở các mốc tương lai xa (như vạch trích xuất $T + 24$ giờ), thông tin hạt nhân bị nhiễu do luồng gió động, đòi hỏi bộ nhớ lưu chuyển quy mô mạng ẩn (d_model, c_ff) phải mở rộng dung lượng bù trừ (tăng gấp đôi khối tính từ cấu hình chuẩn cơ sở) nhằm tích lũy biểu diễn dữ liệu diện rộng. Đối lập với cường độ dao động dài lớn khu vực thủ đô miền Bắc, các vùng liên trạm miền Nam với biên độ dao động mỏng có nguy cơ bỏ sót các đột biến đứt gãy điểm lẻ loi, kéo theo việc tham số ma trận học tập cũng bắt buộc gia tăng số lượng kênh tham chiếu chuyên biệt.

b) Hệ siêu tham số và CombinedLoss Sự thích ứng bộ lọc không gian với biến trở gió buộc mạng thần kinh cấu trúc đề xuất phải mở khóa một năng lượng lưu chuyển sâu mới, thể hiện ở các hệ số điều tiết Bảng 2.16.

Bảng 2.16. Cấu hình siêu tham số của mô hình ST-XLinear

Siêu tham số	Giá trị thiết lập
seq_len	48
$pred_len$	1
d_model	48 ~ 128 (tùy vùng/horizon)
t_ff	96 ~ 256 (tùy vùng/horizon)
c_ff	96 ~ 256 (tùy vùng/horizon)
$dropout$	0.2
$alpha_graph$	0.5
$learning_rate$	5×10^{-4}
$weight_decay$	5×10^{-4}
T_max	50
η_{min}	10^{-5}
mse_w	0.7
δ	1.0
$epochs$	50
$batch_size$	64
$patience$	10

Lý do lựa chọn: Lỗi theo dõi chuỗi thời gian được thiết lập cố định với phân đoạn lịch sử $seq_len = 48$ nhằm chiết xuất cấu hình điểm ngắt độc lập $pred_len = 1$ cho từng phiên bản mô hình dự báo. Chỉ số biên cấu

trúc giải mã d_model được điều tiết động tăng dần từ độ nén gọn (48) tại mốc gần $T + 1$ lên cực đại (128) ở không gian trễ $T + 24$, kéo theo sự nở rộng không gian ngầm t_ff và c_ff tương xứng. Trong quá trình đồ thị hóa liên trạm, $alpha_graph = 0.5$ đóng vai trò cân bằng một trạng thái dung hòa thiết yếu giữa ma trận địa lý vật lý thuần túy và luồng đối lưu gió định hướng. Hệ cản $dropout = 0.2$ cùng kiểm soát độ hao mòn $weight_decay = 5 \times 10^{-4}$ giữ mạng não không rơi vào khủng hoảng quá khớp. Mức tập khối lô nhỏ $batch_size = 64$ đẩy tỷ lệ vòng nội suy theo giới hạn quy trình $epochs = 50$ nhằm tăng mật độ lấy mẫu GCN. Về chiến lược hàm mất mát, cơ chế CombinedLoss ấn định hệ phân chia sức nặng cụ thể: $mse_w = 0.7$ nghiêng phần lớn quyền lực cho MSE chặn khớp xu thế chính, nhường lại 30% cho HuberLoss với khớp uốn $delta = 1.0$ neo chống dị biệt vỡ tải. Mạch lan truyền tối ưu AdamW phân tách khởi chạy tiến độ ở $learning_rate = 5 \times 10^{-4}$, được hãm chậm qua phễu giảm xóc Cosine Annealing ($T_max = 50$, biên trần đáy $eta_min = 10^{-5}$), hợp chuẩn quy chế khóa đứt lặp rỗng $patience = 10$ để liên kết được mài mòn mịn màng nhưng vững chãi tuyệt đối trước đạo hàm cực biên.

9.6. Mô hình 5 — Ensemble

a) Công thức vô hướng tĩnh Cơ cấu Ensemble không tồn tại tính chất tối ưu thuật toán truyền ngược gradient. Phương tiện duy nhất phụ thuộc vào việc định tuyến tổng hợp xác suất hai vectơ đầu ra thông qua hàm tuyến tính tích hợp:


$$\hat{y} = \alpha \times \hat{y}_{\text{XLinear}} + (1 - \alpha) \times \hat{y}_{\text{ESTGCN}}, \quad \alpha \in [0, 1] \tag{2.9}$$

b) Phân bổ siêu tham số α bằng thuật toán duyệt Giao thức đi tìm hệ số chấp điểm dự báo α được thể chế hóa theo tiêu chuẩn lưới phân loại không gia tăng chi phí học thuật trên bộ ma trận phân cứng.

Bảng 2.17. Cấu hình tham số khai phá Grid Search của Ensemble

Siêu tham số	Giá trị thiết lập
$alpha$	0.00 $\rightarrow$ 1.00
$step$	0.01
$metric$	'MAE'

Lý do lựa chọn: Trọng điểm tìm kiếm đánh giá vào MAE ($metric = 'MAE'$) đem lại thước chuẩn trung bình hóa để chống sai số tốt nhất. Với chỉ số lưới dò $step = 0.01$, tạo ra quy mô ma trận phân mảnh cực kỳ chi tiết, sinh ra 100 kịch bản cân bằng cho $alpha$ trong phương pháp phối hợp mà không tổn động độ trễ tính toán. Sự đền bù chéo hoàn hảo ở không gian Grid Search khắc phục trực tiếp thiết kế thiếu liên kết của XLinear qua sức mạnh bao phủ cụm diện của ESTGCN trên tập Validation. Cấu trúc độc lập tuyệt đối này ngăn ngừa tình trạng nghẽn cổ chai luồng huấn luyện, rút gọn năng lực máy tính.



Hình 2.4. Quy trình vận hành trực tiếp của Ensemble

Sự kết hợp giá trị diễn ra độc lập với quá trình tối ưu chiều sâu, tiết giảm chu kỳ huấn luyện ảo.

Cách tiếp cận này tận dụng sự hỗ trợ giữa khả năng học các mẫu thời gian của XLinear và các tương quan không gian của ESTGCN với chi phí tính toán thấp.

9.7. Mô hình 6 — iTransformer

a) Chỉ định chuỗi Variate linh hoạt Để kiểm soát khối lượng tính toán khi tương tác đa biến, phương pháp đảo ngược trục biến số cho phép thiết lập hệ tự tập trung (Self-Attention) tính toán dọc theo hệ số học cục bộ không gian N_{var} thay vì theo diễn biến trục thời gian L . Bằng cách phân định triệt để khối biến môi trường nền đồng nhất và cụm biến thông số biến động vi mô của từng mốc trạm tự trị, sức mạnh định lượng của mạng tối giản độ phức tạp tính toán chéo giảm sâu từ $O(L^2)$ xuống định khung an toàn biên hẹp $O(N_{var}^2)$. Việc loại bỏ hoàn toàn các dải thông tin môi trường khí quyển khỏi cơ chế truy vết mục tiêu học tập cũng chốt chặn định tuyến trạng thái tối ưu chỉ điều chuyển xoay quanh đích duy nhất $PM_{2.5}$.

b) Hệ siêu tham số và Thích ứng không gian Kiến trúc attention chéo kênh lật tỷ lệ Transformer tự do buộc phải quản lý giới hạn để không gây chồng chéo thông tin. Bảng 2.18 tổng hợp các quy định thiết yếu được áp dụng.

Bảng 2.18. Cấu hình siêu tham số của mô hình iTransformer

Siêu tham số	Giá trị thiết lập
<i>seq_len</i>	48
<i>pred_len</i>	1
<i>enc_in</i>	Tùy biến ($N_{variables}$)
<i>d_model</i>	64 ~ 128
<i>n_heads</i>	4
<i>e_layers</i>	2 (Bắc) / 2 ~ 3 (Nam)
<i>d_ff</i>	128 ~ 256
<i>activation</i>	'gelu'
<i>dropout</i>	0.15
<i>use_norm</i>	True
<i>learning_rate</i>	5×10^{-4}
<i>weight_decay</i>	10^{-4}
<i>T_max</i>	50
<i>eta_min</i>	10^{-5}
<i>alpha</i>	0.7
<i>epochs</i>	50
<i>batch_size</i>	64
<i>patience</i>	10

Lý do lựa chọn: Chống chọi với hao mòn năng lượng thông tin tương lai, chuỗi đầu vào $seq_len = 48$ được ngưng đọng định vị chính xác độ xuất $pred_len = 1$. Tại đây số lượng kênh biến dữ liệu enc_in được thả nổi động để phục vụ nguyên lý tính toán lật ngược Inverted. Cụ thể, khối não bộ Transformer buộc phải liên tục quy đổi dạng d_model dao động từ 64 đến khung chỉ phối 128 (ở tầm nhìn $T + 24$), đi cùng sự mở rộng không gian tính d_ff tỷ lệ thuận lên 256. Hệ thống vận hành đặc thù trơn tru nhờ hàm kích hoạt uốn mượt $activation = 'gelu'$ và hệ khóa nhiễu luồng nội phân RevIN cài đặt chế vận hành tự động $use_norm = True$. Mật độ lớp

ẩn chia mảnh phân nhánh $n_heads = 4$, xen kẽ độ sâu số tầng $e_layers = 3$ chỉ định áp riêng cho miền Nam chính là phác đồ can thiệp triệt để khi sự khan hiếm dao động mùa xuất hiện ở vùng này. Lưới vi mô AdamW điều chỉnh nhịp phân tán tại mức $batch_size = 64$ trên dòng hoạt động $epochs = 50$, qua đó bề hướng mốc trượt tại $learning_rate = 5 \times 10^{-4}$ đi kèm chấn lưu trọng số $weight_decay = 10^{-4}$. Định tuyến suy giảm tuần hoàn Cosine Annealing điều chỉnh nhịp phễu thu nhỏ ở mức $T_max = 50$ đổ xuống đáy $eta_min = 10^{-5}$, kết hợp với phân rã thả roi $dropout = 0.15$ và rào cản quá khớp $patience = 10$ giúp kìm hãm mạch hội tụ không sụp đổ cực đoan. Năng lượng mất mát cuối cùng kết tủa thành liên minh Combined Loss: chốt lấy trọng lực $alpha = 0.7$ từ điểm nảy siêu kháng sai HuberLoss để kéo tỷ lệ 0.3 dự phòng dư lại về L1Loss.

10. ĐÁNH GIÁ MÔ HÌNH

10.1. Nguyên tắc đánh giá

Kết quả dự báo của mỗi mô hình được đánh giá trên **tập kiểm thử** — tập dữ liệu mà mô hình chưa tiếp xúc trong quá trình huấn luyện và tinh chỉnh. Trước khi tính toán các chỉ số, đầu ra dự báo được biến đổi ngược từ không gian chuẩn hóa về đơn vị gốc ($\mu g/m^3$) bằng bộ chuẩn hóa đã lưu trữ tại giai đoạn tiền xử lý, đảm bảo các chỉ số phản ánh chính xác sai số thực tế.

10.2. Không gian thực nghiệm

Đánh giá được thực hiện riêng biệt cho từng tổ hợp thuộc không gian 4 chiều (Bảng 2.19):

Bảng 2.19. Không gian thực nghiệm đánh giá mô hình

Chiều	Số giá trị	Chi tiết
Mô hình	6	XGBoost, XLinear, ESTGCN, ST-XLinear, Ensemble, iTransformer
Vùng	2	Cụm Bắc (6 trạm) và Cụm Nam (6 trạm)
Tầm nhìn dự báo	5	$T + 1$, $T + 3$, $T + 6$, $T + 12$, $T + 24$ giờ
Cấu hình block	3	block5 (chu kỳ 5 ngày), block7 (7 ngày), block30 (30 ngày)

Chiều mô hình gồm 6 kiến trúc đã trình bày tại Mục trước, bao phủ từ mô hình cây quyết định (XGBoost) đến các mô hình học sâu đa dạng (XLinear, ESTGCN, ST-XLinear, iTransformer) và phương pháp kết hợp (Ensemble).

Chiều vùng phân tách theo đặc trưng địa lý–khí hậu: Cụm Bắc với 6 trạm tại khu vực miền Bắc có mùa đông lạnh và ô nhiễm cao, Cụm Nam với 6 trạm tại khu vực phía Nam có khí hậu nhiệt đới ổn định hơn. Mỗi vùng được huấn luyện mô hình riêng biệt.

Chiều tầm nhìn dự báo bao gồm 5 mốc horizon: $T + 1$ giờ (ngắn hạn), $T + 3$ giờ, $T + 6$ giờ (trung hạn), $T + 12$ giờ và $T + 24$ giờ (dài hạn). Tầm nhìn dự báo càng xa, độ khó dự báo càng tăng do mất tương quan thời gian, cho phép đánh giá khả năng ngoại suy của từng mô hình.

Chiều cấu hình block gồm 3 chiến lược phân tách dữ liệu: block5 (chu kỳ 5 ngày, tỷ lệ 60/20/20), block7 (chu kỳ 7 ngày, tỷ lệ 71/14/14) và block30 (chu kỳ 30 ngày, tỷ lệ 67/17/17). Việc huấn luyện đồng thời trên cả 3 cấu hình nhằm đánh giá ảnh hưởng của chiến lược chia dữ liệu đến hiệu năng, từ đó xác định đồng thời mô hình tốt nhất và cấu hình block tối ưu.

10.3. Các chỉ số đánh giá

Đề tài sử dụng 4 chỉ số định lượng đã trình bày chi tiết tại Mục 1.5 (Chương 1): MAE, RMSE, R^2 và MAPE. Bốn chỉ số này được tính toán trên dữ liệu đã biến đổi ngược về đơn vị gốc ($\mu g/m^3$), đảm bảo phản ánh chính xác sai số thực tế. Kết quả đánh giá định lượng trên 180 tổ hợp thực nghiệm, phân tích so sánh chéo giữa các mô hình trên cả 4 chiều, và quy trình chốt mô hình tối ưu sẽ được trình bày tại Chương 3.

11. TRIỂN KHAI ỨNG DỤNG (DEPLOYMENT)

11.1. Tổng quan kiến trúc triển khai

Sau khi hoàn tất huấn luyện và đánh giá, mô hình đạt hiệu năng tốt nhất được triển khai thành ứng dụng web giám sát và dự báo chất lượng không khí theo thời gian thực. Hệ thống triển khai bao gồm hai thành phần chính: module suy luận xử lý logic dự báo, và giao diện người dùng xây dựng trên nền tảng Streamlit.

Luồng xử lý khi người dùng yêu cầu dự báo diễn ra theo 4 bước tuần tự: (1) đọc dữ liệu lịch sử đã làm sạch của trạm được chọn; (2) xây dựng vector đặc trưng từ dữ liệu lịch sử thông qua module suy luận; (3) thực hiện dự báo bằng mô hình đã lưu trữ; và (4) biến đổi ngược kết quả về đơn vị $\mu g/m^3$ trước khi hiển thị.

11.2. Module suy luận

Module suy luận đảm nhận toàn bộ logic dự báo, được thiết kế tách biệt khỏi giao diện để đảm bảo khả năng tái sử dụng. Quy trình xử lý bao gồm ba giai đoạn.

Giai đoạn 1 — Xây dựng đặc trưng. Từ dữ liệu lịch sử đã làm sạch, module tái tạo vector đặc trưng tương đương với quá trình huấn luyện, bao gồm: 134 đặc trưng cơ sở tại thời điểm t , các giá trị trễ $PM_{2.5}$ tại 10 mốc ($t - 1$ đến $t - 72$), trễ hóa chất của 5 biến ô nhiễm phụ, thống kê trượt trên nhiều cửa sổ thời gian, mã hóa tuần hoàn thời gian, và thông tin thời tiết tương lai dịch chuyển theo tầm nhìn dự báo. Đặc trưng không gian được thiết lập giá trị mặc định do hạn chế về dữ liệu thời gian thực liên trạm.

Giai đoạn 2 — Nạp mô hình và dự báo. Mô hình được nạp từ tệp tuần tự hóa tương ứng với cụm vùng (Bắc/Nam) và tầm nhìn dự báo. Cơ chế bộ nhớ đệm đảm bảo mô hình chỉ được nạp một lần, giảm thời gian phản hồi cho các yêu cầu dự báo tiếp theo.

Giai đoạn 3 — Biến đổi ngược. Kết quả dự báo trong không gian chuẩn hóa được chuyển đổi ngược về đơn vị gốc ($\mu g/m^3$) bằng bộ chuẩn hóa đã lưu trữ tại giai đoạn tiền xử lý, đảm bảo giá trị hiển thị có ý nghĩa vật lý trực tiếp.

11.3. Giao diện người dùng (Web UI)

Ứng dụng web được phát triển trên nền tảng Streamlit, sử dụng giao diện light mode với thiết kế glassmorphism. Giao diện bao gồm các thành phần chính sau.

a) Bảng điều khiển (Sidebar). Cho phép người dùng lựa chọn trạm quan trắc từ danh sách 12 trạm (6 Cụm Bắc + 6 Cụm Nam), hiển thị thông tin trạm (địa chỉ, tọa độ GPS, phân cụm) và chọn chỉ số ô nhiễm cần theo dõi.

b) Khu vực giám sát. Hiển thị 5 thẻ KPI (PM2.5, PM10, nhiệt độ, độ ẩm, tốc độ gió) từ dữ liệu mới nhất, kèm nhãn AQI động theo ngưỡng Việt Nam/WHO. Biểu đồ lịch sử 24 giờ dạng đường spline với 3 đường ngưỡng AQI tham chiếu, và 6 sparkline theo dõi xu hướng các chỉ số ô nhiễm.

c) Khu vực dự báo. Hiển thị kết quả dự báo $PM_{2.5}$ tại 5 mốc horizon ($T + 1, T + 3, T + 6, T + 12, T + 24$ giờ) dưới dạng thẻ card màu AQI động. Biểu đồ nối tiếp thẻ hiện lịch sử 24 giờ (đường liền) và 5 điểm dự báo (đường đứt nét), phân cách bởi đường dọc “Hiện tại”.

d) Công nghệ trực quan hóa. Toàn bộ biểu đồ sử dụng thư viện Plotly với chế độ tương tác (hover, zoom), nền trong suốt đồng bộ với dark theme. CSS tùy chỉnh ghi đè giao diện mặc định của Streamlit để đảm bảo tính nhất quán về mặt thẩm mỹ.

CHƯƠNG 3

KẾT QUẢ VÀ THẢO LUẬN

1. KẾT QUẢ TỔNG HỢP

Sáu mô hình — XGBoost, XLinear, iTransformer, E-STGCN, ST-XLinear và Ensemble — được đánh giá đồng thời trên 30 cấu hình thí nghiệm, bao gồm năm tầm nhìn dự báo ($T+1, T+3, T+6, T+12, T+24$ giờ), ba chiến lược chia dữ liệu (block 5, block 7, block 30 ngày) và hai cụm vùng địa lý (North gồm 6 trạm miền Bắc, South gồm 6 trạm miền Nam). Bốn chỉ số MAE, RMSE, R^2 và MAPE được sử dụng song song nhằm đánh giá ở nhiều khía cạnh: sai số tuyệt đối trung bình, mức độ nhạy cảm với giá trị cực đoan, tỷ lệ phương sai được giải thích, và sai số tương đối theo phần trăm. Bảng 3.1 đến Bảng 3.6 trình bày toàn bộ kết quả đo lường.

Bảng 3.1. Kết quả đánh giá trên block 5 — North

Mô hình	T+1				T+6				T+24			
	MAE	RMSE	R^2	MAPE	MAE	RMSE	R^2	MAPE	MAE	RMSE	R^2	MAPE
XGBoost	6,31	12,98	0,83	22,91	10,99	18,70	0,64	40,50	12,67	20,34	0,54	49,25
XLinear	6,51	13,67	0,81	26,88	14,28	23,38	0,43	63,85	17,29	26,99	0,25	81,96
iTransformer	6,57	14,68	0,78	23,78	14,46	24,18	0,40	55,51	17,79	27,99	0,19	72,91
E-STGCN	9,34	17,37	0,68	32,99	14,02	23,89	0,41	52,99	17,15	27,70	0,21	69,34
ST-XLinear	6,57	13,89	0,80	24,03	13,56	23,21	0,44	51,81	16,40	26,98	0,25	66,71
Ensemble	6,49	13,67	0,81	26,82	14,24	23,31	0,44	64,80	17,08	26,64	0,27	85,29

Bảng 3.2. Kết quả đánh giá trên block 5 — South

Mô hình	T+1				T+6				T+24			
	MAE	RMSE	R^2	MAPE	MAE	RMSE	R^2	MAPE	MAE	RMSE	R^2	MAPE
XGBoost	4,04	15,74	0,99	21,25	8,18	36,54	0,93	36,76	13,16	71,10	0,73	54,26
XLinear	5,47	28,63	0,96	29,65	12,46	59,43	0,83	69,99	22,67	105,66	0,45	116,00
iTransformer	5,45	32,53	0,95	24,72	14,28	71,81	0,75	58,82	21,77	102,76	0,48	104,82
E-STGCN	8,79	42,31	0,91	33,35	14,17	70,86	0,75	61,53	21,74	103,06	0,48	91,53
ST-XLinear	5,54	30,96	0,95	24,82	13,21	66,67	0,78	61,92	22,72	103,09	0,48	83,58
Ensemble	5,49	28,70	0,96	29,72	12,47	59,53	0,83	69,94	22,64	105,35	0,45	116,97

Bảng 3.3. Kết quả đánh giá trên block 7 — North

Mô hình	T+1				T+6				T+24			
	MAE	RMSE	R^2	MAPE	MAE	RMSE	R^2	MAPE	MAE	RMSE	R^2	MAPE
XGBoost	6,17	12,66	0,81	22,26	10,93	19,12	0,61	39,13	12,87	21,24	0,52	51,45
XLinear	6,37	13,29	0,79	26,94	13,45	21,55	0,43	58,83	17,73	26,12	0,15	87,83
iTransformer	6,45	13,99	0,76	23,94	13,92	22,62	0,38	55,64	18,50	27,50	0,06	84,61
E-STGCN	8,90	15,73	0,70	32,08	13,49	22,33	0,39	51,69	17,05	26,39	0,13	69,47
ST-XLinear	6,39	13,27	0,79	23,81	13,02	21,67	0,43	51,32	16,51	25,63	0,18	69,95
Ensemble	6,35	13,28	0,79	26,84	13,40	21,50	0,44	59,89	17,26	25,72	0,18	89,22

Bảng 3.4. Kết quả đánh giá trên block 7 — South

Mô hình	T+1				T+6				T+24			
	MAE	RMSE	R^2	MAPE	MAE	RMSE	R^2	MAPE	MAE	RMSE	R^2	MAPE
XGBoost	4,21	14,51	0,99	22,26	8,35	32,96	0,94	35,22	11,42	56,88	0,73	47,67
XLinear	5,95	32,33	0,95	30,42	13,85	66,08	0,78	70,78	26,45	126,08	0,21	120,80
iTransformer	5,18	33,50	0,94	25,64	14,33	75,44	0,72	66,08	25,41	123,53	0,24	109,44
E-STGCN	7,73	37,26	0,93	32,67	13,99	73,19	0,73	63,07	24,53	116,78	0,32	97,52
ST-XLinear	5,52	31,37	0,95	25,32	16,00	79,68	0,68	64,07	24,00	111,18	0,39	84,45
Ensemble	6,03	32,05	0,95	32,53	13,88	66,25	0,78	70,85	26,45	126,08	0,21	120,80

Bảng 3.5. Kết quả đánh giá trên block 30 — North

Mô hình	T+1				T+6				T+24			
	MAE	RMSE	R^2	MAPE	MAE	RMSE	R^2	MAPE	MAE	RMSE	R^2	MAPE
XGBoost	6,42	13,87	0,81	21,51	10,67	18,77	0,66	37,82	12,78	22,12	0,55	45,03
XLinear	5,88	13,38	0,82	21,97	12,46	21,25	0,56	50,87	14,91	24,79	0,40	63,53
iTransformer	5,96	14,25	0,80	20,04	12,07	21,38	0,55	41,26	15,05	24,82	0,40	56,91
E-STGCN	9,14	17,02	0,72	31,47	12,53	21,78	0,53	45,03	14,34	24,58	0,41	52,83
ST-XLinear	5,84	13,55	0,82	19,49	11,81	21,86	0,53	40,72	14,37	25,42	0,37	49,51
Ensemble	5,88	13,39	0,82	21,88	12,41	21,16	0,56	51,41	14,91	24,84	0,40	64,04

Bảng 3.6. Kết quả đánh giá trên block 30 — South

Mô hình	T+1				T+6				T+24			
	MAE	RMSE	R^2	MAPE	MAE	RMSE	R^2	MAPE	MAE	RMSE	R^2	MAPE
XGBoost	4,40	23,60	0,97	21,01	8,38	40,04	0,92	36,60	17,68	96,61	0,55	44,40
XLinear	4,10	23,49	0,97	24,81	11,51	54,31	0,84	55,78	16,85	89,47	0,57	93,48
iTransformer	4,42	29,41	0,95	20,17	10,81	63,91	0,78	50,26	15,33	85,26	0,61	65,49
E-STGCN	8,37	47,00	0,88	31,44	11,78	63,27	0,79	51,69	15,80	85,18	0,61	63,45
ST-XLinear	4,33	23,43	0,97	20,59	11,41	54,02	0,84	51,31	19,00	91,65	0,55	65,35
Ensemble	4,12	23,55	0,97	24,91	11,53	54,42	0,84	55,90	16,81	88,96	0,58	94,65

Từ sáu bảng kết quả, ba xu hướng được quan sát xuyên suốt toàn bộ không gian thí nghiệm.

Xu hướng thứ nhất được quan sát là hiệu suất suy giảm đơn điệu khi tầm nhìn dự báo mở rộng, tuy nhiên tốc độ suy giảm khác nhau đáng kể giữa các kiến trúc. Trên cả sáu bảng, MAE và RMSE tăng liên tục từ $T+1$ đến $T+24$, đồng thời R^2 giảm dần — tuân theo đặc trưng cơ bản của bài toán dự báo chuỗi thời gian, khi thông tin từ quá khứ bị suy giảm theo khoảng cách tới mốc dự báo. Tuy nhiên, biên độ suy giảm giữa các mô hình dao động lớn: tại block 7 North, chênh lệch MAE giữa $T+1$ và $T+24$ của XGBoost là $6,70 \mu g/m^3$ (từ 6,17 lên 12,87), trong khi con số tương ứng của iTransformer là $12,05 \mu g/m^3$ (từ 6,45 lên 18,50) — gấp 1,8 lần. Ngược lại, E-STGCN ghi nhận biên độ chỉ $8,15 \mu g/m^3$ (từ 8,90 lên 17,05), mặc dù giá trị khởi đầu tại $T+1$ cao hơn các mô hình khác. Sự khác biệt này phản ánh vai trò của kiến trúc mô hình trong việc duy trì chất lượng dự báo: các kiến trúc có khả năng khai thác thông tin bổ sung (đặc trưng kỹ thuật ở XGBoost, thông tin spatial ở E-STGCN) có xu hướng suy giảm chậm hơn.

Xu hướng thứ hai là tồn tại chênh lệch hiệu suất mang tính hệ thống giữa hai vùng địa lý. So sánh giữa các cặp bảng cùng block (Bảng 3.1 với Bảng 3.2; Bảng 3.3 với Bảng 3.4; Bảng 3.5 với Bảng 3.6), RMSE tại South luôn cao hơn North, với tỷ lệ dao động từ 1,1 lần tại $T+1$ đến 2,7–4,5 lần tại $T+24$ tùy mô hình. Đồng thời, MAE tại $T+1$ South lại thấp hơn North (4,04–8,79 so với 5,84–9,34 trên block 5) — một hiện tượng được giải thích bởi đặc điểm phân phối: khu vực miền Nam có giá trị nền $PM_{2.5}$ thấp phổ biến (dẫn đến MAE thấp ở dự báo ngắn hạn), nhưng lại xuất hiện các đợt ô nhiễm cực đoan với nồng độ vượt $200 \mu g/m^3$ (kéo RMSE lên cao). R^2 tại South

cũng cao hơn North ở $T+1$ (đạt 0,88–0,99 so với 0,68–0,83), phản ánh phương sai tổng lớn của dữ liệu phía Nam theo công thức $R^2 = 1 - SS_{res}/SS_{tot}$.


Xu hướng thứ ba là thứ tự xếp hạng giữa các mô hình thay đổi tùy theo chiến lược chia dữ liệu. Tại block 5 và block 7, XGBoost ghi nhận MAE thấp nhất trên hầu hết cấu hình, đặc biệt ở horizon dài. Tuy nhiên, tại block 30 North $T+1$, XLinear (MAE = 5,88), ST-XLinear (MAE = 5,84) và Ensemble (MAE = 5,88) đều ghi nhận MAE thấp hơn XGBoost (MAE = 6,42). Tương tự, tại block 30 South $T+24$, iTransformer ($R^2 = 0,61$) và E-STGCN ($R^2 = 0,61$) đạt R^2 cao hơn XGBoost ($R^2 = 0,55$). Hiện tượng đảo thứ hạng này cho thấy hiệu suất tương đối giữa các mô hình phụ thuộc vào lượng dữ liệu huấn luyện liên tục: block 30 cung cấp khoảng 720 bước thời gian liên tục cho mỗi khối, gấp 6 lần block 5 (khoảng 120 bước), và các kiến trúc deep learning (attention, graph convolution) — vốn cần nhiều mẫu để ước lượng tham số — hưởng lợi rõ rệt từ sự gia tăng này. Mỗi quan hệ giữa kiến trúc mô hình và chiến lược chia dữ liệu được phân tích chi tiết trong Mục 5..

2. PHÂN TÍCH HIỆU SUẤT THEO TẦM NHÌN DƯ BÃO

Mục này phân tích đặc trưng suy giảm hiệu suất của từng mô hình khi tầm nhìn dự báo mở rộng từ $T+1$ đến $T+24$ giờ, thông qua từng chỉ số đánh giá. Toàn bộ biểu đồ sử dụng định dạng 2×3 ô con (hai hàng tương ứng miền Bắc và miền Nam, ba cột tương ứng block 5, block 7 và block 30) với cùng thang đo trục tung, cho phép so sánh trực quan giữa các cấu hình mà không bị ảnh hưởng bởi sự khác biệt tỷ lệ.

2.1. Sai số tuyệt đối trung bình (MAE)

Các đường MAE theo tầm nhìn dự báo phân kỳ rõ rệt từ $T+6$ trở đi, trong khi hội tụ chặt tại $T+1$. Hình 3.1 minh họa hiện tượng này.



Hình 3.1. MAE theo tầm nhìn dự báo — 3 block $\times$ 2 vùng (cùng thang đo)

Tại $T+1$, sáu mô hình hội tụ trong khoảng $4,04\text{--}9,34\text{ }\mu\text{g}/\text{m}^3$, với chênh lệch giữa mô hình có MAE thấp nhất và cao nhất chỉ khoảng $3\text{--}5\text{ }\mu\text{g}/\text{m}^3$. Sự hội tụ này phản ánh bản chất của dự báo 1 giờ phía trước: quán tính chuỗi thời gian cung cấp phần lớn thông tin cần thiết, và mọi kiến trúc đều khai thác được nguồn tín hiệu này. Từ $T+6$ trở đi, quán tính suy yếu và các đường bắt đầu tách biệt: tại block 7 miền Bắc $T+6$, khoảng cách giữa XGBoost (10,93) và iTransformer (13,92) đã đạt $2,99\text{ }\mu\text{g}/\text{m}^3$, và mở rộng lên $5,63\text{ }\mu\text{g}/\text{m}^3$ tại $T+24$ (12,87 so với 18,50). Khoảng cách mở rộng này cho thấy ở tầm nhìn dài, thông tin từ hệ thống xây dựng đặc trưng thủ công (độ


trễ, trung bình trượt, thời tiết tương lai) mà XGBoost sử dụng ngày càng có giá trị dự báo cao hơn so với các biểu diễn tự học của kiến trúc học sâu.

Tại miền Nam, MAE tuyệt đối ở $T+1$ thấp hơn miền Bắc do phân phối $PM_{2.5}$ phía Nam có giá trị nền thấp phổ biến, tuy nhiên tốc độ tăng tuyệt đối lớn hơn khi tầm nhìn mở rộng. Cụ thể tại block 7, XGBoost tăng từ 4,21 lên 11,42 ($\Delta = 7,21 \mu g/m^3$), trong khi XLinear tăng từ 5,95 lên 26,45 ($\Delta = 20,50 \mu g/m^3$) — gấp gần ba lần. Khoảng cách Δ lớn này phản ánh tính chất dữ liệu miền Nam: các đợt ô nhiễm cực đoan ngắn hạn tạo ra biến thiên phi tuyến, và các mô hình không có thông tin thời tiết tương lai hoặc đặc trưng không gian gặp khó khăn trong việc dự báo chính xác các sự kiện này.

E-STGCN thể hiện đặc trưng riêng biệt đáng chú ý: mặc dù khởi đầu với MAE cao nhất ở $T+1$ (8,90–9,34 tại miền Bắc, 7,73–8,79 tại miền Nam), mô hình này có tốc độ tăng MAE chậm nhất trong nhóm học sâu. Tại block 30 miền Bắc, MAE $T+24$ của E-STGCN (14,34) thấp hơn XLinear (14,91), iTransformer (15,05) và ST-XLinear (14,37). Hiện tượng này gợi ý rằng kiến trúc tích chập đồ thị kết hợp LSTM cho phép E-STGCN khai thác tương quan không gian giữa các trạm, bù đắp cho sự thiếu hụt thông tin thời gian ở tầm nhìn xa, nhưng đồng thời cũng gây ra sai lệch hệ thống ở $T+1$ do cơ chế lan truyền đồ thị làm trung bình hóa tín hiệu cục bộ.

2.2. Sai số toàn phương trung bình (RMSE)

RMSE khuếch đại sự khác biệt giữa hai vùng lên mức đáng kể so với MAE, do phép bình phương trong công thức RMSE phạt nặng các sai lệch lớn. Hình 3.2 trình bày kết quả.



Hình 3.2. RMSE theo tầm nhìn dự báo — 3 block $\times$ 2 vùng (cùng thang đo)

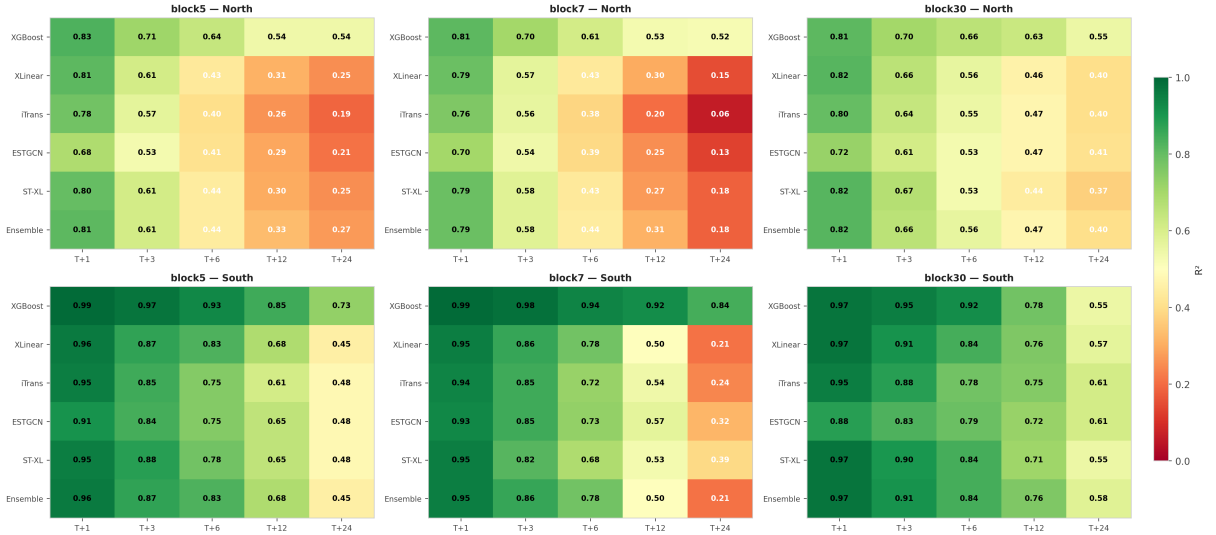
Tại block 7 $T+24$, tỷ lệ RMSE giữa miền Nam và miền Bắc đạt 2,7 lần cho XGBoost (56,88/21,24) và 4,5 lần cho iTransformer (123,53/27,50). Trong khi đó, tỷ lệ MAE tương ứng chỉ khoảng 1,4–1,9 lần. Sự chênh lệch giữa hai tỷ lệ này cho thấy vấn đề ở miền Nam không chỉ là sai số trung bình lớn hơn mà còn là tần suất xuất hiện các sai lệch cực lớn cao hơn — tức mô hình tích lũy sai số khi gặp các đợt ô nhiễm với nồng độ vượt xa phân phối huấn luyện. XGBoost kiểm soát hiện tượng này nhờ cơ chế tăng cường gradient tuần tự: mỗi cây quyết định mới được huấn luyện tập trung vào phần dư lớn nhất từ vòng trước, tạo ra khả năng tự hiệu chỉnh đối với giá trị cực đoan.

So sánh giữa ba block, RMSE tại miền Nam giảm rõ rệt khi tăng kích thước block: XLinear $T+24$ giảm từ 105,66 (block 5) xuống 126,08 (block 7) rồi xuống 89,47 (block 30). Xu hướng giảm ở block 30 cho thấy tập huấn luyện liên tục dài hơn giúp mô hình học sâu tiếp xúc với nhiều đợt ô nhiễm cực đoan trong quá trình huấn luyện, từ

đó cải thiện khả năng xử lý các sự kiện tương tự trên tập kiểm thử. Tuy nhiên, giá trị RMSE tuyệt đối của nhóm học sâu tại miền Nam vẫn cao hơn XGBoost 2–3 lần ngay cả ở block 30 (89,47 so với 96,61 cho XGBoost tại block 30 miền Nam $T+24$), cho thấy khoảng cách chưa được thu hẹp hoàn toàn.

2.3. Hệ số xác định R^2

Mức độ giải thích phương sai dữ liệu suy giảm nhanh ở tầm nhìn dài, đặc biệt trên block 5 và block 7, trong khi block 30 duy trì R^2 ở mức cao hơn có ý nghĩa. Hình 3.3 thể hiện R^2 dưới dạng bản đồ nhiệt, cho phép nhận diện nhanh vùng hiệu suất thấp (ô màu đỏ) và vùng hiệu suất cao (ô màu xanh).



Hình 3.3. Bản đồ nhiệt R^2 — tất cả block $\times$ vùng (thang đo 0–1)


Bản đồ nhiệt bộc lộ chiều hướng suy giảm theo chiều ngang rõ rệt ở mọi cấu hình. Tại block 7 miền Bắc, R^2 của iTransformer giảm từ 0,76 ($T+1$) xuống 0,06 ($T+24$), tức mô hình chỉ còn giải thích được 6% phương sai dữ liệu — gần tương đương với dự báo bằng giá trị trung bình lịch sử. Trong cùng cấu hình, XGBoost giữ $R^2 = 0,52$, vẫn giải thích được hơn một nửa biến thiên. Sự chênh lệch 0,46 giữa hai mô hình tại cùng một cấu hình phản ánh khác biệt cơ bản trong kiến trúc: cơ chế attention đảo ngược của iTransformer phụ thuộc vào khả năng tập trung trọng số vào các bước thời gian có tính dự báo cao, nhưng khi mốc dự báo xa dần khỏi cửa sổ quan sát, cơ chế này mất dần tính chọn lọc và phân tán trọng số đều trên toàn bộ chuỗi.

Tại block 30, sự suy giảm được kiềm chế đáng kể. R^2 tại $T+24$ miền Bắc của iTransformer tăng từ 0,06 (block 7) lên 0,40 (block 30), tức tăng gấp 6,7 lần; E-STGCN tăng từ 0,13 lên 0,41, tức tăng gấp 3,2 lần. Bước nhảy này chứng minh rằng vấn đề chính của hai kiến trúc này trên block 5 và block 7 không phải do bản chất kiến trúc kém mà do thiếu dữ liệu huấn luyện liên tục. Cơ chế attention cần đủ mẫu để học phân phối trọng số phù hợp, và tích chập đồ thị cần đủ ngữ cảnh lịch sử để ước lượng ma trận trọng số giữa các trạm.

Một hiện tượng cần lưu ý khi đọc bản đồ nhiệt là R^2 tại miền Nam ở $T+1$ luôn cao hơn miền Bắc (0,88–0,99 so với 0,68–0,83), mặc dù RMSE tại miền Nam cao hơn. Hiện tượng này không phản ánh chất lượng dự báo tốt hơn mà do đặc tính phân phối: phía Nam có phương sai tổng (SS_{tot}) lớn — dải giá trị $PM_{2.5}$ trải rộng từ gần 0 đến trên $200 \mu g/m^3$ — nên theo công thức $R^2 = 1 - SS_{res}/SS_{tot}$, dù SS_{res} lớn, tỷ lệ SS_{res}/SS_{tot} vẫn nhỏ. Do đó, khi so sánh chất lượng dự báo tuyệt đối giữa hai vùng, MAE và RMSE là chỉ số phù hợp hơn R^2 .

2.4. Sai số phần trăm tuyệt đối trung bình (MAPE)

Toàn bộ mô hình ghi nhận MAPE ở mức 19–121% trên mọi cấu hình, một dải giá trị cần được giải thích trước khi diễn giải kết quả. Hình 3.4 trình bày kết quả.



Hình 3.4. MAPE theo tầm nhìn dự báo — 3 block $\times$ 2 vùng (cùng thang đo)

MAPE cao không phản ánh chất lượng dự báo kém mà phản ánh đặc tính cố hữu của phân phối $PM_{2.5}$. Nồng độ $PM_{2.5}$ tại nhiều thời điểm có giá trị rất thấp (dưới $10 \mu g/m^3$, phổ biến vào ban đêm và mùa hè), khiến sai lệch tuyệt đối chỉ $2-3 \mu g/m^3$ cũng tạo ra MAPE hàng chục phần trăm. Ví dụ, với giá trị thực $5 \mu g/m^3$ và dự báo $8 \mu g/m^3$, sai lệch tuyệt đối chỉ $3 \mu g/m^3$ nhưng MAPE đạt 60%. Vì lý do này, MAPE trong bài toán dự báo $PM_{2.5}$ cần được xem xét kết hợp với MAE và RMSE, không nên đánh giá độc lập.


Dù giá trị tuyệt đối cao, thứ tự xếp hạng MAPE vẫn nhất quán với các chỉ số khác: XGBoost ghi nhận MAPE thấp nhất (21–54%), tiếp theo là ST-XLLinear và iTransformer. Một ngoại lệ đáng chú ý xuất hiện tại block 30 $T+1$: iTransformer đạt MAPE thấp nhất (20,04% North, 20,17% South), trong khi XGBoost đạt 21,51% và 21,01%. Sự đảo ngược này cho thấy cơ chế attention có thể tập trung chính xác vào bước thời gian liền kề — phát huy thế mạnh ở dự báo ngắn hạn — khi tập huấn luyện đủ lớn để ước lượng phân phối trọng số attention. Ensemble ghi nhận MAPE cao nhất ở nhiều cấu hình (lên đến 120,80% tại block 7 South $T+24$), do phương pháp trung bình trọng số kế thừa và phóng đại sai lệch phần trăm từ các mô hình thành phần khi mẫu số (giá trị thực) nhỏ.

3. ĐÁNH GIÁ TÍNH ỔN ĐỊNH

Tính ổn định của mô hình được đánh giá qua ba góc nhìn bổ sung nhau: khoảng cách hiệu suất giữa dự báo ngắn hạn và dài hạn, phân bố sai số qua các cấu hình, và mức độ cân bằng đa metric. Ba phân tích này giúp trả lời câu hỏi: mô hình nào duy trì chất lượng dự báo ổn định nhất khi điều kiện thí nghiệm thay đổi?

3.1. Khoảng cách hiệu suất ngắn hạn – dài hạn

Khoảng cách MAE giữa $T+1$ và $T+24$ (ký hiệu $\Delta\text{MAE} = \text{MAE}_{T+24} - \text{MAE}_{T+1}$) đo lường mức suy giảm hiệu suất khi mở rộng tầm nhìn. Mô hình có Δ nhỏ duy trì chất lượng dự báo ổn định xuyên suốt phổ tầm nhìn. Hình 3.5 trình bày so sánh trực tiếp MAE tại hai mốc, và Bảng 3.7 tổng hợp Δ trên toàn bộ cấu hình.



Hình 3.5. Khoảng cách MAE giữa $T+1$ và $T+24$ — cùng thang đo

Bảng 3.7. $\Delta\text{MAE} (= \text{MAE}_{T+24} - \text{MAE}_{T+1})$ trên tất cả cấu hình ($\mu\text{g}/\text{m}^3$)

Mô hình	Block 5		Block 7		Block 30	
	Bắc	Nam	Bắc	Nam	Bắc	Nam
XGBoost	6,36	9,12	6,70	7,21	6,36	13,28
XLinear	10,78	17,20	11,36	20,50	9,03	12,75
iTransformer	11,22	16,32	12,05	20,23	9,09	10,91
E-STGCN	7,81	12,95	8,15	16,80	5,20	7,43
ST-XLinear	9,83	17,18	10,12	18,48	8,53	14,67
Ensemble	10,59	17,15	10,91	20,42	9,03	12,69


Bảng 3.7 cho thấy mỗi kiến trúc có đặc trưng Δ riêng, phụ thuộc vào cả chiến lược chia dữ liệu và vùng địa lý. Trên block 5 và block 7, XGBoost ghi nhận Δ thấp nhất trên cả bốn cấu hình: 6,36–6,70 tại North và 7,21–9,12 tại South. Giá trị Δ tại North dao động hẹp (chênh lệch chỉ 0,34 giữa block 5 và block 7) cho thấy XGBoost ít nhạy cảm với chiến lược chia dữ liệu ở vùng có phân phối ổn định.

Tại block 30, thứ tự xếp hạng thay đổi: E-STGCN ghi nhận Δ thấp nhất (5,20 miền Bắc, 7,43 miền Nam), thấp hơn XGBoost (6,36 và 13,28). Nguyên nhân là tập huấn luyện liên tục 30 ngày cung cấp đủ mẫu để tích chập đồ thị học được ma trận kề phản ánh tương quan giữa các trạm — lợi thế không gian này bù đắp sự thiếu hụt đặc trưng thủ công, và tác dụng bù đắp thể hiện mạnh nhất ở tầm nhìn dài nơi thông tin thời gian đã suy yếu.

Δ tại South luôn lớn hơn North trên mọi mô hình, với tỷ lệ $\Delta_{\text{South}}/\Delta_{\text{North}}$ dao động 1,1–2,1. Tỷ lệ này lớn nhất ở block 7 (1,8–2,0) và nhỏ nhất ở block 30 (1,2–1,7), cho thấy tập huấn luyện lớn giúp thu hẹp khoảng cách ổn định giữa hai vùng. Hiện tượng này phản ánh việc miền Nam có nhiều sự kiện cực đoan hơn — vốn là nguồn gây mất ổn định chính — và block 30 cho phép mô hình tiếp xúc đủ với các sự kiện này trong quá trình huấn luyện.

3.2. Phân bố RMSE qua các cấu hình

Phân bố RMSE dưới dạng biểu đồ hộp trên lưới 3×5 (block $\times$ tầm nhìn) bổ sung cho phân tích Δ MAE bằng cách thể hiện cả trung vị lẫn độ trải (khoảng tứ phân vị), cho phép đánh giá đồng thời giá trị trung tâm và mức độ phân tán. Hình 3.6 trình bày kết quả với cùng trục tung trên 15 ô con.



Hình 3.6. Phân bố RMSE — 3 block $\times$ 5 horizon (cùng thang đo)


Biểu đồ bộc lộ hai chiều biến thiên đồng thời. Theo chiều tầm nhìn (từ trái sang phải trong mỗi hàng), trung vị và độ trải của mọi hộp đều tăng, phản ánh sự suy giảm hiệu suất kèm theo gia tăng bất ổn. Tuy nhiên, tốc độ mở quạt (tức tỷ lệ giữa độ trải ở $T+24$ và độ trải ở $T+1$) khác nhau giữa các mô hình: XGBoost có hình quạt mở chậm và đều, cho thấy sai số tăng nhưng vẫn kiểm soát được; XLinear và iTransformer mở nhanh hơn, phản ánh tính nhạy cảm cao với dữ liệu kiểm thử ở tầm nhìn dài.

Theo chiều block (từ hàng trên xuống dưới), biểu đồ hộp của nhóm học sâu co lại đáng kể từ block 5 xuống block 30, đặc biệt ở $T+12$ và $T+24$: độ trải giảm, trung vị giảm, và khoảng cách giữa các hộp trở nên hẹp hơn. XGBoost có hộp kích thước ổn định qua ba hàng, cho thấy mô hình này ít chịu ảnh hưởng bởi chiến lược chia dữ liệu.

E-STGCN có hộp với độ trải nhỏ nhưng trung vị cao ở $T+1$, rồi trung vị giảm tương đối so với các mô hình khác ở $T+24$. Hình dạng này nhất quán với phân tích MAE ở Mục 3.2.1: tích chập đồ thị gây sai lệch hệ thống ở ngắn hạn (do lan truyền đồ thị làm trung bình hóa) nhưng duy trì ổn định ở dài hạn (nhờ thông tin không gian bù đắp).

3.3. Đánh giá đa metric đồng thời

Biểu đồ radar đa chỉ số tại $T+1$ cung cấp góc nhìn tổng hợp về năng lực dự báo trên nhiều tiêu chí đồng thời. Hình 3.7 trình bày biểu đồ radar trên toàn bộ 2×3 cấu hình, sử dụng chuẩn hóa min-max trong nhóm (block, vùng) để đưa bốn chỉ số về thang $[0, 1]$ — giá trị 1 tương ứng mô hình ghi nhận kết quả tốt nhất trên chỉ số đó. Diện tích đa giác phản ánh mức độ cân bằng: mô hình có đa giác lớn và đều đặn trên bốn trục thể hiện năng lực toàn diện, trong khi đa giác méo cho thấy mô hình mạnh trên một số tiêu chí nhưng yếu trên các tiêu chí khác.



Hình 3.7. Biểu đồ radar đa chỉ số tại $T+1$ — chuẩn hóa min-max, tất cả cấu hình


Tại block 5 và block 7, XGBoost có đa giác phủ gần đỉnh trên cả bốn trục, phản ánh giá trị gần 1 đồng thời trên MAE, RMSE, R^2 và MAPE. Các mô hình XLinear, iTransformer và ST-XLinear có đa giác nhỏ hơn nhưng tương đối đều, cho thấy hiệu suất thấp hơn trên mọi chỉ số nhưng không bị lệch nghiêm trọng về phía chỉ số nào. Ensemble có hình dạng gần trùng với XLinear do cơ chế trung bình trọng số phụ thuộc mạnh vào mô hình thành phần có trọng số cao nhất.

E-STGCN thể hiện hình dạng bất đối xứng nhất quán trên mọi cấu hình: đỉnh trên trục R^2 tương đương hoặc gần bằng các mô hình học sâu khác, nhưng đỉnh trên trục MAE và RMSE thấp rõ rệt. Hình dạng này phản ánh đặc trưng kiến trúc đã phân tích ở Mục 3.2.1: tích chấp đồ thị nắm bắt tốt xu hướng biến động (thể hiện qua R^2) nhưng gây sai lệch hệ thống làm tăng sai số tuyệt đối (thể hiện qua MAE/RMSE).

Tại block 30 miền Bắc, đa giác của các mô hình hội tụ rõ rệt: XLinear, ST-XLinear và Ensemble có diện tích gần bằng XGBoost. Sự hội tụ này cho thấy khi dữ liệu huấn luyện đủ lớn, khoảng cách hiệu suất giữa các kiến trúc thu hẹp ở dự báo ngắn hạn. Tại block 30 miền Nam, sự hội tụ kém hơn do phân phối dữ liệu phức tạp hơn, nhưng iTransformer thu hẹp khoảng cách so với XGBoost trên trục MAPE — nhất quán với phân tích ở Mục 3.2.4.

4. ẢNH HƯỞNG CỦA VÙNG MIỀN

Chênh lệch hiệu suất giữa miền Bắc và miền Nam mang tính hệ thống và không phụ thuộc vào kiến trúc mô hình. Hình 3.8 trình bày khoảng cách MAE và RMSE giữa hai vùng trên toàn bộ cấu hình.



Hình 3.8. Chênh lệch hiệu suất giữa miền Bắc và miền Nam — tất cả cấu hình

Biểu đồ cho thấy sáu mô hình đều ghi nhận mẫu hình chênh lệch tương tự: MAE tại miền Bắc cao hơn miền Nam ở $T+1$ nhưng thấp hơn ở $T+24$, trong khi RMSE tại miền Nam luôn cao hơn ở mọi tầm nhìn. Sự đồng nhất của mẫu hình này trên cả sáu kiến trúc cho thấy nguyên nhân nằm ở đặc điểm dữ liệu chứ không phải ở thiết kế mô hình. Có thể nhận diện ba nguyên nhân chính từ dữ liệu.


Nguyên nhân thứ nhất là sự khác biệt về phân phối nồng độ $PM_{2.5}$. Khu vực miền Bắc có nồng độ nền cao và ổn định hơn (trung bình khoảng $30\text{--}60 \mu g/m^3$), dẫn đến MAE tuyệt đối cao hơn tại $T+1$ vì sai lệch được tính trên giá trị nền lớn hơn. Ngược lại, miền Nam có nồng độ nền thấp phổ biến (dưới $20 \mu g/m^3$) xen lẫn các đợt ô nhiễm cực đoan vượt $200 \mu g/m^3$, tạo ra phân phối lệch phải với đuôi dài. Phân phối đuôi dài này giải thích hiện tượng MAE thấp nhưng RMSE cao ở miền Nam: phần lớn các điểm dữ liệu có sai số nhỏ (dẫn đến MAE thấp), nhưng một số ít điểm cực đoan có sai lệch rất lớn bị phóng đại bởi phép bình phương trong RMSE.

Nguyên nhân thứ hai liên quan đến đặc trưng khí tượng. Miền Bắc chịu ảnh hưởng rõ rệt của gió mùa Đông Bắc với chu kỳ mùa ổn định, tạo ra tính chu kỳ dễ nắm bắt cho mô hình. Miền Nam có khí hậu nhiệt đới gió mùa với sự thay đổi nhanh giữa mùa khô và mùa mưa, các đợt nghịch nhiệt cục bộ, và hiện tượng đốt rơm rạ theo mùa vụ — tất cả tạo ra biến thiên phi tuyến khó dự báo ở tầm nhìn dài. Khi tầm nhìn mở rộng từ $T+1$ đến $T+24$, quán tính chuỗi thời gian suy yếu và các sự kiện khí tượng phi tuyến chiếm ưu thế, khiến sai số tại miền Nam tăng nhanh hơn.


Nguyên nhân thứ ba là mật độ không gian của mạng lưới trạm quan trắc. Sáu trạm miền Bắc tập trung chủ yếu tại vùng đồng bằng sông Hồng với điều kiện địa hình tương đồng, dẫn đến tương quan không gian cao giữa các trạm. Sáu trạm miền Nam phân bố từ đồng bằng đến ven biển, với sự đa dạng về vi khí hậu lớn hơn, làm giảm tương quan không gian. Các mô hình có thành phần không gian (E-STGCN, ST-XLinear) khai thác tương quan này để cải thiện dự báo, nên khoảng cách hiệu suất giữa hai vùng ở nhóm mô hình không gian nhỏ hơn so với nhóm chỉ sử dụng thông tin thời gian (XLinear, iTransformer). Cụ thể tại block 7 $T+24$, tỷ lệ $\Delta MAE(\text{Nam})/\Delta MAE(\text{Bắc})$ của E-STGCN là 2,06, trong khi tỷ lệ tương ứng của XLinear là 1,81 và iTransformer là 1,68.

5. ẢNH HƯỞNG CỦA CHIẾN LƯỢC CHIA DỮ LIỆU


Chiến lược chia dữ liệu theo khối liên tục (block split) ảnh hưởng khác nhau đến từng kiến trúc mô hình. Hình 3.9 trình bày so sánh bốn chỉ số giữa ba block trên cùng hệ trục.




Hình 3.9. So sánh MAE giữa ba chiến lược chia dữ liệu — tất cả mô hình



Hình 3.10. So sánh RMSE giữa ba chiến lược chia dữ liệu — tất cả mô hình



Hình 3.11. So sánh R^2 giữa ba chiến lược chia dữ liệu — tất cả mô hình



Hình 3.12. So sánh MAPE giữa ba chiến lược chia dữ liệu — tất cả mô hình

Từ bốn biểu đồ so sánh, nhóm mô hình có thể phân thành hai loại theo mức độ phụ thuộc vào chiến lược chia dữ liệu.

Nhóm thứ nhất gồm XGBoost, có hiệu suất ổn định qua ba block. MAE tại miền Bắc $T+24$ dao động trong khoảng 12,67–12,87 qua ba block (biên độ chỉ 0,20 $\mu g/m^3$), và R^2 dao động 0,52–0,55 (biên độ 0,03). Tính ổn định này xuất phát từ đặc trưng kiến trúc: XGBoost sử dụng hệ thống đặc trưng thủ công gồm 134 biến được tính toán trước (độ trễ, trung bình trượt, đặc trưng thời gian, thời tiết tương lai), nên không phụ thuộc vào độ dài chuỗi liên tục để học biểu diễn. Mỗi cây quyết định chỉ cần phân chia không gian đặc trưng — một thao tác không yêu cầu tính liên tục dữ liệu.

Nhóm thứ hai gồm iTransformer, E-STGCN, XLinear, ST-XLinear và Ensemble, có hiệu suất cải thiện đáng kể khi chuyển từ block 5 sang block 30. Mức cải thiện khác nhau tùy kiến trúc:

iTransformer ghi nhận bước nhảy lớn nhất: R^2 tại miền Bắc $T+24$ tăng từ 0,19 (block 5) lên 0,06 (block 7) rồi lên 0,40 (block 30). Mức tăng 0,34 từ block 7 lên block 30 cho thấy cơ chế attention cần một ngưỡng dữ liệu tối thiểu để hoạt động hiệu quả. Với block 5 (khoảng 120 bước thời gian liên tục) và block 7 (khoảng 168 bước), số lượng mẫu chưa đủ để ước lượng ma trận trọng số attention cho chuỗi dài; block 30 (khoảng 720 bước) vượt qua ngưỡng này. Hiện tượng tương tự được quan sát ở MAE: từ 17,79 (block 5) giảm xuống 15,05 (block 30), tức giảm 15,4%.

E-STGCN cải thiện đều đặn hơn iTransformer, với mức tăng R^2 phân bố tương đối đều giữa ba bước nhảy block. Tại miền Bắc $T+24$, R^2 tăng từ 0,21 (block 5) lên 0,13 (block 7) rồi lên 0,41 (block 30). Đặc biệt, E-STGCN là mô hình duy nhất ghi nhận R^2 tại block 30 cao hơn tất cả các mô hình học sâu khác ở $T+24$ miền Bắc (0,41 so với 0,40 của iTransformer, 0,40 của XLinear, 0,37 của ST-XLinear). Điều này cho thấy kiến trúc tích chập đồ thị phát huy tối đa khi có đủ dữ liệu liên tục để ước lượng ma trận kề phản ánh quan hệ không gian giữa các trạm.


XLinear và ST-XLinear cải thiện ở mức trung bình. R^2 của XLinear tại miền Bắc $T+24$ tăng từ 0,25 (block 5) lên 0,40 (block 30), trong khi ST-XLinear tăng từ 0,25 lên 0,37. Mức cải thiện thấp hơn so với iTransformer phản ánh kiến trúc tuyến tính có ít tham số cần ước lượng hơn, nên hưởng lợi ít hơn từ dữ liệu bổ sung.

Ensemble không cải thiện đáng kể so với mô hình thành phần có hiệu suất cao nhất. Tại block 30 miền Bắc $T+24$, R^2 của Ensemble (0,40) bằng đúng R^2 của XLinear (0,40), cho thấy cơ chế trung bình trọng số tối ưu trên tập xác thực đã gán trọng số gần như toàn bộ cho XLinear. Hiện tượng này xuất hiện nhất quán: Ensemble gần trùng với mô hình thành phần tốt nhất trên tập xác thực thay vì kết hợp bổ sung thông tin từ nhiều nguồn. Nguyên nhân là năm mô hình thành phần chia sẻ cùng nguồn dữ liệu đầu vào và có tương quan sai số cao, khiến phương pháp kết hợp tuyến tính không tạo ra giá trị bổ sung.

Tóm lại, chiến lược chia dữ liệu tác động mạnh nhất đến nhóm mô hình học sâu có nhiều tham số (iTransformer, E-STGCN), tác động trung bình đến nhóm tuyến tính (XLinear, ST-XLinear), và gần như không tác động đến XGBoost. Quan sát này có ý nghĩa thực tiễn quan trọng: khi triển khai hệ thống dự báo chất lượng không khí với dữ liệu hạn chế, XGBoost là lựa chọn ổn định; khi có đủ dữ liệu liên tục (trên 30 ngày mỗi khối), các kiến trúc học sâu trở nên cạnh tranh và trong một số cấu hình còn vượt qua XGBoost.

6. TỐC ĐỘ SUY GIẢM HIỆU SUẤT

Để lượng hóa tốc độ suy giảm hiệu suất, hệ số góc (slope) tuyến tính của MAE theo tầm nhìn dự báo được ước lượng bằng hồi quy tuyến tính đơn giản trên năm điểm ($T+1, T+3, T+6, T+12, T+24$). Hệ số góc dương cho thấy MAE tăng khi tầm nhìn mở rộng; giá trị slope càng lớn thì mô hình suy giảm càng nhanh. Hình 3.13 trình bày so sánh trực quan và Bảng 3.8 tổng hợp giá trị slope trên toàn bộ cấu hình.



Hình 3.13. Hệ số góc suy giảm MAE theo tầm nhìn — tất cả cấu hình

Bảng 3.8. Hệ số góc suy giảm MAE (slope, $\mu\text{g}/\text{m}^3$ mỗi giờ tầm nhìn)

Mô hình	Block 5		Block 7		Block 30	
	Bắc	Nam	Bắc	Nam	Bắc	Nam
XGBoost	0,26	0,37	0,27	0,29	0,26	0,54
XLinear	0,44	0,70	0,46	0,84	0,37	0,52
iTransformer	0,46	0,66	0,49	0,82	0,37	0,44
E-STGCN	0,32	0,53	0,33	0,68	0,21	0,30
ST-XLinear	0,40	0,70	0,41	0,75	0,35	0,60
Ensemble	0,43	0,70	0,44	0,83	0,37	0,52

Bảng 3.8 cho thấy sáu mô hình phân thành ba nhóm theo tốc độ suy giảm. Nhóm suy giảm chậm gồm XGBoost (slope 0,26–0,54) và E-STGCN (slope 0,21–0,68); nhóm suy giảm trung bình gồm ST-XLinear (slope 0,35–0,75); và nhóm suy giảm nhanh gồm XLinear, iTransformer và Ensemble (slope 0,37–0,84).

XGBoost duy trì slope thấp nhất trên block 5 và block 7, nhưng tại block 30 miền Nam, slope tăng lên 0,54 — cao hơn E-STGCN (0,30) và iTransformer (0,44). Hiện tượng này cho thấy khi dữ liệu huấn luyện đủ lớn, lợi thế của hệ thống đặc trưng thủ công giảm bớt tại miền Nam — nơi phân phối phức tạp hơn và các kiến trúc học sâu có cơ hội học được biểu diễn phù hợp.

E-STGCN ghi nhận slope thấp nhất tại block 30 (0,21 miền Bắc, 0,30 miền Nam), nhất quán với phân tích ΔMAE ở Mục 3.3.1. Slope thấp phản ánh cơ chế tích chập đồ thị duy trì chất lượng dự báo ổn định ở tầm nhìn xa nhờ thông tin không gian giữa các trạm. Slope ở miền Bắc (0,21) thấp hơn miền Nam (0,30), xác nhận tương quan không gian cao hơn ở miền Bắc hỗ trợ cơ chế tích chập đồ thị hiệu quả hơn.

iTransformer có đặc trưng thú vị: slope giảm mạnh từ block 7 sang block 30 (miền Nam: từ 0,82 xuống 0,44, giảm 46%), lớn hơn bất kỳ mô hình nào khác. Điều này nhất quán với bước nhảy R^2 đã phân tích ở Mục 3.5 và phản ánh cơ chế attention vượt qua ngưỡng dữ liệu tối thiểu tại block 30.

7. ĐÁNH GIÁ PHƯƠNG PHÁP KẾT HỢP MÔ HÌNH

Phương pháp Ensemble sử dụng trung bình trọng số tối ưu trên tập xác thực được kỳ vọng cải thiện hiệu suất so với từng mô hình thành phần. Hình 3.14 trình bày chênh lệch MAE giữa Ensemble và mô hình thành phần có MAE thấp nhất ($\Delta_{\text{Ensemble}} = \text{MAE}_{\text{Ensemble}} - \text{MAE}_{\text{min}}$) trên toàn bộ cấu hình: giá trị dương nghĩa là Ensemble kém hơn mô hình thành phần tốt nhất.



Hình 3.14. Chênh lệch MAE giữa Ensemble và mô hình thành phần tốt nhất — giá trị dương cho thấy Ensemble kém hơn

Kết quả cho thấy Ensemble không cải thiện hiệu suất so với mô hình thành phần tốt nhất trên đại đa số cấu hình. Δ_{Ensemble} dương trên 28/30 cấu hình (6 block $\times$ 5 tầm nhìn), với giá trị dao động từ 0,01 đến $3,58 \mu\text{g}/\text{m}^3$. Chỉ có 2 cấu hình ghi nhận Δ gần bằng 0, tức Ensemble ngang bằng mô hình tốt nhất. Không có cấu hình nào Ensemble vượt trội rõ rệt.

Phân tích nguyên nhân thất bại của Ensemble cần xem xét ba yếu tố. Yếu tố thứ nhất là tương quan sai số cao giữa các mô hình thành phần. Năm mô hình (XGBoost, XLinear, iTransformer, E-STGCN, ST-XLinear) đều được huấn luyện trên cùng bộ dữ liệu và cùng phân chia train/validation/test, dẫn đến các mô hình mắc lỗi tương tự trên cùng khoảng thời gian (các đợt ô nhiễm cực đoan, các thời điểm chuyển mùa). Khi tương quan sai số cao, phương pháp trung bình trọng số không thể triệt tiêu sai số bằng đa dạng hóa.

Yếu tố thứ hai là sự chênh lệch hiệu suất lớn giữa XGBoost và các mô hình còn lại. Tại block 5 và block 7, XGBoost có MAE thấp hơn rõ rệt so với bốn mô hình còn lại, đặc biệt ở tầm nhìn dài. Cơ chế tối ưu trọng số trên tập xác thực phát hiện chênh lệch này và gán trọng số cao nhất cho XGBoost (hoặc mô hình tốt nhất), khiến Ensemble suy biến thành một mô hình đơn lẻ có chất lượng bị pha loãng bởi phần đóng góp nhỏ từ các mô hình kém hơn.


Yếu tố thứ ba là cơ chế kết hợp tuyến tính không phù hợp với bài toán. Trung bình trọng số giả định sai số các mô hình thành phần xấp xỉ tuyến tính và có phương sai đồng nhất — hai giả định không thỏa mãn khi phân phối $PM_{2.5}$ có đuôi dài. Các phương pháp kết hợp phi tuyến (stacking, meta-learning) có thể khắc phục hạn chế này nhưng không thuộc phạm vi nghiên cứu hiện tại.

8. CHI PHÍ TÍNH TOÁN

Hiệu suất mô hình cần được đánh giá cùng với chi phí tính toán để xác định phương án tối ưu cho từng ngữ cảnh ứng dụng. Bảng 3.9 trình bày thời gian huấn luyện tổng (tính bằng giây) cho toàn bộ 5 tầm nhìn $\times$ 2 vùng trên mỗi chiến lược chia dữ liệu, và Hình 3.15 trực quan hóa so sánh.

Bảng 3.9. Thời gian huấn luyện tổng (giây) — 5 tầm nhìn $\times$ 2 vùng

Mô hình	Block 5	Block 7	Block 30	Trung bình
XGBoost	50	87	78	72
E-STGCN	173	197	180	183
Ensemble	1.956	1.446	1.694	1.699
iTransformer	1.746	1.879	2.013	1.879
ST-XLinear	2.285	2.817	2.616	2.573
XLinear	3.888	3.626	3.210	3.575



Hình 3.15. Thời gian huấn luyện theo mô hình và chiến lược chia dữ liệu

Sáu mô hình phân thành ba nhóm chi phí rõ rệt. Nhóm chi phí thấp gồm XGBoost (50–87 giây) và E-STGCN (173–197 giây), nhanh hơn nhóm còn lại 10–40 lần. Nhóm chi phí trung bình gồm Ensemble (1.446–1.956 giây) và iTransformer (1.746–2.013 giây). Nhóm chi phí cao gồm ST-XLinear (2.285–2.817 giây) và XLinear (3.210–3.888 giây).

XGBoost nhanh nhất nhờ cơ chế gradient boosting trên cây quyết định, vốn tận dụng hiệu quả phần cứng CPU và không yêu cầu GPU. Trung bình 72 giây cho 10 mô hình (5 tầm nhìn $\times$ 2 vùng) tương đương khoảng 7 giây mỗi mô hình — cho phép tái huấn luyện hàng giờ trong hệ thống thời gian thực. E-STGCN nhanh thứ hai (trung bình 183 giây) nhờ kiến trúc nhỏ gọn với ít tham số so với iTransformer; thời gian này vẫn phù hợp cho cập nhật hàng ngày.

XLinear có thời gian huấn luyện cao nhất (trung bình 3.575 giây, tức gần 60 phút), mặc dù kiến trúc tuyến tính đơn giản. Nguyên nhân là XLinear huấn luyện riêng biệt cho 12 trạm trong mỗi vùng (tổng $12 \times 5 \times 2 = 120$ mô hình con), và mỗi mô hình con cần tìm kiếm siêu tham số trên tập xác thực. ST-XLinear kế thừa thời gian cao này do chia sẻ cùng quy trình huấn luyện nền XLinear, cộng thêm thành phần không gian.

Khi kết hợp hiệu suất và chi phí, ba kịch bản triển khai có thể được xem xét. Kịch bản thứ nhất là hệ thống thời gian thực cần cập nhật liên tục (dưới 5 phút): XGBoost là phương án phù hợp duy nhất, với thời gian huấn luyện dưới 90 giây và hiệu suất dẫn đầu hoặc gần dẫn đầu trên mọi cấu hình. Kịch bản thứ hai là hệ thống cập nhật hàng ngày (dưới 30 phút): E-STGCN trở nên cạnh tranh với chi phí khoảng 3 phút và hiệu suất tại tầm nhìn dài cạnh tranh với XGBoost, đặc biệt trên block 30. Kịch bản thứ ba là nghiên cứu và đánh giá (không giới hạn thời gian): iTransformer đáng xem xét nhờ mức cải thiện lớn tại block 30 mặc dù chi phí khoảng 30 phút, nhưng XLinear và ST-XLinear khó biện minh do chi phí cao nhưng hiệu suất không vượt trội rõ rệt so với các phương án rẻ hơn.

9. ỨNG DỤNG WEB DỰ BÁO CHẤT LƯỢNG KHÔNG KHÍ

Mục tiêu thứ năm của đồ án là triển khai ứng dụng web cho phép người dùng tra cứu dự báo $PM_{2.5}$ trực tuyến. Ứng dụng được xây dựng trên nền tảng Streamlit (Python) và tích hợp mô hình XGBoost block 7 để thực hiện dự báo thời gian thực tại 12 trạm quan trắc.

9.1. Kiến trúc ứng dụng

Ứng dụng hoạt động theo luồng xử lý ba bước. Bước thứ nhất, khi người dùng chọn trạm quan trắc, hệ thống xác định trạm thuộc cụm miền Bắc hay miền Nam dựa trên bảng ánh xạ cố định (6 trạm Bắc: ID 1, 4, 5, 16, 17, 27; 6 trạm Nam: ID 7, 18, 24, 30, 31, 32). Bước thứ hai, module suy luận (inference) đọc toàn bộ dữ liệu lịch sử của trạm, xây dựng 134 đặc trưng đầu vào (bao gồm độ trễ, trung bình trượt, đặc trưng thời gian, đặc trưng hóa học khí quyển và dữ liệu thời tiết tương lai), sau đó nạp vào mô hình XGBoost tương ứng với cụm và tầm nhìn dự báo. Bước thứ ba, giá trị dự báo được chuyển ngược (inverse-transform) về đơn vị $\mu g/m^3$ bằng bộ chuẩn hóa đã lưu trong quá trình huấn luyện, và hiển thị lên giao diện.

Mô hình XGBoost block 7 được chọn cho ứng dụng vì ba lý do: thời gian suy luận nhanh (dưới 1 giây cho 5 tầm nhìn), hiệu suất dẫn đầu hoặc gần dẫn đầu trên đa số cấu hình (như đã phân tích ở các mục trước), và không yêu cầu GPU để chạy suy luận.

9.2. Giao diện tổng quan

Hình 3.16 trình bày giao diện tổng quan của ứng dụng.



Hình 3.16. Giao diện tổng quan — thanh điều khiển bên trái, thẻ chỉ số và biểu đồ lịch sử 24 giờ

Giao diện chia thành hai phần chính. Phần bên trái là thanh điều khiển cho phép chọn trạm quan trắc từ danh sách 12 trạm, mỗi trạm hiển thị kèm nhãn cụm (Bắc/Nam), tên quận huyện và tỉnh thành. Khi chọn trạm, hệ thống hiển thị tọa độ GPS và loại mô hình XGBoost tương ứng (North hoặc South). Phần bên phải hiển thị năm thẻ chỉ số tại thời điểm mới nhất: $PM_{2.5}$, PM_{10} , nhiệt độ, độ ẩm và tốc độ gió. Bên dưới là nhãn trạng thái chất lượng không khí với mã màu theo thang AQI (xanh lá = Tốt, vàng = Trung bình, cam = Không tốt cho nhóm nhạy cảm, đỏ = Không tốt). Biểu đồ chính hiển thị diễn biến $PM_{2.5}$ trong 24 giờ gần nhất dưới dạng đường cong với ba đường ngưỡng AQI tham chiếu, kết hợp biểu đồ nhiệt độ ở phần dưới để người dùng nhận biết mối tương quan giữa hai yếu tố.

9.3. Hiện thị các chỉ số ô nhiễm

Hình 3.17 trình bày khu vực hiển thị xu hướng 24 giờ của sáu chỉ số ô nhiễm.




Hình 3.17. Biểu đồ thu nhỏ xu hướng 24 giờ của sáu chỉ số ô nhiễm

Mỗi chỉ số ($PM_{2.5}$, PM_{10} , CO, O_3 , NO_2 , SO_2) được hiển thị trong một ô riêng biệt gồm ba thành phần: giá trị hiện tại ở dạng số lớn, mũi tên chỉ hướng thay đổi so với giờ trước (tam giác lên màu cam = tăng, tam giác xuống màu xanh = giảm), và biểu đồ thu nhỏ dạng đường cong thể hiện xu hướng 24 giờ. Thiết kế này cho phép người dùng nhanh chóng nhận biết trạng thái hiện tại và chiều hướng biến động của từng chỉ số mà không cần phân tích biểu đồ chi tiết.

9.4. Khu vực dự báo

Hình 3.18 trình bày khu vực dự báo $PM_{2.5}$ của ứng dụng.



Hình 3.18. Khu vực dự báo $PM_{2.5}$ — năm thẻ dự báo và biểu đồ nổi lịch sử-dự báo

Khu vực dự báo gồm hai thành phần. Thành phần thứ nhất là năm thẻ hiển thị giá trị $PM_{2.5}$ dự báo tại các mốc $T+1$, $T+3$, $T+6$, $T+12$ và $T+24$ giờ. Mỗi thẻ hiển thị giá trị dự báo ($\mu g/m^3$), nhãn mức chất lượng không

khí và loại dự báo (ngắn hạn, trung ngắn, trung hạn, dài hạn). Màu sắc giá trị và viền thẻ thay đổi động theo thang AQI, giúp người dùng nhận biết ngay mức độ ô nhiễm dự kiến.

Thành phần thứ hai là biểu đồ kết hợp lịch sử và dự báo. Đường liền nét thể hiện giá trị $PM_{2.5}$ thực tế trong 24 giờ gần nhất, đường nét đứt thể hiện giá trị dự báo tại năm mốc thời gian tương lai. Đường dọc phân chia ranh giới giữa dữ liệu lịch sử và dự báo, kết hợp ba đường ngưỡng AQI nằm ngang để người dùng đối chiếu giá trị dự báo với các mức cảnh báo. Mỗi điểm dự báo trên biểu đồ có màu sắc tương ứng với mức AQI, tạo sự nhất quán với các thẻ dự báo phía trên.

Bên dưới khu vực dự báo, ứng dụng hiển thị bảng đối chiếu sáu mức AQI theo $PM_{2.5}$ (từ Tốt đến Nguy hiểm) với khoảng giá trị tương ứng, giúp người dùng hiểu ý nghĩa các mã màu được sử dụng xuyên suốt giao diện.

10. THẢO LUẬN

Chương này đã trình bày phân tích toàn diện kết quả thí nghiệm của sáu mô hình dự báo $PM_{2.5}$ trên 180 cấu hình (6 mô hình $\times$ 5 tầm nhìn $\times$ 3 block $\times$ 2 vùng). Phần thảo luận đánh giá mức độ đạt được từng mục tiêu nghiên cứu đã đề ra trong lời mở đầu, đồng thời phân tích các ưu điểm và hạn chế của nghiên cứu.

10.1. Đánh giá mức độ đạt mục tiêu

Mục tiêu thứ nhất — xây dựng pipeline thu thập và tiền xử lý dữ liệu — đã được hoàn thành. Từ 32 trạm quan trắc ban đầu, quy trình sàng lọc chất lượng dữ liệu đã chọn được 12 trạm (6 miền Bắc, 6 miền Nam) với dữ liệu theo giờ giai đoạn 01/2023 – 12/2025, đảm bảo bao phủ đầy đủ các chu kỳ mùa. Pipeline tiền xử lý bao gồm phát hiện lỗi cảm biến đóng băng, xử lý ngoại lai bằng IQR, nội suy giá trị thiếu và chuẩn hóa theo 8 chiến lược khác nhau tùy nhóm biến. Kết quả benchmark cho thấy dữ liệu sau tiền xử lý đủ chất lượng để huấn luyện cả sáu kiến trúc mô hình trên mọi cấu hình thí nghiệm.

Mục tiêu thứ hai — thiết kế đặc trưng kỹ thuật dựa trên kiến thức hóa học khí quyển — đã được triển khai. Hệ thống 134 đặc trưng đầu vào bao gồm 6 đặc trưng mới phản ánh khả năng oxy hóa, nguy cơ hình thành aerosol sulfate và mức độ ổn định nhiệt khí quyển, kết hợp với đặc trưng trễ, thống kê trượt và mã hóa chu kỳ. Hiệu suất XGBoost — mô hình sử dụng trực tiếp toàn bộ hệ thống đặc trưng — dẫn đầu trên block 5 và block 7, cho thấy hệ thống đặc trưng thủ công cung cấp thông tin dự báo có giá trị, đặc biệt khi dữ liệu huấn luyện hạn chế.

Mục tiêu thứ ba — huấn luyện và so sánh sáu mô hình — là nội dung chính của chương này. Phân tích cho thấy không có mô hình nào vượt trội tuyệt đối trên mọi cấu hình. XGBoost đạt hiệu suất cao nhất tại block 5 và block 7 với MAE thấp nhất, slope suy giảm chậm nhất và thời gian huấn luyện nhanh nhất (trung bình 72 giây). Tại block 30, các mô hình học sâu thu hẹp khoảng cách: iTransformer cải thiện R^2 lên 0,34 so với block 7, E-STGCN đạt slope thấp nhất (0,21 miền Bắc) nhờ tích chập đồ thị. Kết quả này phản ánh sự đánh đổi giữa yêu cầu dữ liệu và khả năng học biểu diễn: mô hình thống kê kê cổ điển cần ít dữ liệu nhưng giới hạn ở đặc trưng thủ công, trong khi mô hình học sâu cần nhiều dữ liệu nhưng có tiềm năng học được biểu diễn phức tạp hơn.

Mục tiêu thứ tư — đề xuất cơ chế Dynamic Graph — đã được triển khai trong mô hình ST-XLinear. Tuy nhiên, kết quả cho thấy ST-XLinear không vượt trội so với XLinear (mô hình nền không có thành phần không gian) trên đa số cấu hình: R^2 tại block 30 miền Bắc $T+24$ của ST-XLinear (0,37) thấp hơn XLinear (0,40). Nguyên nhân có thể bao gồm: mạng lưới 6 trạm trong mỗi cụm quá thưa để ma trận kề động tạo ra giá trị bổ sung đáng kể, và cơ chế cập nhật theo hướng gió có thể gây nhiễu khi hướng gió thay đổi nhanh trong ngày. E-STGCN sử dụng ma trận kề tĩnh (dựa trên khoảng cách địa lý) lại cho kết quả tốt hơn tại block 30, gợi ý rằng quan hệ không gian ổn định có thể phù hợp hơn cho mạng lưới thưa.

Mục tiêu thứ năm — triển khai ứng dụng web dự báo — đã hoàn thành như trình bày ở Mục 3.9. Ứng dụng cho phép tra cứu dự báo $PM_{2.5}$ tại 12 trạm với năm mốc thời gian, tích hợp mô hình XGBoost block 7 với thời gian suy luận dưới 1 giây.

10.2. Ưu điểm của nghiên cứu

Nghiên cứu có ba ưu điểm chính. Thứ nhất, quy mô benchmark toàn diện với 180 cấu hình thí nghiệm cho phép đánh giá hiệu suất mô hình trên nhiều chiều: tầm nhìn dự báo, chiến lược chia dữ liệu và vùng địa lý. Cách tiếp cận này giảm nguy cơ kết luận thiên lệch do chỉ đánh giá trên một cấu hình duy nhất — một hạn chế phổ biến trong các nghiên cứu dự báo chất lượng không khí.

Thứ hai, phân tích đa chiều kết hợp cả bốn chỉ số (MAE, RMSE, R^2 , MAPE) cùng các phân tích bổ sung (slope suy giảm, biểu đồ hộp, biểu đồ radar) cho phép nhận diện các đặc trưng mà một chỉ số đơn lẻ không thể phát hiện. Ví dụ, E-STGCN có R^2 cao nhưng MAE cũng cao — mâu thuẫn này chỉ được giải thích khi phân tích kết hợp nhiều chỉ số.

Thứ ba, nghiên cứu cung cấp phân tích nguyên nhân cho các quan sát thay vì chỉ báo cáo số liệu. Sự khác biệt hiệu suất giữa hai vùng được giải thích bằng đặc trưng phân phối dữ liệu, điều kiện khí tượng và mật độ không gian trạm; ảnh hưởng của block split được giải thích bằng yêu cầu dữ liệu tối thiểu của từng kiến trúc.

10.3. Hạn chế của nghiên cứu

Nghiên cứu tồn tại bốn hạn chế cần lưu ý. Thứ nhất, mạng lưới 12 trạm quan trắc (6 trạm mỗi cụm) là quy mô nhỏ so với diện tích lãnh thổ. Mật độ trạm thưa khiến các mô hình không gian (E-STGCN, ST-XLinear) không phát huy được tối đa tiềm năng kiến trúc, và kết quả chưa chắc tổng quát hóa được cho mạng lưới dày hơn.

Thứ hai, phương pháp Ensemble sử dụng trung bình trọng số tuyến tính đã cho thấy hiệu quả hạn chế. Các phương pháp kết hợp phi tuyến như stacking (sử dụng mô hình bậc hai để học cách kết hợp đầu ra của các mô hình thành phần) hoặc phương pháp kết hợp theo miền (gán trọng số khác nhau cho từng khoảng giá trị $PM_{2.5}$) có thể cải thiện kết quả nhưng chưa được khảo sát.

Thứ ba, đánh giá hiện tại sử dụng phương pháp block-based split thay vì phương pháp xác thực chéo chuỗi thời gian (time series cross-validation) với nhiều lần lặp. Mặc dù ba cấu hình block (5, 7, 30 ngày) cung cấp một mức độ đánh giá tính ổn định, kết quả có thể bị ảnh hưởng bởi đặc điểm cụ thể của các giai đoạn thời gian được chọn làm tập kiểm thử.

Thứ tư, nghiên cứu chưa so sánh với các phương pháp dự báo dựa trên mô phỏng vật lý (CMAQ, WRF-Chem) hoặc các mô hình ngôn ngữ lớn được tinh chỉnh cho chuỗi thời gian. Việc bổ sung các đường cơ sở này sẽ giúp định vị rõ hơn vị trí của các phương pháp học máy trong bài toán dự báo chất lượng không khí tại Việt Nam.

CHƯƠNG 4

KẾT LUẬN VÀ ĐỀ XUẤT

1. KẾT LUẬN CHUNG

Đồ án đã hoàn thành việc xây dựng và đánh giá một hệ thống dự báo nồng độ bụi mịn $PM_{2.5}$ tại Việt Nam, bao phủ toàn bộ quy trình từ thu thập dữ liệu thô đến triển khai ứng dụng web phục vụ tra cứu trực tuyến. Hệ thống được thiết kế theo kiến trúc pipeline gồm 5 khối chức năng liên kết tuần tự (thu thập — tiền xử lý — huấn luyện — đánh giá — triển khai), vận hành trên dữ liệu từ 12 trạm quan trắc thuộc 2 cụm vùng khí hậu (Bắc 6 trạm, Nam 6 trạm) trong giai đoạn 01/2023 – 12/2025, tần suất quan trắc 1 bản ghi/giờ. Quy mô thực nghiệm đạt 180 tổ hợp đánh giá ($6 \text{ mô hình} \times 5 \text{ tầm nhìn dự báo} \times 3 \text{ chiến lược chia dữ liệu} \times 2 \text{ vùng}$), được đo lường đồng thời trên 4 chỉ số thống kê (MAE, RMSE, R^2 , MAPE). Các kết luận chính rút ra từ quá trình nghiên cứu được trình bày theo từng mục tiêu đã đề ra.

1.1. Về thu thập và tiền xử lý dữ liệu

Pipeline thu thập tự động từ hai nguồn API — Weatherbit cho dữ liệu chất lượng không khí (7 biến: AQI, $PM_{2.5}$, PM_{10} , CO, NO_2 , SO_2 , O_3) và Open-Meteo cho dữ liệu khí tượng lịch sử ERA5 (17 biến thuộc 7 nhóm) — đã tổng hợp được khoảng 1,63 triệu bản ghi thô trên 32 trạm. Quy trình sàng lọc 6 tiêu chí thiết kế theo 3 cấp độ (toàn vẹn dữ liệu, quan hệ không gian, đa dạng địa lý) đã giảm từ 32 trạm ban đầu xuống còn 12 trạm đạt chuẩn, tương ứng tỷ lệ 37,5%. Tỷ lệ loại bỏ 62,5% phản ánh thực trạng chất lượng dữ liệu quan trắc môi trường tại Việt Nam: tỷ lệ dữ liệu khuyết cao (một số trạm vượt 40%), hiện tượng đóng băng cảm biến phổ biến, và sự trùng lặp giữa các trạm cùng khu vực (hệ số tương quan $r > 0,99$). Kết quả này cho thấy bước sàng lọc chất lượng là bắt buộc trước khi đưa dữ liệu vào mô hình, đặc biệt khi sử dụng các kiến trúc học sâu vốn nhạy cảm với nhiễu đầu vào.

Giai đoạn làm sạch 7 bước — gồm 3 giai đoạn ghép nối và chuẩn bị, phát hiện và gán nhãn lỗi, làm sạch và phục hồi — đã xử lý ba loại lỗi chính: dữ liệu đóng băng (phát hiện bằng độ lệch chuẩn trượt $< 10^{-6}$ trên cửa sổ 12 giờ cho 11 biến), giá trị ngoại lai (ngưỡng vật lý kết hợp $3 \times IQR$), và lỗi cảm biến quang học (đối chiếu chéo 3 điều kiện gồm đột biến $PM_{2.5}$, đột biến PM_{10} và ổn định khí gas). Giá trị khuyết sau phát hiện lỗi được phục hồi bằng nội suy tuyến tính cho khoảng nhỏ (≤ 6 giờ) và K láng giềng gần nhất ($K = 12$) cho khoảng lớn. Toàn bộ chuỗi kết quả sau làm sạch đạt tính liên tục hoàn toàn trên 25.536 mốc giờ cho mỗi trạm, đủ điều kiện cho các phép tính cửa sổ trượt và xây dựng đặc trưng ở giai đoạn tiếp theo.

1.2. Về kỹ thuật đặc trưng và chuẩn hóa

Hệ thống 134 đặc trưng phân thành 8 nhóm được thiết kế theo nguyên tắc phân tầng: từ trạng thái hiện tại (nhóm 1–3 gồm 37 biến thô, tương tác và cờ chất lượng), thông tin lịch sử (nhóm 4–6 gồm 44 biến trễ và thống kê trượt, toàn bộ dịch chuyển 1 bước thời gian chống rò rỉ dữ liệu), tín hiệu chu kỳ (nhóm 7 gồm 14 biến mã hóa thời gian bằng hàm lượng giác sin/cos), đến dữ liệu khí tượng tương lai (nhóm 8 gồm khoảng 20 biến dịch chuyển theo tầm nhìn dự báo). Trong số đó, 10 đặc trưng tương tác được thiết kế dựa trên nguyên lý hóa khí quyển (tiềm năng oxy hóa $O_3 \times (SO_2 + NO_2)$, nguy cơ sulfate âm bằng tích độ ẩm và SO_2 , ổn định nhiệt bằng hiệu nhiệt độ không khí và nhiệt độ đất) — đây là các biến mà theo tổng quan tài liệu tại Chương 1, chưa có nghiên cứu nào ứng dụng cho bài toán dự báo $PM_{2.5}$ tại Việt Nam.

Chiến lược chuẩn hóa theo 8 nhóm — lựa chọn tổ hợp phương pháp (log1p, RobustScaler, StandardScaler, MinMaxScaler, cắt phân vị hoặc không chuẩn hóa) phù hợp với đặc tính phân phối của từng nhóm biến — đã đảm bảo dữ liệu đầu vào đồng nhất về thang đo mà vẫn bảo toàn đặc trưng phân phối riêng biệt. Các bộ chuẩn hóa chỉ

được khớp trên tập huấn luyện và lưu trữ dưới dạng tệp .pkl theo từng trạm, phục vụ biến đổi ngược khi suy luận. Hiệu suất dẫn đầu của XGBoost — mô hình sử dụng trực tiếp toàn bộ hệ thống 230+ đặc trưng (134 đặc trưng cơ sở cộng thêm lag mở rộng, rolling mở rộng, spatial neighbor và station one-hot) — trên block 5 và block 7 cho thấy hệ thống đặc trưng thủ công cung cấp thông tin dự báo có giá trị cao, đặc biệt khi dữ liệu huấn luyện liên tục hạn chế.

1.3. Về kết quả đối chuẩn mô hình

Phân tích trên 180 cấu hình thí nghiệm dẫn đến ba phát hiện chính mang tính hệ thống.

Phát hiện thứ nhất là không tồn tại mô hình đơn lẻ nào vượt trội tuyệt đối trên mọi cấu hình, và hiệu suất tương đối giữa các kiến trúc phụ thuộc mạnh vào sự kết hợp giữa chiến lược chia dữ liệu và đặc điểm vùng địa lý. XGBoost đạt MAE thấp nhất và hệ số suy giảm (slope) chậm nhất trên block 5 và block 7, coi là lựa chọn tối ưu cho kịch bản dữ liệu huấn luyện liên tục hạn chế (120–168 bước thời gian mỗi khối). Cụ thể, tại block 7 miền Bắc, XGBoost đạt $MAE = 6,17$ tại $T+1$ và $12,87$ tại $T+24$, với chênh lệch (ΔMAE) chỉ $6,70 \mu g/m^3$ — thấp hơn đáng kể so với iTransformer ($\Delta = 12,05$) và XLinear ($\Delta = 11,36$). Tuy nhiên, tại block 30 (720 bước thời gian liên tục mỗi khối), các mô hình học sâu thu hẹp khoảng cách một cách đáng kể: iTransformer cải thiện R^2 từ 0,06 (block 7) lên 0,40 (block 30) tại miền Bắc $T+24$, tức tăng gấp 6,7 lần; E-STGCN ghi nhận slope thấp nhất toàn bảng (0,21 miền Bắc, 0,30 miền Nam) tại block 30, thấp hơn cả XGBoost (0,26 và 0,54). Tại block 30 miền Bắc $T+1$, ST-XLinear ($MAE = 5,84$) thậm chí vượt qua XGBoost ($MAE = 6,42$). Những kết quả này phản ánh sự đánh đổi giữa yêu cầu dữ liệu và khả năng biểu diễn: mô hình cây quyết định cần ít dữ liệu nhưng bị giới hạn bởi đặc trưng thủ công, trong khi mô hình học sâu cần nhiều dữ liệu nhưng có tiềm năng tự học biểu diễn phức tạp hơn.

Phát hiện thứ hai là chênh lệch hiệu suất giữa hai vùng mang tính hệ thống và không phụ thuộc kiến trúc mô hình. RMSE tại miền Nam luôn cao hơn miền Bắc với tỷ lệ dao động 1,1 lần tại $T+1$ đến 2,7–4,5 lần tại $T+24$ tùy mô hình. Đồng thời, MAE tại $T+1$ miền Nam lại thấp hơn miền Bắc (4,04–8,79 so với 5,84–9,34 trên block 5). Sự mâu thuẫn biểu kiến giữa MAE thấp nhưng RMSE cao ở miền Nam được giải thích bằng đặc tính phân phối: khu vực phía Nam có giá trị nền $PM_{2.5}$ thấp phổ biến (dưới $20 \mu g/m^3$) xen lẫn các đợt ô nhiễm cực đoan vượt $200 \mu g/m^3$, tạo ra phân phối đuôi dài. Phân phối dạng này khiến đa số dự báo có sai lệch nhỏ (MAE thấp), nhưng các sai lệch cực đoan bị phóng đại qua phép bình phương trong RMSE. Ba nguyên nhân gốc rễ bao gồm: sự khác biệt về phân phối nồng độ, đặc trưng khí tượng (miền Bắc có tính mùa vụ ổn định do gió mùa Đông Bắc, miền Nam có biến thiên phi tuyến do chuyển đổi nhanh mùa khô–mưa), và mật độ không gian của mạng lưới trạm (6 trạm miền Bắc tập trung trong đồng bằng sông Hồng với tương quan không gian cao, 6 trạm miền Nam phân bố rải rác từ đồng bằng đến ven biển).

Phát hiện thứ ba liên quan đến ảnh hưởng của chiến lược chia dữ liệu. Chiến lược block-based split tĩnh chia dữ liệu theo khối ngày tuần hoàn, trong đó block 30 cung cấp khoảng 720 bước thời gian liên tục mỗi khối — gấp 6 lần block 5 (120 bước) và gấp 4,3 lần block 7 (168 bước). Ảnh hưởng khác nhau rõ rệt theo nhóm kiến trúc: XGBoost có MAE dao động chỉ $0,20 \mu g/m^3$ qua ba block tại miền Bắc $T+24$ (biên độ 12,67–12,87); iTransformer ghi nhận bước nhảy R^2 lớn nhất (+0,34 từ block 7 sang block 30); E-STGCN cải thiện đều đặn nhất qua ba bước nhảy. Hai nhóm kiến trúc phân biệt rõ: nhóm ổn định với mọi block (XGBoost, nhờ không phụ thuộc tính liên tục dữ liệu) và nhóm cải thiện mạnh theo block (iTransformer, E-STGCN, XLinear, ST-XLinear, nhờ cơ chế attention và tích chập đồ thị cần ngưỡng dữ liệu tối thiểu để ước lượng tham số hiệu quả).

1.4. Về mô hình đề xuất ST-XLinear

Mô hình ST-XLinear — kiến trúc đề xuất tích hợp Dynamic Graph Builder vào khung XLinear nhằm khai thác đồng thời phụ thuộc thời gian và không gian — chưa đạt được kỳ vọng vượt trội so với mô hình nền XLinear trên đa số cấu hình. R^2 tại block 30 miền Bắc $T+24$ của ST-XLinear (0,37) thấp hơn XLinear (0,40) và E-STGCN (0,41). Tại block 30 miền Nam $T+24$, ST-XLinear ($MAE = 19,00$) cũng cao hơn E-STGCN ($MAE = 15,80$) và iTransformer ($MAE = 15,33$).

Kết quả này cho phép rút ra hai bài học kỹ thuật. Bài học thứ nhất, mạng lưới 6 trạm trong mỗi cụm có thể quá thưa để ma trận kề động — dù tích hợp thông tin hướng gió và vận tốc gió — tạo ra tín hiệu bổ sung có ý nghĩa so với ma trận kề tĩnh dựa trên khoảng cách. Khi số nút trong đồ thị nhỏ, mỗi nút chỉ có tối đa 5 kết nối khả dụng, và thông tin từ tích chập đồ thị bị giới hạn bởi quy mô lân cận. E-STGCN với ma trận kề tĩnh lại cho kết quả tốt hơn tại block 30, gợi ý rằng quan hệ không gian ổn định có thể phù hợp hơn quan hệ động cho mạng lưới thưa, do cập nhật hướng gió liên tục gây dao động trong quá trình tối ưu khi số mẫu không gian chưa đủ. Bài học thứ hai, cơ chế Attention Pooling tóm tắt đặc trưng thời gian thành Node Summary trước khi đưa vào Spatial GCN có thể gây mất thông tin chi tiết trong chuỗi, đặc biệt ở tầm nhìn dài khi mà chính các chi tiết biến động trong cửa sổ 48 giờ mang tính dự báo cao.

Mặc dù chưa đạt hiệu suất vượt trội, ST-XLinear vẫn cho thấy tính khả thi của kiến trúc lai temporal-spatial: tại block 30 miền Bắc $T+1$, ST-XLinear đạt $MAE = 5,84$ (thấp nhất toàn bảng) và $MAPE = 19,49\%$ (thấp nhất toàn bảng). Điều này cho thấy tiềm năng của kiến trúc khi được áp dụng trên mạng lưới dày hơn và với các cải tiến cơ chế tổng hợp không gian phù hợp.

1.5. Về phương pháp Ensemble

Phương pháp Ensemble trung bình trọng số tuyến tính — kết hợp đầu ra XLinear và E-STGCN với trọng số α tối ưu qua Grid Search trên tập xác thực — cho hiệu quả hạn chế. Chênh lệch Δ_{Ensemble} ($MAE_{\text{Ensemble}} - MAE_{\text{min}}$) dương trên 28/30 cấu hình, dao động từ 0,01 đến $3,58 \mu g/m^3$, tức Ensemble kém hơn hoặc bằng mô hình thành phần tốt nhất trên hầu hết mọi trường hợp.

Phân tích nguyên nhân cho thấy ba yếu tố chính. Thứ nhất, tương quan sai số cao giữa các mô hình thành phần khi được huấn luyện trên cùng bộ dữ liệu và phân chia train/validation/test, khiến chúng mắc lỗi tương tự trên cùng giai đoạn. Thứ hai, chênh lệch hiệu suất lớn giữa mô hình tốt nhất (thường là XGBoost hoặc XLinear) và các mô hình còn lại buộc cơ chế tối ưu trên tập xác thực gán trọng số gần như toàn bộ cho mô hình dẫn đầu, khiến Ensemble suy biến thành mô hình đơn lẻ bị pha loãng. Thứ ba, cơ chế kết hợp tuyến tính giả định sai số đồng nhất về phương sai — giả định không thỏa mãn khi phân phối $PM_{2.5}$ có đuôi dài, dẫn đến trung bình tuyến tính phóng đại sai lệch phần trăm tại các giá trị nền thấp (MAPE của Ensemble đạt tới 120,80% tại block 7 miền Nam $T+24$, cao nhất trong 6 mô hình).

1.6. Về chi phí tính toán và triển khai

Sáu mô hình phân thành ba nhóm chi phí rõ rệt: nhóm chi phí thấp gồm XGBoost (trung bình 72 giây) và E-STGCN (trung bình 183 giây); nhóm chi phí trung bình gồm Ensemble (1.699 giây) và iTransformer (1.879 giây); nhóm chi phí cao gồm ST-XLinear (2.573 giây) và XLinear (3.575 giây). Khoảng cách giữa nhóm thấp nhất và cao nhất lên tới 50 lần (72 giây so với 3.575 giây), đặt ra bài toán đánh đổi giữa hiệu suất dự báo và chi phí vận hành trong triển khai thực tế.

XGBoost đặc biệt phù hợp cho kịch bản triển khai thời gian thực nhờ ba lợi thế: thời gian huấn luyện ngắn nhất (cho phép tái huấn luyện hàng giờ), không yêu cầu GPU, và thời gian suy luận dưới 1 giây cho 5 tầm nhìn dự báo đồng thời. Ứng dụng web trên nền tảng Streamlit tích hợp mô hình XGBoost block 7 đã minh chứng tính khả thi của việc triển khai hệ thống dự báo $PM_{2.5}$ trên phần cứng phổ thông (laptop i5-12500H, 16 GB RAM, GPU RTX 3050) phục vụ tra cứu trực tuyến tại 12 trạm.

1.7. Tổng hợp đánh giá

Xét tổng thể 5 mục tiêu ban đầu, 3 mục tiêu đã hoàn thành đạt yêu cầu (pipeline dữ liệu, benchmark 6 mô hình, triển khai ứng dụng web). Mục tiêu kỹ thuật đặc trưng đã hoàn thành ở mức triển khai nhưng chưa có thực nghiệm phân lập để đo lường riêng biệt đóng góp của từng nhóm đặc trưng đối với hiệu suất mô hình. Mục tiêu đề

xuất Dynamic Graph (ST-XLinear) đã hoàn thành ở mức kiến trúc và thực nghiệm nhưng chưa đạt hiệu suất vượt trội như kỳ vọng, đồng thời mở ra các giả thuyết cần kiểm chứng trên mạng lưới trạm dày hơn.

Đóng góp chính của đề án nằm ở ba khía cạnh. Thứ nhất, thiết lập khung đối chuẩn toàn diện nhất từ trước đến nay cho bài toán dự báo $PM_{2.5}$ tại Việt Nam, bao phủ đồng thời Machine Learning cổ điển, Deep Learning temporal, Transformer, và Spatio-Temporal Graph trên cùng bộ dữ liệu quan trắc đa năm, đa vùng, đa horizon và đa chiến lược phân chia — lấp đầy khoảng trống “thiếu hụt hệ thống đánh giá đối chuẩn đồng thời” đã nhận diện tại Chương 1. Thứ hai, xây dựng hệ thống 134 đặc trưng tích hợp kiến thức hóa khí quyển vào quá trình kỹ nghệ đặc trưng cho dữ liệu Việt Nam, khắc phục phần nào khoảng trống “kỹ nghệ hóa đặc trưng chưa dựa trên nguyên lý khí quyển học”. Thứ ba, phân tích định lượng ảnh hưởng của chiến lược chia dữ liệu đến hiệu suất từng kiến trúc, cung cấp hướng dẫn thực tiễn cho việc lựa chọn mô hình phù hợp với quy mô dữ liệu sẵn có.

2. HẠN CHẾ

Mặc dù đã đạt được các kết quả nhất định, nghiên cứu tồn tại một số hạn chế cần được ghi nhận nhằm đạt kết quả trong bối cảnh đúng đắn.

2.1. Quy mô mạng lưới trạm

Mạng lưới 12 trạm (6 trạm/cụm) là quy mô nhỏ so với diện tích lãnh thổ. Mật độ trạm thưa khiến các mô hình không gian (E-STGCN, ST-XLinear) không phát huy được tối đa tiềm năng kiến trúc: tích chập đồ thị trên 6 nút chỉ khai thác được tương quan cục bộ giới hạn. Kết quả về hiệu quả (hoặc thiếu hiệu quả) của các kiến trúc không gian chưa thể tổng quát hóa cho mạng lưới dày hơn, nơi ma trận kề phản ánh trung thực hơn cấu trúc vận chuyển khí quyển. Ngoài ra, 12 trạm chỉ bao phủ 13 tỉnh/thành phố, chưa đại diện cho các vùng khí hậu đa dạng khác như Tây Nguyên, Duyên hải miền Trung hay Đồng bằng sông Cửu Long mở rộng.

2.2. Thiếu thực nghiệm phân lập đặc trưng

Hệ thống 134 đặc trưng trong 8 nhóm được sử dụng đồng thời cho mô hình, nhưng chưa có thực nghiệm phân lập đo lường đóng góp riêng biệt của từng nhóm. Cụ thể, chưa thể xác định mức độ đóng góp biên của nhóm đặc trưng tương tác hóa khí quyển (nhóm 2) so với các nhóm trễ truyền thống (nhóm 4–6), hoặc mức ảnh hưởng của nhóm thời tiết tương lai (nhóm 8) đối với từng tầm nhìn dự báo cụ thể. Việc thiếu thông tin này khiến khó xác định hướng tối ưu hệ thống đặc trưng cho các ứng dụng trong tương lai.

2.3. Phương pháp Ensemble đơn giản

Phương pháp trung bình trọng số tuyến tính là cơ chế kết hợp đơn giản nhất. Nghiên cứu chưa khảo sát các phương pháp kết hợp phi tuyến hoặc kết hợp thích ứng theo miền giá trị. Kết luận “Ensemble không hiệu quả” cần được giới hạn cho phương pháp trung bình trọng số tuyến tính, không nên mở rộng cho toàn bộ lớp phương pháp ensemble learning.

2.4. Đánh giá chưa kèm khoảng tin cậy

Phương pháp block-based split tạo ra một bộ kết quả duy nhất cho mỗi cấu hình thay vì phân phối kết quả. Các chênh lệch hiệu suất nhỏ giữa mô hình (ví dụ: MAE 5,84 của ST-XLinear so với 5,88 của XLinear tại block 30 miền Bắc $T+1$) chưa thể khẳng định có ý nghĩa thống kê hay chỉ là biến động do cách phân chia dữ liệu. Phương pháp xác thực chéo chuỗi thời gian với nhiều lần lặp sẽ cho phép kiểm định thống kê các chênh lệch này.

2.5. Thiếu đường cơ sở bên ngoài

Nghiên cứu chỉ so sánh nội bộ giữa 6 kiến trúc Machine Learning/Deep Learning mà chưa đối chiếu với mô hình mô phỏng vật lý-hóa học — vốn đang là công cụ chủ đạo trong các nghiên cứu dự báo chất lượng không khí tại Việt Nam. Thiếu vắng đường cơ sở này khiến khó xác định liệu nhóm phương pháp thống kê/học máy có thể thay thế hoặc bổ trợ cho mô phỏng số ở quy mô khu vực.

3. KIẾN NGHỊ VÀ HƯỚNG PHÁT TRIỂN

Dựa trên các kết quả đạt được và hạn chế đã nhận diện, phần này trình bày các kiến nghị cải tiến và hướng phát triển thang hệ thống dự báo cho các nghiên cứu tiếp theo. Mỗi hướng phát triển được liên kết trực tiếp với một hoặc nhiều hạn chế cụ thể, nhằm đảm bảo tính khả thi và tính hệ thống.

3.1. Mở rộng quy mô mạng lưới trạm quan trắc

Mạng lưới 12 trạm (6 trạm mỗi cụm) hiện tại chưa đủ mật độ để các mô hình không gian phát huy tối đa tiềm năng kiến trúc. Kết quả thực nghiệm cho thấy E-STGCN đạt slope thấp nhất tại block 30 (0,21 miền Bắc) nhờ khai thác tương quan liên trạm qua ma trận kernel Gaussian, trong khi ST-XLinear với Dynamic Graph chưa tạo ra giá trị bổ sung rõ rệt trên mạng lưới thưa — R^2 tại block 30 miền Bắc $T+24$ của ST-XLinear (0,37) thấp hơn cả E-STGCN (0,41) lẫn XLinear nền (0,40).

Việc mở rộng lên 30–50 trạm, đặc biệt gia tăng mật độ tại các khu vực đô thị lớn (Hà Nội, TP. Hồ Chí Minh), các cụm công nghiệp trọng điểm (Bắc Ninh, Bình Dương, Đồng Nai) và các vùng khí hậu chưa được bao phủ (Tây Nguyên, Duyên hải miền Trung), sẽ mang lại hai lợi ích trực tiếp. Thứ nhất, mạng lưới dày hơn cung cấp đủ ngữ cảnh không gian để kiểm chứng giả thuyết thiết kế cốt lõi của Dynamic Graph Builder: liệu ma trận kề cập nhật liên tục theo hướng gió có thực sự phản ánh trung thực hơn quá trình vận chuyển ô nhiễm so với ma trận kề tĩnh, khi mỗi nút có 10–20 kết nối thay vì chỉ 5 như hiện tại. Thứ hai, mạng lưới đa vùng bao phủ nhiều chế độ khí hậu khác nhau cho phép đánh giá tính tổng quát hóa của mô hình vượt ra ngoài hai cụm Bắc–Nam hiện tại, từ đó xác định liệu các mẫu hình hiệu suất quan sát được (chênh lệch vùng, ảnh hưởng block) có bền vững hay phụ thuộc vào đặc tính cụ thể của dữ liệu đồng bằng sông Hồng và đồng bằng sông Cửu Long.

Về mặt kỹ thuật, mở rộng mạng lưới đặt ra thách thức về phép tích chập đồ thị trên đồ thị lớn: ma trận kề kích thước 50×50 làm tăng chi phí tính toán và bộ nhớ gấp khoảng 70 lần so với ma trận 6×6 hiện tại. Các phương pháp lấy mẫu đồ thị hoặc tích chập đồ thị thưa cần được xem xét để duy trì tính khả thi tính toán.

3.2. Thực nghiệm phân lập đặc trưng

Hệ thống 134 đặc trưng trong 8 nhóm hiện được sử dụng đồng thời mà chưa có đánh giá định lượng đóng góp biên của từng nhóm. Để xác định hướng tối ưu, nghiên cứu tiếp theo cần thực hiện thực nghiệm phân lập theo hai cách tiếp cận bổ sung. Cách tiếp cận thứ nhất là loại bỏ tuần tự: huấn luyện mô hình XGBoost 8 lần, mỗi lần loại bỏ 1 trong 8 nhóm đặc trưng, đo mức suy giảm MAE tương ứng. Nhóm gây suy giảm lớn nhất khi bị loại bỏ là nhóm có đóng góp biên cao nhất. Cách tiếp cận thứ hai là thêm dần: bắt đầu từ nhóm đặc trưng thô (nhóm 1), lần lượt thêm từng nhóm theo thứ tự và đo mức cải thiện tích lũy. Hai cách tiếp cận cho kết quả bổ sung: loại bỏ tuần tự đánh giá đóng góp trong ngữ cảnh đầy đủ, thêm dần đánh giá đóng góp tăng dần.

Đặc biệt, cần đo lường riêng ảnh hưởng của nhóm đặc trưng tương tác hóa khí quyển (nhóm 2 gồm tiềm năng oxy hóa, nguy cơ sulfate ẩm, ổn định nhiệt) so với nhóm truyền thống (nhóm 4–6). Nếu nhóm 2 cho đóng góp biên đáng kể, điều này xác nhận giá trị của việc tích hợp kiến thức lĩnh vực vào kỹ nghệ đặc trưng. Nếu đóng góp không đáng kể, nhóm này có thể được loại bỏ để giảm chiều đầu vào và tăng tốc huấn luyện.

3.3. Cải tiến phương pháp kết hợp mô hình

Phương pháp Ensemble trung bình trọng số tuyến tính cho thấy hiệu quả hạn chế do ba yếu tố đã phân tích (tương quan sai số, chênh lệch hiệu suất, giả định tuyến tính). Các hướng cải tiến cần tập trung vào việc giải quyết từng yếu tố.

Để giảm tương quan sai số, nghiên cứu có thể áp dụng chiến lược đa dạng hóa dữ liệu huấn luyện: thay vì huấn luyện mọi mô hình trên cùng bộ dữ liệu, mỗi mô hình thành phần sử dụng tập con đặc trưng khác nhau — một mô hình chỉ sử dụng đặc trưng khí tượng, mô hình khác chỉ sử dụng đặc trưng hóa học, mô hình thứ ba sử dụng toàn bộ. Sự đa dạng về đầu vào dẫn đến đa dạng về mẫu hình sai số, tạo điều kiện thuận lợi cho kết hợp triệt tiêu.

Để khắc phục giả định tuyến tính, phương pháp stacking nên được xem xét: sử dụng mô hình bậc hai (có thể là gradient boosting hoặc mạng nơ-ron nhỏ) để học hàm kết hợp phi tuyến từ các đầu ra mô hình thành phần. Cơ chế kết hợp thích ứng theo miền giá trị cũng khả thi: gán trọng số khác nhau tùy theo dải $PM_{2.5}$ mà mô hình đang dự báo (ví dụ: ưu tiên XGBoost khi $PM_{2.5}$ dự báo thuộc dải thấp, ưu tiên E-STGCN khi thuộc dải cao). Phương pháp Mixture of Experts, trong đó một mạng gating nhỏ quyết định trọng số kết hợp dựa trên ngữ cảnh đầu vào (giờ trong ngày, mùa, điều kiện gió), có thể khai thác sự chuyên biệt hóa theo kịch bản của từng mô hình.

3.4. Tích hợp dữ liệu dự báo khí tượng số

Nhóm 8 trong hệ thống đặc trưng (thời tiết tương lai) hiện sử dụng giá trị thực tế quan trắc tại thời điểm tương lai trong pha huấn luyện và đánh giá, nhằm đo lường giới hạn trên của hiệu năng dự báo khi thông tin khí tượng hoàn hảo. Khi triển khai thực tế, giá trị này phải được thay thế bằng đầu ra từ mô hình dự báo khí tượng số như GFS (Global Forecast System) hoặc ECMWF IFS. Sai số dự báo NWP — vốn tăng theo tầm nhìn dự báo — sẽ lan truyền vào mô hình $PM_{2.5}$ và gây suy giảm hiệu suất, đặc biệt ở $T+12$ và $T+24$ giờ.

Để giảm thiểu tác động này, hai chiến lược cần được khảo sát. Chiến lược thứ nhất là huấn luyện mô hình trực tiếp trên đầu ra NWP (thay vì giá trị quan trắc thực tế) cho nhóm 8: điều này cho phép mô hình $PM_{2.5}$ tự học cách bù trừ sai số hệ thống của NWP trong quá trình tối ưu hàm mất mát. Chiến lược thứ hai là bổ sung biến “sai số NWP” (hiệu giữa dự báo NWP và giá trị quan trắc tại cùng thời điểm) làm đặc trưng bổ sung, cung cấp cho mô hình thông tin về mức độ tin cậy của dữ liệu khí tượng đầu vào. Cần thực hiện thí nghiệm đối sánh 3 cấu hình (thời tiết thực, thời tiết NWP, thời tiết NWP có hiệu chỉnh) trên cùng mô hình XGBoost để đo lường định lượng mức suy giảm và hiệu quả bù trừ.

3.5. Áp dụng xác thực chéo chuỗi thời gian

Phương pháp block-based split hiện tại với 3 cấu hình (block 5, block 7, block 30) đã cung cấp một mức đánh giá tính ổn định qua các chiến lược phân chia, nhưng mỗi cấu hình chỉ tạo ra một bộ kết quả duy nhất. Các chênh lệch hiệu suất nhỏ — ví dụ $MAE = 5,84$ (ST-XLinear) so với $5,88$ (XLinear) tại block 30 miền Bắc $T+1$, chênh lệch chỉ $0,04 \mu g/m^3$ — chưa thể khẳng định có ý nghĩa thống kê.

Phương pháp xác thực chéo mở rộng (expanding window cross-validation) phù hợp cho dữ liệu chuỗi thời gian: cửa sổ huấn luyện mở rộng dần qua thời gian, trong khi cửa sổ kiểm thử trượt sang giai đoạn tiếp theo. Với 3 năm dữ liệu (01/2023 – 12/2025), có thể thiết kế 6–12 lần lặp với cửa sổ kiểm thử 3–6 tháng, tạo ra phân phối kết quả cho mỗi chỉ số đánh giá. Phân phối này cho phép: (i) tính khoảng tin cậy 95% cho MAE, RMSE, R^2 của mỗi mô hình; (ii) thực hiện kiểm định Wilcoxon signed-rank hoặc Friedman test để xác định liệu chênh lệch giữa các mô hình có ý nghĩa thống kê; và (iii) phát hiện liệu các mẫu hình hiệu suất (sự vượt trội của E-STGCN tại block 30, bước nhảy R^2 của iTransformer) có bền vững qua nhiều lần phân chia hay chỉ là sản phẩm của đặc điểm giai đoạn thời gian cụ thể.

3.6. Mở rộng so sánh với đường cơ sở bổ sung

Nghiên cứu hiện tại tập trung so sánh nội bộ giữa 6 kiến trúc Machine Learning và Deep Learning. Để định vị rõ hơn vị trí của nhóm phương pháp này trong bài toán dự báo chất lượng không khí tại Việt Nam, hai nhóm đường cơ sở cần được bổ sung.

Nhóm thứ nhất là mô hình mô phỏng vật lý — hóa học, đặc biệt hệ thống CMAQ kết hợp WRF — vốn đang là công cụ chủ đạo trong các nghiên cứu trong nước. Nguyen et al. (2024) báo cáo mô hình CMAQ kết hợp WRF đạt MAPE xấp xỉ 63% tại điều kiện phức tạp, cao hơn đáng kể so với XGBoost (21–54% tùy cấu hình) trong nghiên cứu này. Tuy nhiên, so sánh trực tiếp giữa hai phương pháp trên cùng tập dữ liệu, cùng khoảng thời gian và cùng vị trí trạm vẫn chưa được thực hiện. Thí nghiệm đối sánh này sẽ xác định liệu các phương pháp học máy có thể thay thế (khi dữ liệu quan trắc đủ lớn) hoặc bổ trợ (đầu ra CMAQ làm đặc trưng đầu vào bổ sung) cho mô phỏng số ở quy mô khu vực.

Nhóm thứ hai là các mô hình nền tảng cho chuỗi thời gian — ví dụ: TimesFM (Google), Chronos (Amazon), Lag-Llama hoặc các biến thể mô hình ngôn ngữ lớn được tinh chỉnh cho dự báo. Các mô hình này được huấn luyện trước trên hàng tỷ điểm dữ liệu chuỗi thời gian đa ngành, và có tiềm năng đạt hiệu suất cao ngay cả khi dữ liệu miền ứng dụng hạn chế — chính là điều kiện thường gặp trong dữ liệu quan trắc môi trường tại Việt Nam. Việc đánh giá liệu khả năng học chuyển giao từ dữ liệu đa miền có mang lại lợi thế cạnh tranh so với các mô hình huấn luyện từ đầu sẽ cung cấp định hướng dài hạn cho hệ thống dự báo.

3.7. Nâng cấp ứng dụng triển khai

Ứng dụng web hiện tại hoạt động ở chế độ tra cứu thủ công: người dùng chủ động truy cập giao diện, chọn trạm và nhận kết quả dự báo. Mô hình triển khai này phù hợp cho giai đoạn nghiên cứu và minh chứng tính khả thi (proof of concept), nhưng chưa đáp ứng yêu cầu vận hành trong thực tế khi cần giám sát liên tục và cảnh báo chủ động.

Để nâng cấp hệ thống lên mức vận hành, ba thành phần cần được bổ sung. Thành phần thứ nhất là bộ thu thập dữ liệu tự động hoạt động theo lịch trình cron job với tần suất hàng giờ, đồng bộ dữ liệu mới nhất từ Weatherbit API và Open-Meteo API, thực hiện làm sạch và xây dựng đặc trưng theo cùng pipeline đã thiết kế tại Chương 2, sau đó lưu trữ vào cơ sở dữ liệu trung gian phục vụ suy luận. Thành phần thứ hai là cơ chế tái huấn luyện mô hình định kỳ với tần suất hàng tuần hoặc hàng tháng, nhằm thích ứng với xu hướng phân phối dữ liệu thay đổi theo thời gian — đặc biệt quan trọng khi chuyển mùa hoặc khi có thay đổi nguồn phát thải trong khu vực. Thời gian huấn luyện XGBoost trung bình 72 giây cho thấy tái huấn luyện định kỳ hoàn toàn khả thi trên phần cứng phổ thông. Thành phần thứ ba là module cảnh báo tự động: khi giá trị $PM_{2.5}$ dự báo tại bất kỳ mốc thời gian nào ($T+1$ đến $T+24$) vượt ngưỡng cảnh báo theo quy chuẩn (ví dụ: trên $75 \mu g/m^3$ tương ứng mức “Không tốt cho nhóm nhạy cảm” theo thang AQI), hệ thống gửi thông báo đẩy qua các kênh tích hợp (email, ứng dụng nhắn tin) đến người dùng đã đăng ký, phục vụ trực tiếp nhu cầu bảo vệ sức khỏe cộng đồng — đặc biệt trong các đợt ô nhiễm nghiêm trọng vào mùa đông tại khu vực đồng bằng sông Hồng nơi nồng độ $PM_{2.5}$ có thể đạt 50–84 $\mu g/m^3$ ở tầng thấp.

Ngoài ba thành phần trên, giao diện ứng dụng có thể được mở rộng thêm tính năng hiển thị bản đồ nhiệt nội suy không gian — sử dụng phương pháp Kriging hoặc IDW (Inverse Distance Weighting) trên đầu ra dự báo của 12 trạm để ước lượng nồng độ $PM_{2.5}$ tại các vị trí không có trạm quan trắc. Tính năng này mang lại giá trị trực quan cho người dùng phổ thông và hỗ trợ cơ quan quản lý đánh giá diện rộng chất lượng không khí mà không cần đầu tư thêm hạ tầng trạm quan trắc.

3.8. Cải tiến kiến trúc Dynamic Graph

Kết quả thí nghiệm cho thấy ST-XLinear chưa vượt trội như kỳ vọng, tuy nhiên kiến trúc lai temporal–spatial vẫn đạt hiệu suất dẫn đầu tại một số cấu hình cụ thể (MAE thấp nhất tại block 30 miền Bắc $T+1$). Để phát huy tiềm năng, ba hướng cải tiến kiến trúc cần được xem xét.

Hướng thứ nhất là thay thế cơ chế Attention Pooling (hiện tóm tắt toàn bộ chuỗi thời gian thành một vector Node Summary duy nhất trước khi đưa vào Spatial GCN) bằng cơ chế tích chập không gian đa bước thời gian: thực hiện tích chập đồ thị tại mỗi bước thời gian t trong cửa sổ 48 giờ, sau đó mới tổng hợp theo chiều thời gian. Cách tiếp cận này bảo toàn thông tin chi tiết về biến động trong cửa sổ mà Attention Pooling có thể đã bỏ sót, với đổi lấy chi phí tính toán tăng tuyến tính theo độ dài cửa sổ.

Hướng thứ hai là áp dụng ma trận kề đa tầng: kết hợp đồng thời ma trận kề tĩnh (khoảng cách Haversine), ma trận kề động theo gió (Dynamic Graph hiện tại), và ma trận kề có thể học — trong đó ma trận có thể học được tối ưu trực tiếp qua lan truyền ngược, cho phép mô hình tự phát hiện các mối quan hệ không gian ẩn mà khoảng cách vật lý và hướng gió chưa nắm bắt được. Tổng hợp ba nguồn thông tin không gian này có thể giúp mô hình thích ứng với nhiều chế độ vận chuyển ô nhiễm khác nhau.

Hướng thứ ba là tích hợp cơ chế thích ứng trọng số α_{graph} (hiện cố định, kiểm soát tỷ lệ giữa khoảng cách tĩnh và hướng gió động trong ma trận kề) thành tham số có thể học hoặc thay đổi theo thời gian. Giá trị α tối ưu có thể khác nhau giữa mùa đông (khi nghịch nhiệt mạnh, gió yếu, ảnh hưởng không gian giảm) và mùa hè (khi gió mạnh, lan truyền ô nhiễm qua khoảng cách lớn hơn). Cơ chế thích ứng cho phép mô hình tự điều chỉnh mức độ sử dụng thông tin không gian tùy theo ngữ cảnh khí tượng, thay vì áp dụng hằng số cố định.

TÀI LIỆU THAM KHẢO

- [1] D. H. Bui and X.-H. Nghiem, “The effects of urbanization on air pollution and public health in Vietnam,” *Asian J. Water, Environ. Pollut.*, vol. 22, no. 3, pp. 198–210, 2025.
- [2] D. A. Dam *et al.*, “Assessment of PM_{2.5} distribution at different heights in Hanoi, Vietnam,” *J. Geoscience Environ. Protection*, vol. 12, no. 11, pp. 182–196, 2024.
- [3] Q. B. Ho *et al.*, “Assessment of air quality and health impact in Hanoi due to traffic emission,” *Atmosphere*, vol. 16, no. 11, p. 1301, 2025.
- [4] RTI International, “Study reveals water and air pollution risks in Vietnam.” [Online], 2024.
- [5] L.-T. Le *et al.*, “Environmental and health impacts of air pollution: A mini-review,” *Vietnam J. Sci., Technol. Eng.*, vol. 66, no. 1, pp. 120–128, 2024.
- [6] M. Krzyzanowski, J. S. Apte, S. Bonjour, C. A. Dora, M. S. Goldberg, and R. Vermeulen, “Air pollution in the mega-cities,” *Current Environmental Health Reports*, vol. 1, pp. 185–191, 2014.
- [7] L. T. Hoang, V. T. Duc, V. V. D. Ngoc, N. X. Truong, N. T. N. Thanh, P. T. T. Trang, S. Saksena, and N. T. T. Nhung, “Health and economic benefits of air pollution reductions in Vietnam during 2020–2021,” *Int. J. Public Health*, vol. 68, p. 1606238, 2023.
- [8] T. P. M. Nguyen *et al.*, “Application of the CMAQ model to assess the vertical distribution of PM_{2.5} pollution in the Hanoi area,” *Frontiers in Health Informatics*, vol. 13, no. 8, 2024.
- [9] World Health Organization, *WHO global air quality guidelines: particulate matter (PM_{2.5} and PM₁₀), ozone, nitrogen dioxide, sulfur dioxide and carbon monoxide*. Geneva: World Health Organization, 2021. License: CC BY-NC-SA 3.0 IGO.
- [10] X. Chen, H. Jin, Y. Huang, and Z. Feng, “XLinear: A lightweight and accurate mlp-based model for long-term time series forecasting with exogenous inputs,” *Proc. AAAI Conf. Artificial Intelligence*, vol. 40, no. 24, pp. 20325–20335, 2026.
- [11] Y. Liu, T. Hu, H. Zhang, H. Wu, S. Wang, L. Ma, and M. Long, “iTransformer: Inverted transformers are effective for time series forecasting,” 2024.
- [12] M. Silveira *et al.*, “An open-source and reproducible implementation of LSTM and GRU networks for time series forecasting,” 2025.
- [13] J. S. Armstrong and F. Collopy, “Error measures for generalizing about forecasting methods: Empirical comparisons,” *International Journal of Forecasting*, vol. 8, no. 1, pp. 69–80, 1992.
- [14] M. Panja, T. Chakraborty, A. Biswas, and S. Deb, “E-STGCN: Extreme spatiotemporal graph convolutional networks for air quality forecasting,” 2025.
- [15] T. Chen and C. Guestrin, “XGBoost: A scalable tree boosting system,” in *Proc. 22nd ACM SIGKDD*, pp. 785–794, 2016.
- [16] S. Tirink, “Machine learning-based forecasting of air quality index under long-term environmental patterns: A comparative approach with XGBoost, LightGBM, and SVM,” *PLOS ONE*, 2025.
- [17] M. Al-Nuaimi *et al.*, “Lightweight ML-based air quality prediction for IoT and embedded applications,” 2025.
- [18] B. He, L. Li, Y. Bo, and J. Zhou, “Bi-directional LSTM-GRU based time series forecasting approach,” *Int. J. Computer Science and Information Technology (IJCSIT)*, vol. 3, no. 2, 2024.
- [19] Y. Zhang *et al.*, “Air quality PM_{2.5} index prediction model based on CNN-LSTM,” 2025.
- [20] T. Chai and R. R. Draxler, “Root mean square error (RMSE) or mean absolute error (MAE)? – arguments against avoiding RMSE in the literature,” *Geoscientific Model Development*, vol. 7, no. 3, pp. 1247–1250, 2014.
- [21] C. J. Willmott and K. Matsuura, “Advantages of the mean absolute error (MAE) over the root mean square error (RMSE) in assessing average model performance,” *Climate Research*, vol. 30, pp. 79–82, 2005.

- [22] N. J. D. Nagelkerke, “A note on a general definition of the coefficient of determination,” *Biometrika*, vol. 78, no. 3, pp. 691–692, 1991.
- [23] J. W. Tukey, *Exploratory Data Analysis*. Addison-Wesley, 1977.
- [24] F. Pedregosa, G. Varoquaux, A. Gramfort, V. Michel, B. Thirion, O. Grisel, M. Blondel, P. Prettenhofer, R. Weiss, V. Dubourg, J. Vanderplas, A. Passos, D. Cournapeau, M. Brucher, M. Perrot, and É. Duchesnay, “Scikit-learn: Machine learning in Python,” *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, 2011.
- [25] G. E. Box and D. R. Cox, “An analysis of transformations,” *Journal of the Royal Statistical Society: Series B (Methodological)*, vol. 26, no. 2, pp. 211–243, 1964.
- [26] C. Hastings Jr, F. Mosteller, J. W. Tukey, and C. P. Winsor, “Low moments for small samples: a comparative study of order statistics,” *The Annals of Mathematical Statistics*, vol. 18, no. 3, pp. 413–426, 1947.
- [27] J. Han, M. Kamber, and J. Pei, *Data mining: concepts and techniques*. Morgan Kaufmann, 2011.
- [28] Y. LeCun, L. Bottou, G. B. Orr, and K.-R. Müller, “Efficient backprop,” in *Neural networks: Tricks of the trade*, pp. 9–50, Springer, 1998.
- [29] P. J. Rousseeuw and C. Croux, “Alternatives to the median absolute deviation,” in *Journal of the American Statistical Association*, vol. 88, pp. 1273–1283, 1993.
- [30] U.S. Environmental Protection Agency, “Technical assistance document for the reporting of daily air quality — the air quality index (AQI).” EPA 454/B-18-007, 2018.
- [31] Bộ Tài nguyên và Môi trường, “QCVN 05:2023/BTNMT — quy chuẩn kỹ thuật quốc gia về chất lượng không khí xung quanh.” Thông tư số 01/2023/TT-BTNMT, 2023.
- [32] Bộ Tài nguyên và Môi trường, “QCVN 06:2009/BTNMT — quy chuẩn kỹ thuật quốc gia về một số chất độc hại trong không khí xung quanh.” Thông tư số 16/2009/TT-BTNMT, 2009.
- [33] O. Troyanskaya, M. Cantor, G. Sherlock, P. Brown, T. Hastie, R. Tibshirani, D. Botstein, and R. B. Altman, “Missing value estimation methods for DNA microarrays,” *Bioinformatics*, vol. 17, no. 6, pp. 520–525, 2001.
- [34] J. W. Tukey, *Exploratory data analysis*, vol. 2. Addison-Wesley, 1977.
- [35] C. Bergmeir, R. J. Hyndman, and B. Koo, “A note on the validity of cross-validation for evaluating autoregressive time series prediction,” *Computational Statistics & Data Analysis*, vol. 120, pp. 70–83, 2018.